ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KINH TẾ - LUẬT

KHOA HỆ THỐNG THÔNG TIN

TIỂU LUẬN CUỐI KỲ

Học phần: Phân tích dữ liệu nâng cao

ĐỀ TÀI

HỆ THỐNG HỖ TRỢ RA QUYẾT ĐỊNH KHÉP KÍN TRONG PHÂN BỔ NGÂN SÁCH KHUYẾN MÃI VÀ ĐIỀU PHỐI CHIẾN DỊCH GIỮ CHÂN KHÁCH HÀNG ĐA KÊNH TRÊN NỀN TẢNG THƯƠNG MẠI ĐIỆN TỬ

GVHD: TS. Nguyễn Thôn Dã
Học viên: Phan Minh Quỳnh Tiên
MSHV: C25611266
Lớp: 261MIE401601

TP.HCM, THÁNG 11/2026

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KINH TẾ – LUẬT

KHOA HỆ THỐNG THÔNG TIN

TIỂU LUẬN CUỐI KỲ

Học phần: Phân tích dữ liệu nâng cao

ĐỀ TÀI

HỆ THỐNG HỖ TRỢ RA QUYẾT ĐỊNH KHÉP KÍN TRONG PHÂN BỔ NGÂN SÁCH KHUYẾN MÃI VÀ ĐIỀU PHỐI CHIẾN DỊCH GIỮ CHÂN KHÁCH HÀNG ĐA KÊNH TRÊN NỀN TẢNG THƯƠNG MẠI ĐIỆN TỬ

GVHD: TS. Nguyễn Thôn Dã
Học viên: Phan Minh Quỳnh Tiên
MSHV: C25611266
Lớp: 261MIE401601

TP.HCM, THÁNG 11/2026

LỜI CẢM ƠN

Để có thể hoàn thành bài tiểu luận cuối kỳ học phần Phân tích dữ liệu nâng cao, em đã nhận được sự giúp đỡ từ nhiều phía.

Đầu tiên, em xin gửi lời cảm ơn chân thành đến Ban lãnh đạo Trường Đại học Kinh tế – Luật và quý Thầy, Cô Khoa Hệ thống Thông tin. Thầy, Cô đã tạo điều kiện học tập và truyền đạt những kiến thức nền tảng để em có thể vận dụng vào bài tiểu luận này.

Đặc biệt, em xin gửi lời cảm ơn sâu sắc đến thầy TS. Nguyễn Thôn Dã, giảng viên phụ trách học phần. Những bài giảng của Thầy về dự báo, suy luận nhân quả, tối ưu hóa và vận hành hệ thống ra quyết định là nền tảng để em xây dựng toàn bộ chu trình tám giai đoạn trong bài.

Mặc dù em đã cố gắng hoàn thành bài tiểu luận một cách tốt nhất, nhưng do kiến thức và kinh nghiệm thực tế còn hạn chế nên bài làm khó tránh khỏi những thiếu sót. Em rất mong nhận được những nhận xét, góp ý của Thầy để bài tiểu luận được hoàn thiện hơn.

Em xin chân thành cảm ơn!

TP. Hồ Chí Minh, ngày … tháng 11 năm 2026

Học viên thực hiện

Phan Minh Quỳnh Tiên

LỜI CAM KẾT

Tôi xin cam kết bài tiểu luận cuối kỳ với đề tài "Hệ thống hỗ trợ ra quyết định khép kín trong phân bổ ngân sách khuyến mãi và điều phối chiến dịch giữ chân khách hàng đa kênh trên nền tảng thương mại điện tử" là bài làm của tôi, được thực hiện dưới sự hướng dẫn của TS. Nguyễn Thôn Dã.

Các số liệu và kết quả trong bài được tạo ra từ mã nguồn của dự án và có thể kiểm tra lại qua kho mã nguồn công khai, bảng mã băm SHA-256 và notebook Google Colab đính kèm ở Phụ lục. Các nội dung, dữ liệu và tài liệu tham khảo từ nguồn khác đều được trích dẫn đầy đủ theo chuẩn APA. Trong quá trình thực hiện, tôi có sử dụng công cụ trí tuệ nhân tạo (Claude) để hỗ trợ lập trình, kiểm tra và soạn thảo; việc sử dụng này được ghi nhận công khai trong kho mã nguồn. Tôi chịu hoàn toàn trách nhiệm về nội dung và kết quả của bài tiểu luận.

TP. Hồ Chí Minh, ngày … tháng 11 năm 2026

Học viên thực hiện

Phan Minh Quỳnh Tiên

MỤC LỤC

LỜI CẢM ƠN..... i
LỜI CAM KẾT.....ii
DANH MỤC HÌNH ẢNH.....v
DANH MỤC BẢNG BIỂU.....vi
DANH MỤC TỪ VIẾT TẮT.....vii
TÓM TẮT.....viii
I. GIỚI THIỆU (INTRODUCTION).....1
1.1. Bối cảnh thực tiễn và lý do thực hiện dự án.....1
1.2. Bài toán hướng đến quyết định và hành động.....1
1.3. Mục tiêu của dự án.....2
1.4. Phạm vi và giới hạn của dự án.....3
1.5. Phương pháp nghiên cứu và cách tiếp cận theo chu trình tám giai đoạn.....3
TÓM TẮT CHƯƠNG I.....4
II. CƠ SỞ LÝ THUYẾT (THEORETICAL BACKGROUND).....5
2.1. Tổng quan các khái niệm liên quan.....5
2.2. Các nghiên cứu và dự án ứng dụng liên quan trước đó.....7
2.3. Khung lý thuyết, mô hình toán học và cơ chế kiểm soát được áp dụng.....7
TÓM TẮT CHƯƠNG II.....7
III. PHƯƠNG PHÁP THỰC HIỆN (METHODOLOGY & SYSTEM DESIGN)..9
3.1. Quy trình triển khai theo chu trình tám giai đoạn, kiến trúc hệ thống, Graphic Abstract và đặc tả luồng xử lý.....9
3.2. Thiết kế dữ liệu theo thời gian, chiến lược nhận dạng nhân quả và công cụ Python sử dụng.....11
3.3. Hệ thống mô hình, thuật toán và cơ chế điều phối áp dụng.....13
3.4. Phương pháp kiểm định thực chứng, hệ thống chỉ số đo lường đa tầng và thiết kế vòng phản hồi.....15
TÓM TẮT CHƯƠNG III.....16
IV. KẾT QUẢ VÀ PHÂN TÍCH (RESULTS AND ANALYSIS).....18
4.1. Kết quả thực nghiệm qua từng giai đoạn.....18
4.2. Phân tích độ trễ đầu cuối, giám sát độ trôi, độ trễ nhãn và đối sánh Current – Challenger.....35
4.3. Phân tích, đánh giá kết quả thực chứng và kiểm định các cổng phát hành.....38
TÓM TẮT CHƯƠNG IV.....41
V. THẢO LUẬN (DISCUSSION).....42
5.1. So sánh kết quả đạt được với mục tiêu quản trị và các tiêu chí chấp nhận ban đầu.42
5.2. Những điểm mạnh, hạn chế của hệ thống.....42
5.3. Những phát hiện đáng chú ý.....44
TÓM TẮT CHƯƠNG V.....45
VI. KẾT LUẬN VÀ ĐỀ XUẤT (CONCLUSION AND RECOMMENDATIONS)
.....46

6.1. Tổng kết nội dung chính và tính xuyên suốt của toàn bộ quy trình hỗ trợ ra quyết định.....46
6.2. Ý nghĩa thực tiễn trong việc tối ưu hóa nguồn lực và kiểm soát rủi ro cho doanh nghiệp.....46
6.3. Hướng phát triển và nâng cấp hệ thống trong tương lai.....46
6.4. Kiến nghị vận hành và kịch bản ứng phó sự cố (Playbook) cho tổ chức.....47
VII. TÀI LIỆU THAM KHẢO (REFERENCES).....49
VIII. PHỤ LỤC (APPENDIX).....52
8.1. Tài liệu minh chứng được cấp quyền truy cập (Google Colab / GitHub Repository) 52
8.2. Mã nguồn Python xuyên suốt.....52
8.3. Hợp đồng dữ liệu đầu vào – đầu ra (trích).....53
8.4. Ma trận tương thích phiên bản.....54
8.5. Bảng mã băm kiểm chứng SHA-256.....54
8.6. Ghi chú tái lập.....55

DANH MỤC HÌNH ẢNH

Hình 3.1. Graphic Abstract: dữ liệu, chu trình tám giai đoạn và kết quả cổng phát hành.....9
Hình 3.2. Thiết kế trục thời gian: 38 kỳ t0, năm tập và các vùng embargo 42 ngày.....12
Hình 4.1. Tỷ lệ mua lại nền (a0) theo từng kỳ t0 và màu theo tập dữ liệu.....19
Hình 4.2. Biểu đồ độ tin cậy của $\hat{\mu}_0$ trên valid trước và sau hiệu chỉnh Platt.....20
Hình 4.3. Giá trị giỏ dự báo $\hat{S}$ so với quan sát trên valid và biên conformal 90 %.....21
Hình 4.4. SHAP beeswarm của $\hat{\mu}_0$ trên valid (thang log-odds, nhãn nghiệp vụ tiếng Việt).....22
Hình 4.5. Kiểm tra faithfulness: xóa top-k đặc trưng theo SHAP so với xóa ngẫu nhiên.....23
Hình 4.6. Chồng lấp propensity theo hành động (trên) và propensity ước lượng so với ghi log (dưới), train ngoài fold.....23
Hình 4.7. Forest plot ATE trên mua lại (trái) và lợi nhuận (phải), train, CI 95 % bootstrap cụm theo khách.....24
Hình 4.8. Đường Qini trên nhánh ngẫu nhiên valid+calib theo learner và theo hành động.....25
Hình 4.9. Dự báo power của cổng G3 theo bội số cỡ mẫu nhánh ngẫu nhiên so với locked...26
Hình 4.10. Regret chuẩn hóa A và B theo phương pháp (trung bình ± sd qua 5 seed).....27
Hình 4.11. Huấn luyện SPO+ (seed 42): SPO+ loss trên valid và giá trị DR theo epoch với ba learning rate.....28
Hình 4.12. MSE của vector chi phí so với regret chuẩn hóa hiện thực (trái) và kỳ vọng (phải) 29
Hình 4.13. MILP, Greedy và luật cũ theo từng kỳ: giá trị kế hoạch (trái) và giá trị thật kỳ vọng (phải).....30
Hình 4.14. Chi phí chiết khấu và xác suất mua: kế hoạch so với thực tế, theo trạng thái hiệu chỉnh của $\hat{\mu}_0$.....31
Hình 4.15. Thời gian giải theo số khách n: MILP (highspy, PuLP) so với Greedy, thang log.32
Hình 4.16. Số phận của các đề xuất MILP qua Router (mỗi khách xếp vào một nhóm, tổng 7 kỳ).....33
Hình 4.17. Giá trị thật của chính sách trước và sau Router theo từng kỳ: hiện thực (trái) và kỳ vọng (phải).....34
Hình 4.18. Hillstrom: hệ số Qini ± CI bootstrap 95 % trên test theo learner, chuyển đổi (trái) và chi tiêu (phải).....35
Hình 4.19. Giám sát OOT theo kỳ: (a) độ trễ P50/P95/P99, (b) ECE và Brier của Current và Challenger, (c) PSI của bốn biến tiêu biểu, (d) Action TVD.....36
Hình 4.20. Phát lại OOT: 15 biến trôi nhiều nhất theo PSI, Current so với Challenger, guardrail khi dữ liệu trôi, và giá trị thực hiện DR trên nhóm đối chứng.....37
Hình 4.21. Cổng phát hành chính thức trên Locked Test: G2 (độ tin cậy), G3 (Qini), G4 (giá trị chính sách), G6 (độ trễ).....39
Hình 5.1. Thiết kế thí điểm: power của G3 theo cỡ mẫu nhánh ngẫu nhiên (trái) và số kỳ cần để CI giá trị chương trình loại trừ 0 theo tỷ lệ đối chứng (phải).....45

DANH MỤC BẢNG BIỂU

Bảng 1.1. Hình thức hóa bài toán quyết định....1
Bảng 3.1. Đặc tả luồng xử lý của chu trình tám giai đoạn....9
Bảng 3.2. Tóm tắt các tập dữ liệu theo thời gian....12
Bảng 3.3. Hệ thống chỉ số đo lường đa tầng....15
Bảng 3.4. Cổng phát hành đăng ký trước (configs/config.yaml, đóng băng trước khi mở Locked Test)....15
Bảng 4.1. Kết quả kiểm thử rò rỉ ở giai đoạn 1....18
Bảng 4.2. Chỉ số dự báo của $\hat{\mu}_0$ trên valid (n = 3 650 dòng a0) trước và sau hiệu chỉnh....19
Bảng 4.3. PFI theo nhóm đặc trưng và 8 đặc trưng SHAP quan trọng nhất (valid)....21
Bảng 4.4. ATE trên biến mua lại (train, n = 43 921) theo các bộ ước lượng so với ATE thật. 24
Bảng 4.5. Chất lượng CATE của các learner trên valid+calib....25
Bảng 4.6. Regret chuẩn hóa trung bình trên calib (120 instance × 5 seed, lô 100 khách)....26
Bảng 4.7. Thí nghiệm nhiễu: MSE của vector chi phí và regret chuẩn hóa (calib, seed 0, trung bình theo mức nhiễu)....28
Bảng 4.8. MILP, Greedy và luật cũ trên toàn bộ khách của 7 kỳ valid+calib (B = £8 000, K = 60)....29
Bảng 4.9. Chi phí chiết khấu kế hoạch so với thực tế theo $\hat{\mu}_0$ thô và $\hat{\mu}_0$ đã hiệu chỉnh (7 kỳ valid+calib)....31
Bảng 4.10. Luồng quyết định qua Router v2.1 trên 7 kỳ valid+calib (25 327 dòng khách × kỳ) 32
Bảng 4.11. Giá trị chính sách cộng dồn 7 kỳ valid+calib theo luồng (lợi nhuận gia tăng so với a0)....33
Bảng 4.12. Giám sát phát lại Out-of-Time theo từng kỳ (Current)....35
Bảng 4.13. Cổng phát hành trên Locked Test (toàn bộ, mở một lần) và đối chiếu với dự báo đăng ký trước....38
Bảng 4.14. Khuyết nhãn có chọn lọc: ước lượng tác động trên nhóm khách được chọn (OOT, 765 khách được gửi, 72 đối chứng)....40
Bảng 4.15. Guardrail khi dữ liệu trôi trên 5 kỳ OOT (lợi nhuận gia tăng hiện thực cộng dồn) 41
Bảng 6.1. Playbook giám sát và ứng phó sự cố....47
Bảng 8.1. Các module mã nguồn và kích thước....52
Bảng 8.2. Trích hợp đồng dữ liệu....53
Bảng 8.3. Ma trận tương thích phiên bản (outputs/tables/s8_compat_matrix.csv)....54
Bảng 8.4. Trích bảng SHA-256....54

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Nội dung
AIPW / DR	Augmented Inverse Probability Weighting / Doubly Robust (ước lượng kép bền vững)
ATE	Average Treatment Effect (tác động nhân quả trung bình)
AUC	Area Under the Curve (diện tích dưới đường cong ROC/PR)
CATE	Conditional Average Treatment Effect (tác động nhân quả có điều kiện)
CI	Confidence Interval (khoảng tin cậy)
CRM	Customer Relationship Management (quản trị quan hệ khách hàng)
CSKH	Chăm sóc khách hàng
DML	Double/Debiased Machine Learning (học máy kép khử chệch)
ECE	Expected Calibration Error (sai số hiệu chỉnh kỳ vọng)
GBP (£)	Bảng Anh
GĐ	Giai đoạn
HITL	Human-in-the-loop (con người tham gia vào vòng ra quyết định)
IPW	Inverse Probability Weighting (trọng số nghịch đảo xác suất)
LP	Linear Programming (quy hoạch tuyến tính)
MILP	Mixed-Integer Linear Programming (quy hoạch tuyến tính nguyên hỗn hợp)
MLOps	Machine Learning Operations (vận hành hệ thống học máy)
MSE	Mean Squared Error (sai số bình phương trung bình)
OOT	Out-of-Time (dữ liệu ngoài thời gian huấn luyện)
PFI	Permutation Feature Importance (tầm quan trọng đặc trưng theo hoán vị)
PSI	Population Stability Index (chỉ số ổn định quần thể)
PTO	Predict-Then-Optimize (dự báo rồi tối ưu)
RCT	Randomized Controlled Trial (thử nghiệm ngẫu nhiên có đối chứng)
RFM	Recency – Frequency – Monetary (gần đây – tần suất – giá trị)
SHAP	SHapley Additive exPlanations (giải thích theo giá trị Shapley)
SHA-256	Secure Hash Algorithm 256-bit (hàm băm kiểm chứng toàn vẹn)
SPO+	Smart Predict-then-Optimize Plus (hàm mất mát hướng quyết định)
TMĐT	Thương mại điện tử
TVD	Total Variation Distance (khoảng cách biến thiên toàn phần)

TÓM TẮT

Trong thương mại điện tử, giữ chân khách hàng hiện có là khoản đầu tư hiệu quả hơn nhiều so với thu hút khách hàng mới. Tuy nhiên, ngân sách khuyến mãi giữ chân ở nhiều doanh nghiệp vẫn được phân bổ theo luật kinh nghiệm RFM. Cách làm này gửi ưu đãi cho cả những khách đằng nào cũng mua và không có cơ chế tự kiểm chứng hiệu quả. Vì thế, việc xây dựng một hệ thống ra quyết định dựa trên dữ liệu, có khả năng tự đánh giá bằng chứng trước khi triển khai, là rất cần thiết.

Mục tiêu của bài tiểu luận là xây dựng và kiểm chứng một hệ thống hỗ trợ ra quyết định khép kín cho bài toán phân bổ voucher và cuộc gọi chăm sóc khách hàng. Hệ thống đi qua tám giai đoạn: thiết kế dữ liệu theo thời gian, dự báo có hiệu chỉnh xác suất, giải thích mô hình, ước lượng nhân quả và uplift, Predict-Then-Optimize và SPO+, tối ưu hóa MILP, định tuyến hành động có guardrail và Human-in-the-loop, cuối cùng là kiểm định thực chứng và giám sát MLOps. Tác giả sử dụng dữ liệu Online Retail II (UCI) kết hợp lớp can thiệp bán tổng hợp, và kiểm định ngoài trên bộ dữ liệu thử nghiệm ngẫu nhiên thật Hillstrom.

Kết quả cho thấy hệ thống đạt 7/8 tiêu chí của cổng phát hành đăng ký trước trên Locked Test: dữ liệu không rò rỉ, hiệu chỉnh tốt (ECE 0,020), không vi phạm ràng buộc, độ trễ dưới 1,5 giây và không phân khúc nào bị thiệt. MILP trên giá trị dự báo giảm regret kỳ vọng từ 0,90 (luật cũ) xuống 0,49. Tuy nhiên, cổng regret G4b không đạt, và các chênh lệch về lợi nhuận tuy đúng hướng nhưng chưa vượt qua nhiễu thống kê. Vì vậy, hệ thống tự kết luận chưa đủ bằng chứng để phát hành toàn phần.

Từ đó, tác giả đề xuất doanh nghiệp chạy thí điểm với nhóm đối chứng 50 % trong khoảng 26–91 kỳ, nới giới hạn cuộc gọi theo giá bóng, hiệu chỉnh lại xác suất theo mùa và vận hành theo playbook giám sát có điều kiện quay lui.

Từ khóa: giữ chân khách hàng, uplift, Double Machine Learning, SPO+, MILP, Human-in-the-loop, MLOps, cổng phát hành.

I. GIỚI THIỆU (INTRODUCTION)

1.1. Bối cảnh thực tiễn và lý do thực hiện dự án

Trong thương mại điện tử (TMĐT), chi phí thu hút một khách hàng mới thường cao gấp nhiều lần chi phí giữ chân một khách hàng hiện có, nên ngân sách khuyến mãi giữ chân (voucher, mã giảm giá, cuộc gọi chăm sóc) là một trong những khoản chi tiếp thị lớn và lặp lại thường xuyên nhất của doanh nghiệp. Tuy vậy, cách phân bổ khoản chi này ở nhiều doanh nghiệp vẫn dựa trên các luật kinh nghiệm theo phân khúc RFM (Recency – Frequency – Monetary): khách lâu không mua thì gửi voucher, khách giá trị cao thì gọi điện. Cách làm này có ba điểm yếu đã được ghi nhận trong tài liệu nghiên cứu. Thứ nhất, nó nhắm vào *rủi ro rời bỏ* chứ không nhắm vào *khả năng thay đổi hành vi nhờ can thiệp*, trong khi hai đại lượng này không trùng nhau (Ascarza, 2018). Thứ hai, chiết khấu được trả cho cả những khách đằng nào cũng mua (sure things), nên một phần đáng kể ngân sách bị lãng phí. Thứ ba, các luật này không có cơ chế tự kiểm chứng: doanh nghiệp hiếm khi biết chiến dịch vừa qua thực sự mang lại bao nhiêu lợi nhuận gia tăng so với việc không làm gì.

Các tiến bộ gần đây về dự báo có hiệu chỉnh xác suất, suy luận nhân quả bằng học máy (Double Machine Learning, mô hình uplift) và tối ưu hóa hướng quyết định (Predict-Then-Optimize, SPO+) cho phép xây dựng một chu trình khép kín: từ dữ liệu giao dịch, dự báo xác suất mua lại và giá trị giỏ hàng, ước lượng tác động biên của từng phương án can thiệp lên từng khách hàng, rồi giải bài toán phân bổ ngân sách dưới ràng buộc vận hành và chuyển kết quả thành hành động có kiểm soát. Điều còn thiếu trong phần lớn các bài tập ứng dụng là **lớp kiểm chứng thực chứng**: cổng phát hành đăng ký trước, tập kiểm định khóa, phát lại ngoài thời gian và giám sát sau triển khai. Xuất phát từ thực tế đó, tác giả lựa chọn đề tài này nhằm xây dựng đầy đủ cả hai lớp trên trên một bộ dữ liệu giao dịch TMĐT thật, và đặc biệt để kiểm tra một câu hỏi mà doanh nghiệp thường bỏ qua: *với lượng dữ liệu hiện có, hệ thống đã đủ bằng chứng để được phát hành hay chưa?*

1.2. Bài toán hướng đến quyết định và hành động

Bài toán được hình thức hóa theo đúng các thành phần mà một hệ thống hỗ trợ ra quyết định cần có: chủ thể quyết định, đơn vị phân tích, thời điểm quyết định, kỳ dự báo, biến kết quả, tập hành động, hàm giá trị và các ràng buộc vận hành (Bảng 1.1).

Bảng 1.1. Hình thức hóa bài toán quyết định

Thành phần	Thiết kế trong tiểu luận
Chủ thể quyết định	Trưởng nhóm CRM ra quyết định gửi; bộ phận Tài chính duyệt ngân sách mệnh giá mỗi kỳ; bộ phận CSKH xử lý các ca cần con người duyệt (HITL).
Đơn vị phân tích	Cặp (khách hàng × thời điểm quyết định t0). t0 là thứ Hai, lặp lại 2 tuần một lần; 38 kỳ từ 07/06/2010 đến 07/11/2011.
Thời điểm quyết định và dữ liệu được dùng	Tại t0 chỉ dùng các sự kiện xảy ra trước cutoff = t0 − 1 ngày (giả định dữ liệu ngày hôm trước chưa kịp vào kho). Khách đủ điều kiện: có ít nhất một đơn hợp lệ trong 365 ngày trước t0.

Thành phần	Thiết kế trong tiểu luận
Kỳ dự báo và biến kết quả	Cửa sổ 30 ngày [t0, t0 + 30). Kết quả nhị phân Y = 1 nếu khách mua lại trong cửa sổ; kết quả giá trị S = giá trị giỏ hàng nếu mua.
Tập hành động	a0 không làm gì; a1 email voucher 10 % (trần £30); a2 email voucher 20 % (trần £60); a3 account manager gọi điện kèm voucher 10 % (trần £30, chi phí liên hệ £3/cuộc). Chi phí email £0,02.
Hàm giá trị	Lợi nhuận gia tăng so với a0 của khách i dưới hành động a: $V[i,a] = m\cdot\hat{S}_i\cdot\hat{\tau}_a(x_i) - \min(d_a\cdot\hat{S}_i, \text{trần}_a)\cdot(\hat{\mu}_0(x_i) + \hat{\tau}_a(x_i)) - \text{chi phí liên hệ}_a$; $V[i,a0] = 0$. Biên lợi nhuận gộp m = 0,30 (giả định, phân tích độ nhạy 0,20–0,40).
Ràng buộc vận hành	Mỗi khách đúng một hành động; tổng mệnh giá voucher phát hành mỗi kỳ ≤ B = £8 000; số cuộc gọi ≤ K = 60; số voucher 20 % ≤ 25 % tổng số voucher; độ phủ tối thiểu 3 % cho mỗi phân khúc UK / non-UK; không gửi voucher cho khách có tỷ lệ hủy đơn 365 ngày > 0,3, khách đã opt-out, hoặc khách đã nhận ưu đãi trong 28 ngày.

Hai ý trong hàm giá trị cần được giữ xuyên suốt toàn bài. Một là, chi phí chiết khấu được tính trên *tất cả* những người sẽ dùng voucher, tức là cả những người đằng nào cũng mua (xác suất nền $\hat{\mu}_0$) lẫn những người được thuyết phục thêm ($\hat{\tau}_a$). Vì vậy chất lượng hiệu chỉnh xác suất của $\hat{\mu}_0$ tác động trực tiếp đến chi phí kế hoạch và ngân sách, chứ không chỉ đến thứ hạng khách hàng. Hai là, ràng buộc ngân sách được định nghĩa theo **mệnh giá phát hành** (không phụ thuộc dự báo), nên miền khả thi của bài toán tối ưu là cố định. Đây là điều kiện để khung SPO+ (Elmachtoub & Grigas, 2022) áp dụng hợp lệ.

1.3. Mục tiêu của dự án

Mục tiêu tổng quát là xây dựng và kiểm chứng một hệ thống hỗ trợ ra quyết định khép kín, chuyển liền mạch từ dự báo và ước lượng nhân quả sang quyết định tối ưu và hành động có kiểm soát. Các mục tiêu cụ thể gồm:

1. Xây dựng bộ dữ liệu theo thời gian tại thời điểm ra quyết định (point-in-time), có kiểm thử rò rỉ tự động, chia tập theo thời gian với vùng đệm (embargo) và tập khách hàng giữ riêng (entity holdout).
2. Dự báo xác suất mua lại nền $\hat{\mu}_0$ và giá trị giỏ $\hat{S}$ với hiệu chỉnh xác suất (Platt) và định lượng bất định (khoảng conformal); giải thích mô hình bằng PFI và SHAP, có kiểm tra độ ổn định và faithfulness.
3. Nhận dạng và ước lượng tác động nhân quả trung bình (ATE) và không đồng nhất (CATE/uplift) của từng hành động bằng IPW, Double ML và các meta-learner; kiểm định ngoài mẫu bằng hệ số Qini trên nhánh ngẫu nhiên; kiểm định ngoài trên một RCT thật (Hillstrom).
4. Cấu trúc hóa bài toán theo Predict-Then-Optimize và SPO+, so sánh regret của hai khung; giải bài toán phân bổ ngân sách toàn quy mô bằng MILP với phân tích giá bóng, độ nhạy và chi phí tính toán.
5. Thiết kế Action Router tích hợp guardrail nghiệp vụ, Human-in-the-loop, nhóm đối chứng ngẫu nhiên và bản ghi quyết định chống lặp.

6. Triển khai lớp kiểm chứng thực chứng: cổng phát hành đăng ký trước, đóng băng bằng SHA-256, Locked Test mở đúng một lần, phát lại Out-of-Time với giám sát độ trễ, độ trôi, độ trễ nhãn, đối sánh Current – Challenger và playbook vận hành.

1.4. Phạm vi và giới hạn của dự án

Không gian và dữ liệu. Tác giả sử dụng bộ dữ liệu công khai Online Retail II (Chen, 2012; giấy phép CC BY 4.0), ghi nhận hơn một triệu dòng giao dịch của một nhà bán lẻ quà tặng trực tuyến tại Vương quốc Anh từ 12/2009 đến 12/2011, với phần lớn khách hàng là khách sỉ. Sau làm sạch còn 794 163 dòng giao dịch, tạo thành 151 013 cặp (khách × t0) đủ điều kiện trên 38 kỳ quyết định. Bộ dữ liệu chỉ có hành vi mua, không có lịch sử chiến dịch khuyến mãi; vì vậy **lớp can thiệp được xây dựng bán tổng hợp**: kết quả dưới a0 là hành vi mua lại thật, còn kết quả dưới a1–a3 được sinh từ một cơ chế đã biết, có lưu lại propensity của chính sách lịch sử. Cách làm này tạo ra "đáp án" (oracle) để tính regret thật, nhưng cũng là giới hạn quan trọng nhất của dự án: các kết quả nhân quả chỉ kiểm chứng được *cài đặt phương pháp*, không kiểm chứng được *hiệu quả thật của voucher*. Để bù đắp, dự án kiểm định phương pháp thêm một lần trên bộ dữ liệu thử nghiệm ngẫu nhiên thật Hillstrom (2008).

Khung thời gian. Dữ liệu được chia theo thời gian thành năm tập: huấn luyện (15 kỳ, 06–12/2010), chọn mô hình (4 kỳ, 01–03/2011), hiệu chỉnh (3 kỳ, 04–05/2011), Locked Test (3 kỳ, 07–08/2011, mở đúng một lần) và Out-of-Time (5 kỳ, 09–11/2011, mùa cao điểm quý IV). Giữa hai tập liên tiếp có vùng đệm 42 ngày lớn hơn cửa sổ nhãn 30 ngày.

Giới hạn nguồn lực và giả định. Biên lợi nhuận gộp 30 % là giả định; giá trị giỏ $\hat{S}$ được giả định không đổi theo can thiệp; người duyệt HITL là một quy tắc mô phỏng chứ không phải người thật; không mô hình hóa hiệu ứng mang sang giữa các kỳ. Toàn bộ pipeline chạy trên máy cá nhân (macOS Apple Silicon, Python 3.14) và một phần trên Linux; bộ giải MILP là HiGHS mã nguồn mở. Những giới hạn này được bàn kỹ ở Chương V.

1.5. Phương pháp nghiên cứu và cách tiếp cận theo chu trình tám giai đoạn

Tác giả thực hiện dự án theo cách tiếp cận thiết kế – thực nghiệm (design science), trong đó hệ thống được xây dựng thành tám giai đoạn nối tiếp, mỗi giai đoạn là một script Python độc lập có tiêu chí chấp nhận riêng, ghi bảng, hình và manifest SHA-256 của mọi đầu ra. Tám giai đoạn gồm: (1) thiết kế bài toán và dữ liệu chống rò rỉ; (2) dự báo nền và hiệu chỉnh xác suất; (3) giải thích và độ tin cậy; (4) nhân quả và uplift; (5) Predict-Then-Optimize và SPO+; (6) MILP toàn quy mô; (7) Action Router; (8) triển khai, kiểm định thực chứng và MLOps. Giai đoạn bổ sung s9 kiểm định ngoài trên Hillstrom. Nguyên tắc phương pháp luận xuyên suốt là **đăng ký trước và tách vai trò dữ liệu**: ngưỡng của các cổng phát hành được công bố trong file cấu hình trước khi mở Locked Test; mã nguồn, mô hình, cấu hình và dữ liệu được băm SHA-256 và đóng băng; đáp án (oracle) chỉ được đọc trong các hàm đánh giá có tên bắt đầu bằng `evaluate_`/`oracle_` và có kiểm thử tự động bảo vệ quy tắc này. Sau khi hoàn tất, một phiên kiểm toán độc lập

chỉ đọc đã tính lại toàn bộ bảy cổng phát hành và đối chiếu 443 con số trong bản tóm tắt kết quả với file nguồn.

TÓM TẮT CHƯƠNG I

Chương I đã trình bày bối cảnh thực tiễn của bài toán phân bổ ngân sách khuyến mãi giữ chân khách hàng trong TMĐT và lý do tác giả lựa chọn đề tài. Bài toán được hình thức hóa đầy đủ gồm chủ thể quyết định, đơn vị phân tích, thời điểm quyết định, tập hành động, hàm giá trị và các ràng buộc vận hành. Bên cạnh đó, tác giả đã xác định sáu mục tiêu cụ thể, phạm vi dữ liệu Online Retail II giai đoạn 2009–2011 và cách tiếp cận theo chu trình tám giai đoạn với nguyên tắc đăng ký trước. Đây là cơ sở để tác giả hệ thống hóa lý thuyết liên quan trong Chương II.

II. CƠ SỞ LÝ THUYẾT (THEORETICAL BACKGROUND)

2.1. Tổng quan các khái niệm liên quan

2.1.1. Dự báo có hiệu chỉnh và định lượng bất định

Một mô hình phân loại được gọi là *hiệu chỉnh tốt* (well-calibrated) khi trong số các trường hợp được dự báo xác suất p, tỷ lệ xảy ra thực tế xấp xỉ p. Chỉ số Expected Calibration Error (ECE) đo khoảng cách trung bình có trọng số giữa xác suất dự báo và tần suất quan sát trong từng bin (Naeini và cộng sự, 2015; Guo và cộng sự, 2017); tiểu luận dùng 15 bin cùng khối lượng để tránh bin thưa. Điểm Brier là trung bình bình phương sai số giữa p và nhãn, phân rã được thành thành phần hiệu chỉnh và thành phần phân giải. Hai bộ hiệu chỉnh hậu kỳ phổ biến là Platt scaling (hồi quy logistic trên logit của điểm thô; Platt, 1999) và hồi quy isotonic (đơn điệu không tham số). Với bài toán này hiệu chỉnh không chỉ là vấn đề thống kê: như đã nêu ở mục 1.2, $\hat{\mu}_0$ đi thẳng vào chi phí chiết khấu kế hoạch, nên lệch hiệu chỉnh là lệch ngân sách.

Với biến liên tục (giá trị giỏ hàng), bất định được định lượng bằng khoảng dự báo split-conformal (Lei và cộng sự, 2018): mô hình được khớp trên tập huấn luyện, phân vị của phần dư tuyệt đối được lấy trên một tập hiệu chỉnh độc lập, và khoảng $[\hat{y} - q, \hat{y} + q]$ bảo đảm độ phủ biên xấp xỉ $1 - \alpha$ mà không cần giả định phân phối. Trong bài, tác giả thực hiện hồi quy trên thang log, nên khoảng conformal là khoảng nhân.

2.1.2. Suy luận nhân quả và tác động biên

Theo khung kết quả tiềm năng, mỗi khách hàng i có các kết quả $Y_i(a)$ dưới từng hành động a, nhưng chỉ một trong số đó được quan sát. Tác động trung bình $ATE_a = E[Y(a) - Y(a0)]$ và tác động không đồng nhất có điều kiện $CATE_a(x) = E[Y(a) - Y(a0) | X = x]$ chỉ nhận dạng được dưới các giả định không nhiễu chưa quan sát (unconfoundedness), chồng lấp (overlap) và nhất quán. Khi chính sách lịch sử phụ thuộc vào đặc trưng đã quan sát, ước lượng naive bị chệch; hai hướng khắc phục là trọng số nghịch đảo propensity (IPW) và các bộ ước lượng kép bền vững (AIPW/doubly robust; Robins và cộng sự, 1994). Double/Debiased Machine Learning (Chernozhukov và cộng sự, 2018) kết hợp học máy linh hoạt cho các hàm nuisance với trực giao Neyman và cross-fitting để có ước lượng $\sqrt{n}$-nhất quán và khoảng tin cậy hợp lệ.

Với CATE, các meta-learner T-learner, X-learner (Künzel và cộng sự, 2019), DR-learner (Kennedy, 2023) và Causal Forest (Athey và cộng sự, 2019) là những lựa chọn tiêu chuẩn. Vì τ thật không quan sát được, chất lượng xếp hạng theo CATE được đánh giá bằng đường cong Qini/uplift trên nhánh ngẫu nhiên (Radcliffe, 2007): hệ số Qini dương với khoảng tin cậy bootstrap không chứa 0 là bằng chứng mô hình xếp hạng tốt hơn ngẫu nhiên. Trong tiếp thị, khách hàng được chia thành bốn nhóm theo cặp (Y(0), Y(a)): persuadables (chỉ mua khi được can thiệp), sure things, lost causes và sleeping dogs (bị can thiệp làm mất); chỉ nhóm thứ nhất tạo giá trị dương, và chi phí chiết khấu cho nhóm thứ hai là lãng phí.

2.1.3. Predict-Then-Optimize và SPO+

Bài toán quyết định có dạng max $w \in \mathcal{W}$ $c^T w$ với vector chi phí c chưa biết lúc ra quyết định. Khung hai giai đoạn Predict-Then-Optimize (PTO) huấn luyện mô hình $\hat{c} = f(x)$ theo sai số dự báo (MSE), rồi đưa $\hat{c}$ vào bộ giải. Elmachtoub và Grigas (2022) chỉ ra rằng sai số dự báo nhỏ không đồng nghĩa quyết định tốt, và đề xuất hàm mất mát SPO: $\ell_{SPO}(\hat{c}, c) = c^T w(c) - c^T w(\hat{c})$, tức là regret của quyết định; vì hàm này không lồi và không liên tục theo $\hat{c}$, họ đưa ra thay thế lồi SPO+ với subgradient $2(w(c) - w(2\hat{c} - c))$ (theo quy ước bài toán max). Lý thuyết yêu cầu miền khả thi $\mathcal{W}$ cố định, không phụ thuộc $\hat{c}$; thiết kế ngân sách theo mệnh giá ở mục 1.2 chính là để thỏa điều kiện này. Tổng quan về học hướng quyết định (decision-focused learning) và các thư viện hiện hành được trình bày trong Mandi và cộng sự (2024) và Tang & Khalil (2024).

2.1.4. Quy hoạch tuyến tính nguyên hỗn hợp (MILP)

Bài toán phân bổ ở mỗi kỳ là chọn biến nhị phân $x[i,a] \in \{0,1\}$ để cực đại Σ_{ia} $V[i,a] \cdot x[i,a]$ dưới các ràng buộc tuyến tính (mỗi khách một hành động, ngân sách mệnh giá, số cuộc gọi, tỷ lệ voucher sâu, độ phủ phân khúc). Đây là một bài toán kiểu multiple-choice knapsack, NP-khó về lý thuyết nhưng giải được rất nhanh với bộ giải branch-and-cut hiện đại; tác giả sử dụng bộ giải HiGHS (Huangfu & Hall, 2018) qua highspy và PuLP. Nghiệm đối ngẫu của bài toán nới lỏng LP cho **giá bóng** (shadow price): giá trị biên của thêm một đơn vị ngân sách hay một cuộc gọi, là thông tin quản trị quan trọng để Tài chính quyết định mức B, K. Giải pháp tham lam (Greedy) xếp hạng theo $\hat{V}$/mệnh giá là mốc so sánh tự nhiên về cả chất lượng lẫn thời gian giải.

2.1.5. Định tuyến hành động, Human-in-the-loop và MLOps

Điểm quyết định của mô hình không được gửi thẳng cho khách hàng. Lớp *Action Router* đứng giữa bộ tối ưu và kênh thực thi, kiểm tra hợp đồng dữ liệu đầu vào, áp các guardrail cứng (opt-out, giới hạn tần suất, sàn biên lợi nhuận, chặn khách hay hủy đơn), chuyển các ca không chắc chắn hoặc rủi ro cao sang người duyệt (Human-in-the-loop), giữ lại một nhóm đối chứng ngẫu nhiên để đo giá trị thực hiện, và ghi bản ghi quyết định có khóa chống lặp. Về MLOps, Sculley và cộng sự (2015) cảnh báo về nợ kỹ thuật ẩn trong hệ thống học máy; Breck và cộng sự (2017) đề xuất bộ tiêu chí sẵn sàng sản xuất gồm kiểm thử dữ liệu, mô hình, hạ tầng và giám sát. Các chỉ số giám sát tiêu chuẩn là Population Stability Index (PSI) cho trôi phân phối đặc trưng và điểm số, Brier/ECE khi nhãn trưởng thành, khoảng cách biến thiên toàn phần (TVD) của phân phối hành động, và độ trễ P50/P95/P99 của pipeline. Gama và cộng sự (2014) tổng quan các cơ chế thích nghi với trôi khái niệm; mô hình Current – Challenger là cơ chế vận hành phổ biến để đưa phiên bản mới vào so sánh song song trước khi thay thế.

Một vấn đề đặc thù của hệ thống quyết định – hành động là **khuyết nhãn có chọn lọc** (selective labels; Lakkaraju và cộng sự, 2017): sau khi hệ thống vận hành, nhãn chỉ được quan sát cho những khách mà chính sách đã chọn, nên dữ liệu phản hồi bị chệch và mô hình học lại từ đó có thể tự củng cố sai lầm. Nhóm đối chứng ngẫu nhiên và các bộ ước lượng doubly robust (Dudík và cộng sự, 2011) là hai công cụ để kiểm soát vấn đề này.

2.2. Các nghiên cứu và dự án ứng dụng liên quan trước đó

Về tiếp thị giữ chân, Ascarza (2018) dùng thử nghiệm thực địa để chứng minh rằng nhắm vào khách có rủi ro rời bỏ cao nhất là chiến lược kém hiệu quả, vì rủi ro cao không đồng nghĩa với độ nhạy can thiệp cao; đây là cơ sở để tác giả đưa "nhắm theo rủi ro" vào làm một mốc so sánh. Gubela và cộng sự (2019) so sánh có hệ thống các chiến lược mô hình uplift trong TMĐT và cho thấy sự khác biệt giữa các learner thường nhỏ hơn nhiều so với sự khác biệt giữa cách đánh giá; điều này nhất quán với việc tác giả chọn learner bằng Qini trên nhánh ngẫu nhiên thay vì bằng chỉ số dự báo. Bộ dữ liệu Hillstrom (2008), một RCT thật với 64 000 khách và hai nhánh email, là chuẩn mực để kiểm định phương pháp uplift và được tác giả dùng làm kiểm định ngoài.

Về tối ưu hóa hướng quyết định, Bertsimas và Kallus (2020) xây dựng khung "từ dự báo đến đề xuất" và chứng minh rằng điều kiện hóa quyết định trên dữ liệu phụ trợ có thể giảm regret đáng kể; Elmachtoub và Grigas (2022) cùng Mandi và cộng sự (2024) tổng kết bằng chứng rằng SPO+ thắng PTO khi mô hình bị sai dạng (misspecified) nhưng lợi thế thu hẹp khi mô hình dự báo đủ tốt hoặc nhãn chi phí quá nhiễu. Về phương pháp luận nghiên cứu, Nosek và cộng sự (2018) lập luận cho đăng ký trước như một cơ chế tách khâu sinh giả thuyết khỏi khâu kiểm định; tác giả chuyển cơ chế này vào bối cảnh phát hành mô hình bằng file cấu hình đóng băng và Locked Test mở một lần.

2.3. Khung lý thuyết, mô hình toán học và cơ chế kiểm soát được áp dụng

Khung lý thuyết mà tác giả áp dụng gồm ba tầng nối nhau bằng hàm giá trị V[i,a]. **Tầng dự báo** cung cấp $\hat{\mu}_0(x) = P(Y = 1 \mid A = a0, x)$ đã hiệu chỉnh và $\hat{S}(x) = E[S \mid x]$ kèm khoảng conformal. **Tầng nhân quả** cung cấp $\hat{\tau}_a(x) = E[Y(a) - Y(a0) \mid x]$ cho $a \in \{a1, a2, a3\}$ kèm khoảng tin cậy. **Tầng quyết định** giải bài toán:

$$\max \Sigma_i \Sigma_a V[i,a] \cdot x[i,a] \quad \text{s.t.} \quad \Sigma_a x[i,a] = 1 \ \forall i; \ \Sigma_i \Sigma_a \text{trần}_a \cdot x[i,a] \le B; \ \Sigma_i x[i,a3] \le K;$$

$$\Sigma_i x[i,a2] \le 0{,}25 \cdot \Sigma_i \Sigma_{a \ne a0} x[i,a]; \ \Sigma_{i \in g} \Sigma_{a \ne a0} x[i,a] \ge \lceil 0{,}03 \cdot |g| \rceil \ \forall g \in \{\text{UK, non-UK}\};$$

$$x[i,a] = 0 \text{ nếu guardrail chặn.}$$

Chất lượng quyết định được đo bằng **regret chuẩn hóa** $R = (Z - Z_\pi)/|Z|$, trong đó Z_π là lợi nhuận gia tăng thật của chính sách π và Z *là giá trị của chính sách tốt nhất trong cùng miền khả thi. Tác giả phân biệt hai mốc: regret A lấy Z* theo kết quả *hiện thực* (chính sách biết trước mọi kết quả) và regret B lấy Z *theo* kỳ vọng thật* của cơ chế sinh dữ liệu; A luôn lớn hơn B vì chứa phần may rủi không thể dự báo. Cơ chế kiểm soát gồm bảy cổng phát hành (G1 hợp đồng dữ liệu; G2 hiệu chỉnh; G3 Qini; G4a lợi nhuận so với luật cũ; G4b regret; G5 ràng buộc; G6 độ trễ; G7 công bằng phân khúc) với ngưỡng công bố trước, và một playbook giám sát sau triển khai gắn mỗi cảnh báo với ngưỡng, chủ sở hữu, hành động và điều kiện quay lui. Toàn bộ khung này được triển khai trong một kho mã nguồn duy nhất với manifest SHA-256 cho từng giai đoạn.

TÓM TẮT CHƯƠNG II

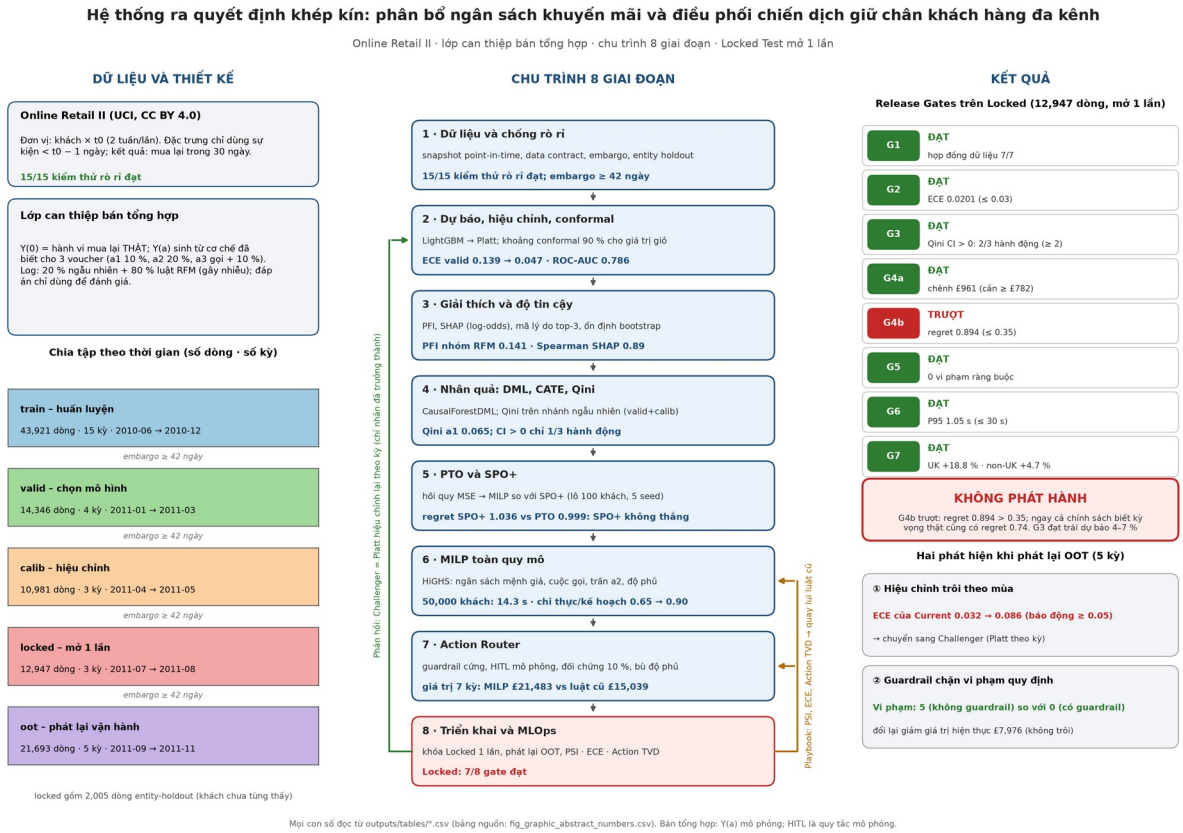
Chương II đã hệ thống hóa các khái niệm nền tảng của đề tài: dự báo có hiệu chỉnh và định lượng bất định, suy luận nhân quả và tác động biên, khung Predict-Then-

Optimize và SPO+, quy hoạch tuyến tính nguyên hỗn hợp, định tuyến hành động và MLOps. Thông qua tổng quan các nghiên cứu trước, tác giả nhận thấy nhắm theo rủi ro rời bỏ chưa chắc hiệu quả, việc đánh giá mô hình uplift cần dựa trên nhánh ngẫu nhiên, và lợi thế của SPO+ phụ thuộc vào chất lượng nhãn chi phí. Từ đó, tác giả xây dựng khung lý thuyết ba tầng nối với nhau bằng hàm giá trị, cùng hệ thống bảy cổng phát hành. Khung này được cụ thể hóa thành quy trình và kiến trúc hệ thống trong Chương III.

III. PHƯƠNG PHÁP THỰC HIỆN (METHODOLOGY & SYSTEM DESIGN)

3.1. Quy trình triển khai theo chu trình tám giai đoạn, kiến trúc hệ thống, Graphic Abstract và đặc tả luồng xử lý

Hình 3.1 là Graphic Abstract của toàn bộ hệ thống: cột trái mô tả dữ liệu và cách chia tập, cột giữa là chu trình tám giai đoạn với kết quả chính của từng giai đoạn, cột phải là bảng cổng phát hành trên Locked Test và hai phát hiện khi phát lại Out-of-Time. Hai mũi tên phản hồi thể hiện vòng lặp MLOps: Challenger hiệu chỉnh lại theo kỳ khi nhãn trưởng thành, và playbook giám sát (PSI, ECE, Action TVD) có thể quay lui về luật cũ.



Hình 3.1. Graphic Abstract: dữ liệu, chu trình tám giai đoạn và kết quả cổng phát hành

Nguồn: Tác giả thiết kế; số liệu đọc từ `outputs/tables/fig_graphic_abstract_numbers.csv`

Về kiến trúc phần mềm, mỗi giai đoạn là một module `src/sX_*.py` có hàm `main()`, đọc toàn bộ tham số từ một file cấu hình duy nhất `configs/config.yaml`, đặt seed cố định, và kết thúc bằng việc ghi manifest JSON chứa SHA-256 của mọi file đầu ra cùng phiên bản thư viện. Bảng 3.1 đặc tả luồng xử lý: đầu vào, đầu ra và công cụ của từng giai đoạn.

Bảng 3.1. Đặc tả luồng xử lý của chu trình tám giai đoạn

GĐ	Nội dung và đầu vào	Đầu ra chính	Công cụ Python
1	Làm sạch Online Retail II; snapshot point-in-time theo t0; nhãn 30 ngày; chia tập theo thời gian + embargo + entity	`snapshots.parquet`, `s1_split_summary`, `s1_leakage_tests`, từ điển dữ liệu	pandas, pyarrow, pandera

GĐ	Nội dung và đầu vào	Đầu ra chính	Công cụ Python
	holdout; hợp đồng dữ liệu; 6 kiểm thử rò rỉ		
1b	Lớp can thiệp bán tổng hợp: Y(0) thật, Y(a) từ cơ chế đã biết; chính sách lịch sử 20 % ngẫu nhiên + 80 % luật RFM; propensity ghi log	`logged.parquet` (mô hình được thấy), `oracle.parquet` (đáp án, chỉ để đánh giá)	numpy
2	$\hat{\mu}_0$ (Logistic, LightGBM) chọn trên valid; Platt/Isotonic khớp trên calib; $\hat{S}$ hồi quy log + split-conformal 90 %	`pred_s2.parquet`: `mu0_raw, mu0_cal, s_hat, s_lo, s_hi`; reliability diagram	scikit-learn, LightGBM
3	PFI (10 lần lặp) theo đặc trưng và nhóm; SHAP TreeExplainer; ổn định bootstrap; faithfulness xóa top-k; mã lý do top-3	`reasons_s3.parquet`, bảng PFI/SHAP, beeswarm, waterfall	SHAP, scikit-learn
4	Propensity ước lượng vs ghi log; ATE (naive, IPW, DML-APOS, DML-IRM); CATE (T, X, DR-learner, CausalForestDML); Qini trên nhánh ngẫu nhiên; placebo	`pred_s4.parquet`: `tau_hat_a*, tau_lo/hi_a*, V_hat_a*`	EconML, DoubleML, scikit-uplift
4b	Dự báo power của cổng G3 trên locked (đăng ký trước)	`s4_power_g3*.csv`	numpy
5	Lô 100 khách; so sánh luật cũ, nhắm rủi ro, Greedy, MILP trên $\hat{V}$, PTO (MSE), SPO+ (tự cài subgradient); MSE ↔ regret; kiểm chứng instance 6 khách	`s5_regret_summary`, `s5_mse_vs_regret`, `s5_verification_6`	numpy, scipy, highspy, LightGBM
5b	Chẩn đoán bộ ước lượng DR/AIPW: chệch, độ phủ CI, đuôi nặng	`s5b_estimates`, `s5b_bias_units`	numpy
6	MILP toàn quy mô từng t0; MILP vs Greedy vs luật cũ; giá bóng; độ nhạy B, K, m; thời gian giải theo n; thí nghiệm hiệu chỉnh ↔ chi phí chiết khấu	`s6_main_comparison`, `s6_shadow_prices`, `s6_scaling`	PuLP, highspy (HiGHS)
7	`ActionRouter`: hợp đồng đầu vào → guardrail cứng → đối chứng 10 % → MILP → hậu kiểm HITL → bù độ phủ → sửa khả thi cuối; bản ghi quyết định chống lặp	`decisions_s7_v21.parquet`, thống kê luồng, độ trễ	Python thuần, pandas
8	Đóng băng SHA-256; Locked Test mở 1 lần → 7 cổng; phát lại OOT: độ trễ, PSI, Brier/ECE khi nhãn trưởng thành, TVD, DR; Current vs Challenger;	`s8_freeze_manifest`, `s8_locked_gates`, `s8_oot_*`, `s8_oot_playbook`	Python thuần, pytest

GĐ	Nội dung và đầu vào	Đầu ra chính	Công cụ Python
	kịch bản trôi; playbook		
s9	Kiểm định ngoài trên RCT Hillstrom: ATE, CATE, Qini, MILP vs ngẫu nhiên	`s9_ate_rct`, `s9_qini_test`, `s9_policy_value_test`	EconML, scikit-uplift

3.2. Thiết kế dữ liệu theo thời gian, chiến lược nhận dạng nhân quả và công cụ Python sử dụng

3.2.1. Dữ liệu nguồn và làm sạch

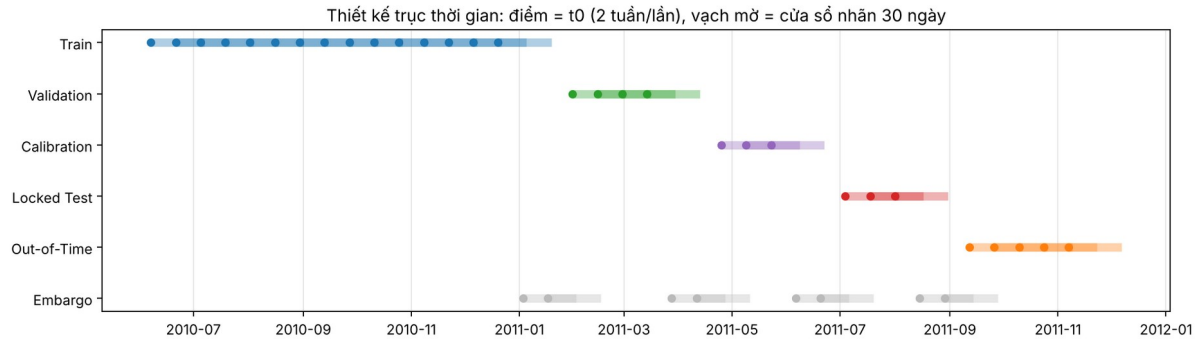
Online Retail II gồm hai sheet (12/2009–12/2010 và 12/2010–12/2011) với 1 067 371 dòng. Quy trình làm sạch gồm bảy bước được ghi nhật ký: bỏ hóa đơn trùng giữa hai sheet (22 523 dòng), bỏ dòng trùng tuyệt đối (11 812), bỏ dòng thiếu mã khách vì không gắn được đơn vị phân tích (235 151), chỉ giữ hóa đơn bán và hóa đơn hủy, bỏ mã không phải hàng hóa như phí bưu điện hay phí ngân hàng (3 662), bỏ đơn giá không dương (60) và kiểm tra dấu số lượng khớp loại hóa đơn. Kết quả còn 794 163 dòng giao dịch. Hóa đơn hủy (mã bắt đầu bằng C) được giữ riêng để tính các đặc trưng hủy đơn và guardrail.

3.2.2. Snapshot point-in-time và đặc trưng

Với mỗi t0 trên lưới hai tuần, hệ thống dựng một snapshot cho mọi khách đủ điều kiện, chỉ dùng giao dịch có thời điểm < cutoff = t0 − 1 ngày. Từ điển dữ liệu gồm 40 cột, trong đó 31 đặc trưng mô hình được chia thành năm nhóm: RFM (recency, thâm niên, số đơn và doanh số trong 30/90/180/365 ngày và toàn lịch sử, giá trị đơn trung bình, số mã hàng, số dòng và số lượng mỗi đơn, xu hướng doanh số 90/365), nhịp mua (chu kỳ mua trung bình, độ lệch chu kỳ, mức quá chu kỳ), hủy đơn (số lần, giá trị, tỷ lệ hủy 365 ngày, số ngày từ lần hủy gần nhất), lịch (tháng của t0, số ngày đến Giáng sinh) và quốc gia (UK/non-UK, top-10 quốc gia). Nhãn Y được tính trên cửa sổ [t0, t0 + 30) từ cùng bảng giao dịch, với độ trễ nhãn 30 ngày; cửa sổ nhãn cuối cùng kết thúc 07/12/2011, trước ngày cuối của dữ liệu.

3.2.3. Chia tập theo thời gian, embargo và entity holdout

Hình 3.2 và Bảng 3.2 mô tả cách chia tập. Năm tập được xếp theo thời gian với vùng đệm (embargo) 42 ngày giữa hai tập liên tiếp, lớn hơn cửa sổ nhãn 30 ngày, để nhãn của kỳ cuối tập trước không chồng lên đặc trưng của kỳ đầu tập sau. Ngoài ra 15 % mã khách được chọn bằng hàm băm làm **entity holdout**: những khách này không bao giờ xuất hiện trong train/valid/calib, chỉ xuất hiện trong locked và oot, nên cho phép đo riêng hiệu năng trên khách hàng mô hình chưa từng thấy. Vai trò của từng tập được quy định cứng: train để huấn luyện (GroupKFold theo khách khi tinh chỉnh), valid để chọn mô hình và siêu tham số, calib chỉ để khớp bộ hiệu chỉnh xác suất và khoảng conformal, locked chỉ mở ở giai đoạn 8 sau khi đóng băng, oot để phát lại vận hành.



Hình 3.2. Thiết kế trục thời gian: 38 kỳ t0, năm tập và các vùng embargo 42 ngày

Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s1_split_timeline.png`)

Bảng 3.2. Tóm tắt các tập dữ liệu theo thời gian

Đvt: dòng (khách × kỳ), khách

Tập	Khoảng t0	Số kỳ	Số dòng	Số khách	Tỷ lệ mua lại (a0)	Dòng entity holdout
train	07/06/2010 – 20/12/2010	15	43 921	3 637	0,2575	0
valid	31/01/2011 – 14/03/2011	4	14 346	3 741	0,1751	0
calib	25/04/2011 – 23/05/2011	3	10 981	3 753	0,2031	0
locked	04/07/2011 – 01/08/2011	3	12 947	4 426	0,1873	2 005
oot	12/09/2011 – 07/11/2011	5	21 693	4 782	0,2817	3 396
embargo (không dùng)	8 kỳ xen kẽ	8	34 348	5 119	0,1875	5 323

Nguồn: Tác giả tính toán từ `outputs/tables/s1_split_summary.csv`. Tỷ lệ mua lại biến thiên mạnh theo mùa (0,2575 ở train, 0,1751 ở valid, 0,2817 ở oot), là nguồn trôi hiệu chỉnh được phân tích ở Chương IV.

3.2.4. Hợp đồng dữ liệu và kiểm thử rò rỉ

Hợp đồng dữ liệu được khai báo bằng pandera cho ba bảng snapshot, logged và decisions (kiểu dữ liệu, ràng buộc miền giá trị, khóa duy nhất; trích ở Phụ lục). Sáu kiểm thử rò rỉ chạy tự động ở giai đoạn 1: (T1) dựng lại đặc trưng từ dữ liệu cắt tại cutoff và so sánh; (T2) nhân giá trị và số lượng của mọi giao dịch sau cutoff lên 10 lần và xác nhận đặc trưng không đổi; (T3) tính lại nhãn độc lập; (T4) khoảng cách embargo ≥ 30 ngày ở cả bốn ranh giới; (T5) cô lập entity holdout; (T6) nhãn, khóa và cột kiểm toán không nằm trong danh sách đặc trưng. T1–T3 chạy trên bốn t0 ngẫu nhiên; phiên kiểm toán độc lập sau đó tính lại trên cả 38 kỳ.

3.2.5. Lớp can thiệp bán tổng hợp và chiến lược nhận dạng nhân quả

Vì dữ liệu gốc không có chiến dịch khuyến mãi, giai đoạn 1b sinh kết quả tiềm năng Y(a) cho a1–a3 từ Y(0) thật theo cơ chế: với người không mua (Y(0) = 0), xác suất

chuyển đổi c_a tăng theo mức "sắp rời bỏ" (hàm của hạng phần trăm recency) và giảm theo tần suất mua; a2 có thêm thành phần nhạy giá (tăng khi giá trị đơn thấp), a3 có thêm thành phần giá trị (tăng khi giá trị đơn cao); với người đang mua (Y(0) = 1), xác suất bị làm phiền d_a nhỏ, riêng a3 lớn hơn ở khách sỉ mua đều (sleeping dogs). Giá trị giỏ của người mới chuyển đổi mô phỏng bằng aov_365 nhân nhiễu lognormal. Chính sách lịch sử (logging policy) gửi 20 % ngẫu nhiên đều và 80 % theo luật RFM; propensity của mỗi dòng được lưu lại. Thiết kế này tạo nhiễu (confounding) có chủ đích theo các đặc trưng đã quan sát, và vì cơ chế sinh dữ liệu chỉ phụ thuộc đặc trưng đã quan sát, giả định không nhiễu chưa quan sát đúng theo cấu trúc. Chiến lược nhận dạng vì thế là: ước lượng propensity bằng mô hình như thể chưa biết, dùng IPW/AIPW/DML để khử chệch, và dùng nhánh 20 % ngẫu nhiên làm nơi duy nhất để đánh giá Qini ngoài mẫu. Luật cứng của dự án: `oracle.parquet` chỉ được đọc trong các hàm đánh giá, và một kiểm thử tự động quét mã nguồn để bảo đảm điều đó.

3.2.6. Công cụ Python sử dụng

Toàn bộ hệ thống được tác giả xây dựng bằng ngôn ngữ Python, chia theo chức năng như sau:

- **Xử lý và kiểm soát dữ liệu:** pandas, numpy, pyarrow (lưu parquet), pandera (hợp đồng dữ liệu).
- **Dự báo, hiệu chỉnh và giải thích:** scikit-learn (Pipeline, logistic, Platt, Isotonic), LightGBM, SHAP.
- **Nhân quả và uplift:** EconML (DML, DR-learner, CausalForestDML), DoubleML (DML-IRM), scikit-uplift (Qini, AUUC).
- **Tối ưu hóa:** highspy và PuLP gọi bộ giải HiGHS; SPO+ được tác giả tự cài bằng numpy, PyEPO chỉ dùng để đối chiếu.
- **Kiểm thử và tái lập:** pytest (77 kiểm thử), hashlib (SHA-256), Jupyter/Google Colab cho notebook nộp bài.

Phiên bản cụ thể của từng thư viện được ghi trong ma trận tương thích ở Phụ lục.

3.3. Hệ thống mô hình, thuật toán và cơ chế điều phối áp dụng

3.3.1. Mô hình dự báo nâng cao, bộ hiệu chỉnh xác suất (Calibrator) và định lượng bất định

$\hat{\mu}_0$ được học trên các dòng của train có hành động ghi log là a0 (hợp lệ vì chính sách lịch sử chỉ phụ thuộc đặc trưng đã quan sát). Hai họ mô hình được so sánh: hồi quy logistic (impute, chuẩn hóa, one-hot quốc gia) và LightGBM, tinh chỉnh bằng GroupKFold 5 fold theo khách trên lưới nhỏ, chọn trên valid theo log loss và PR-AUC. Bộ hiệu chỉnh Platt và Isotonic được khớp trên calib ∧ a0, chọn bằng CV 5 fold bên trong calib theo log loss, rồi báo cáo trên valid với ECE 15 bin cùng khối lượng, Brier, và CI bootstrap 95 % (300 lần). $\hat{S}$ là LightGBM hồi quy trên log giá trị giỏ của các dòng có mua trong train, với hệ số smearing Duan để quay về thang gốc và khoảng split-conformal 90 % khớp trên calib.

3.3.2. Mô hình phân tích nhân quả và ước lượng tác động biên (Double ML / CATE / Uplift)

ATE từng hành động so với a0 được ước lượng bằng bốn cách để đối chiếu: naive, IPW với propensity ghi log, IPW với propensity ước lượng, DML-APOS đa nhánh (EconML, cross-fitting 5 fold) và DML-IRM từng cặp (DoubleML). CATE đa nhánh được học bằng T-learner (mốc), X-learner, DR-learner và CausalForestDML (để có CI); learner được chọn theo Qini trên nhánh ngẫu nhiên của valid, rồi báo cáo riêng trên calib (không dùng để chọn, nên không bị thiên lệch chọn mô hình). Các chẩn đoán gồm histogram chồng lấp propensity, kiểm định placebo (xáo trộn A, kỳ vọng ATE ≈ 0) và ổn định theo tập con. Đầu ra là $\hat{\tau}_a(x)$ kèm CI và $\hat{V}[i,a]$ tính theo công thức ở mục 1.2 với $\hat{\mu}_0$ đã hiệu chỉnh và $\hat{S}$.

3.3.3. Cấu trúc hóa bài toán quyết định (Predict-Then-Optimize / SPO+) và tối ưu hóa phân bổ nguồn lực bằng MILP

Ở giai đoạn 5, mỗi instance là một lô 100 khách lấy mẫu trong một t0, với B và K co theo tỷ lệ $100/n_{t_0}$. Vector chi phí huấn luyện cho PTO và SPO+ là pseudo-outcome AIPW ngoài fold của lợi nhuận gia tăng (dùng propensity ghi log và $\hat{\mu}_a$ cross-fitting), không dùng đáp án. SPO+ được tự cài bằng subgradient $2(w(c) - w(2\hat{c} - c))$ theo quy ước bài toán max, kiểm chứng trên một instance 6 khách bằng cách liệt kê toàn bộ 4 096 nghiệm. Một quy tắc đăng ký trước về mở rộng biên lưới siêu tham số được áp dụng thống nhất cho mọi phương pháp có học. Giai đoạn 6 giải MILP trên toàn bộ khách của từng t0 (3,5–3,7 nghìn khách) bằng PuLP + HiGHS (giới hạn 60 giây, gap 0,1 %), đối chiếu với highspy trực tiếp; lấy giá bóng từ nghiệm đối ngẫu của LP nới lỏng; chạy độ nhạy theo $B \in \{2k, 4k, 8k, 16k, 32k\}$, $K \in \{30, 60, 120\}$, $m \in [0{,}20; 0{,}40]$ và thời gian giải theo n tới 50 000 khách.

3.3.4. Cơ chế định tuyến hành động (Action Router) tích hợp quy tắc nghiệp vụ (Guardrails) và Human-in-the-loop

Lớp `ActionRouter` xử lý từng kỳ theo trình tự: (1) kiểm tra hợp đồng đầu vào; (2) guardrail cứng: opt-out giả lập 8 % theo hàm băm, giới hạn tần suất 28 ngày theo nhật ký quyết định của chính router, sàn biên lợi nhuận (chiết khấu ≤ $m \cdot \hat{S}$), tỷ lệ hủy đơn > 0,3 chặn mọi voucher; (3) nhóm đối chứng 10 % chọn bằng băm (khách × t0) và ép về a0; (4) giải MILP trên miền còn lại; (5) hậu kiểm: ca có CI của $\hat{\tau}$ vắt qua 0 nhưng $\hat{V}$ lớn, hoặc khoảng conformal của $\hat{S}$ quá rộng, hoặc khách VIP top 2 % được đề xuất a2/a3 thì chuyển HITL; solver quá giờ thì chuyển Greedy; thiếu mô hình thì chuyển luật cũ; (6) bù độ phủ phân khúc nếu HITL từ chối làm hụt; (7) bước sửa khả thi cuối bảo đảm tỷ lệ a2 ≤ 25 % và ngân sách. Người duyệt HITL là quy tắc mô phỏng: duyệt nếu $\hat{V}$ tính tại điểm giữa $\hat{\tau}$ và cận dưới CI vẫn ≥ 0. Mỗi quyết định có `decision_id` (uuid5), khóa chống lặp `customer_id|t0|policy_version`, phiên bản mô hình và quy tắc, mã lý do từ giai đoạn 3 và từ guardrail.

3.4. Phương pháp kiểm định thực chứng, hệ thống chỉ số đo lường đa tầng và thiết kế vòng phản hồi

Hệ thống chỉ số được tổ chức theo nhiều tầng tương ứng với từng lớp của kiến trúc (Bảng 3.3): chất lượng dự báo, hiệu chỉnh, chất lượng xếp hạng nhân quả, tổn thất quyết định, giá trị thực hiện, độ trễ và độ trôi. Điểm khác biệt về phương pháp so với một bài phân tích thông thường là **cổng phát hành được đăng ký trước** (Bảng 3.4): bảy cổng với ngưỡng ghi trong `configs/config.yaml` và các làm rõ về cách tính ghi trong `CLAUDE.md` mục 6b, tất cả nằm trong phạm vi băm SHA-256 và được đóng băng trước khi mở Locked Test. Mục 6b còn chứa các **dự báo đăng ký trước** về kết quả của từng cổng (ví dụ P(G3 đạt) ≈ 4–7 %, G4b gần như chắc trượt) để sau này đối chiếu, theo tinh thần Nosek và cộng sự (2018).

Bảng 3.3. Hệ thống chỉ số đo lường đa tầng

Tầng	Chỉ số	Tập dùng để đo
Chất lượng dự báo	ROC-AUC, PR-AUC, log loss, Brier; R^2 và MAE trên thang log của $\hat{S}$	valid; locked
Hiệu chỉnh và bất định	ECE 15 bin cùng khối lượng, reliability diagram; độ phủ và độ rộng khoảng conformal 90 %	valid, calib (CV); locked; OOT khi nhãn trưởng thành
Giải thích	PFI, SHAP (thang log-odds), Spearman ổn định bootstrap, faithfulness xóa top-k	valid
Nhân quả	Sai lệch ATE so với đáp án, độ phủ CI, placebo; Spearman($\hat{\tau}$, τ thật); Qini/AUUC với CI bootstrap cụm	train ngoài fold; valid+calib; nhánh ngẫu nhiên của locked
Tổn thất quyết định	Regret chuẩn hóa A (hiện thực) và B (kỳ vọng) so với đáp án; so sánh theo cặp giữa phương pháp	calib (lô 100); valid+calib toàn t0; locked
Giá trị thực hiện	Lợi nhuận gia tăng hiện thực cộng dồn; ước lượng DR/AIPW trên nhóm đối chứng với CI bootstrap cụm theo khách	valid+calib; locked; OOT
Vận hành	Độ trễ P50/P95/P99 từng khâu; vi phạm ràng buộc; tải HITL; tỷ lệ bị chặn	mỗi t0
Độ trôi	PSI đặc trưng và điểm số so với train; Action TVD so với kỳ tham chiếu; độ trễ nhãn	OOT, mỗi t0

Bảng 3.4. Cổng phát hành đăng ký trước (configs/config.yaml, đóng băng trước khi mở Locked Test)

Cổng	Tiêu chí	Cách tính đã làm rõ trước khi mở locked (CLAUDE.md §6b)
G1	Mọi kiểm tra hợp đồng dữ liệu đạt	Schema snapshot, hợp đồng logged, khóa logged = snapshot, y_obs dưới a0 = Y(0), entity holdout, embargo, hợp đồng đầu vào Router
G2	ECE của $\hat{\mu}_0$ đã hiệu chỉnh ≤ 0,03 và Brier không tệ hơn điểm thô	Đo trên dòng a0 của toàn bộ locked; Current = Platt khớp ở GĐ2, không hiệu chỉnh lại

Cổng	Tiêu chí	Cách tính đã làm rõ trước khi mở locked (CLAUDE.md §6b)
G3	Hệ số Qini > 0 với CI 95 % > 0 cho ≥ 2 hành động	Nhánh ngẫu nhiên của locked; CausalForestDML đã chốt; bootstrap cụm theo khách 300 lần
G4a	Giá trị chính sách ≥ luật cũ + 10 %	Đọc là (chính sách − luật cũ) ≥ 0,10·|luật cũ| vì luật cũ có thể âm; lợi nhuận gia tăng hiện thực cộng dồn; so sánh chính: MILP qua Router v2.1 vs Luật cũ qua Router v2.1
G4b	Regret chuẩn hóa ≤ 0,35	Regret A (mốc biết trước hiện thực), MILP qua Router v2.1, cộng dồn qua các kỳ locked
G5	0 vi phạm ràng buộc	Trên quyết định gửi thực tế của luồng Current
G6	P95 độ trễ đầu–cuối một t0 ≤ 30 s	Gồm đặc trưng, mã lý do SHAP top-3, chấm điểm, hợp đồng và miền, MILP, router; ≥ 30 lượt/kỳ
G7	Không phân khúc UK / non-UK nào kém luật cũ quá 5 %	Cùng so sánh chính như G4a

Quy trình kiểm chứng gồm bốn bước có thứ tự và có dấu vết. **Bước 1 – diễn tập:** chạy `--dry-run` với calib đóng vai locked để kiểm tra mã chấm gate (trong lần đầu, G1 từng trượt vì một lỗi mã kiểm tra propensity, đã sửa trước khi đóng băng). **Bước 2 – đóng băng:** ghi `s8_freeze_manifest.json` với SHA-256 theo byte của `src/`, `configs/`, `models/`, `CLAUDE.md` và 15 file parquet. **Bước 3 – mở Locked Test một lần:** lệnh `--open-locked` ghi file khóa `s8_locked_opened.lock` chứa hash tổng hợp của trạng thái đóng băng và từ chối chạy lại; chấm bảy cổng và báo cáo riêng cho ba quần thể (toàn bộ, khách thường, entity holdout). **Bước 4 – phát lại Out-of-Time:** lệnh `--oot` chỉ chạy khi đã có khóa và `verify_freeze` khớp; phát lại tuần tự năm kỳ với mô hình Current, đo độ trễ từng khâu (perf_counter, 30 lượt/kỳ), PSI từng đặc trưng và điểm số so với train, Brier/ECE chỉ khi nhãn đã trưởng thành (t0 + 30 ≤ ngày phát lại), Action TVD so với kỳ tham chiếu, giá trị thực hiện bằng DR trên nhóm đối chứng. Vòng phản hồi được thiết kế theo mô hình Current – Challenger: Challenger = Current + Platt hiệu chỉnh lại theo kỳ chỉ với nhãn đã trưởng thành, báo cáo song song và không thay thế Current khi chấm gate; Challenger-2 (phụ) huấn luyện lại μ_0 trên dữ liệu trước OOT, chỉ chạy sau khi chấm gate. Kịch bản trôi ($\tau \times 0{,}6$) được sinh trước khi đóng băng để đánh giá guardrail khi khách bớt nhạy ưu đãi. Toàn bộ bộ kiểm thử `pytest` gồm 77 kiểm thử (76 đạt, 1 bỏ qua có chủ đích khi khóa đã tồn tại).

TÓM TẮT CHƯƠNG III

Chương III đã trình bày quy trình triển khai theo chu trình tám giai đoạn cùng Graphic Abstract và đặc tả luồng xử lý của từng giai đoạn. Tác giả thiết kế dữ liệu theo thời gian với snapshot point-in-time, năm tập dữ liệu, vùng embargo 42 ngày và tập

khách hàng giữ riêng. Đồng thời, chương này mô tả hệ thống mô hình dự báo, mô hình nhân quả, bài toán tối ưu MILP, Action Router và phương pháp kiểm định thực chứng với hệ thống chỉ số đa tầng. Điểm quan trọng nhất là các cổng phát hành được đăng ký trước và đóng băng trước khi mở Locked Test. Kết quả thực hiện từng giai đoạn được trình bày trong Chương IV.

IV. KẾT QUẢ VÀ PHÂN TÍCH (RESULTS AND ANALYSIS)

Dựa trên phương pháp đã trình bày ở Chương III, chương này trình bày kết quả thực nghiệm theo đúng thứ tự tám giai đoạn, sau đó là kiểm định ngoài trên bộ dữ liệu Hillstrom. Mọi con số đều được tác giả đọc từ các bảng trong thư mục `outputs/tables/` của kho mã nguồn, tên file nguồn được ghi dưới mỗi bảng. Số liệu tiền tệ tính bằng bảng Anh (GBP, ký hiệu £).

4.1. Kết quả thực nghiệm qua từng giai đoạn

Phần này trình bày lần lượt kết quả của bảy giai đoạn đầu, đi từ chất lượng dữ liệu và dự báo, qua hiệu chỉnh, ước lượng nhân quả, đến tối ưu hóa phân bổ nguồn lực và định tuyến hành động. Cuối phần là kết quả kiểm định ngoài trên bộ dữ liệu thử nghiệm ngẫu nhiên thật Hillstrom.

4.1.1. Giai đoạn 1: dữ liệu point-in-time, chống rò rỉ và lớp can thiệp

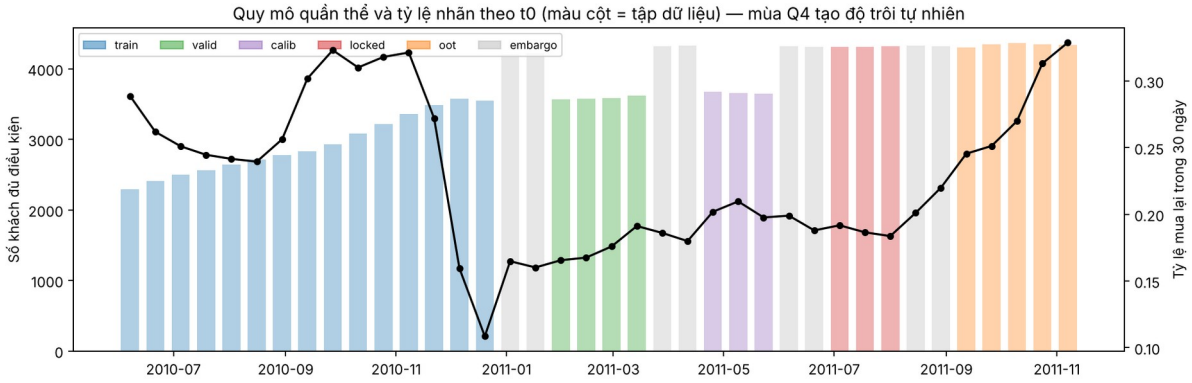
Bước đầu tiên của hệ thống là bảo đảm dữ liệu không "nhìn thấy tương lai". Dưới đây là kết quả sáu kiểm thử rò rỉ mà tác giả cài đặt ở giai đoạn 1. Qua Bảng 4.1, ta thấy toàn bộ sáu kiểm thử đều đạt. Đáng chú ý là T2: khi nhân giá trị và số lượng của mọi giao dịch sau cutoff lên 10 lần, không một đặc trưng nào thay đổi, chứng tỏ snapshot không nhìn thấy tương lai. Khoảng cách embargo đo được là đúng 42 ngày ở cả bốn ranh giới, với ngày kết thúc cửa sổ nhãn của tập trước luôn sớm hơn t0 đầu tiên của tập sau. Entity holdout cô lập 878 khách hàng. Điều này cho thấy bộ dữ liệu đủ tin cậy để làm nền cho các giai đoạn sau.

Bảng 4.1. Kết quả kiểm thử rò rỉ ở giai đoạn 1

Kiểm thử	Nội dung	Kết quả
T1 point-in-time rebuild	Dựng lại đặc trưng từ dữ liệu cắt tại cutoff, 4 t0 (3 046–4 322 khách/t0)	ĐẠT 4/4
T2 future perturbation	Nhân giá trị/số lượng sau cutoff ×10, đặc trưng không đổi	ĐẠT 4/4
T3 label recompute	Tính lại nhãn độc lập (base rate 0,160–0,242)	ĐẠT 4/4
T4 embargo ≥ H	train → valid, valid → calib, calib → locked, locked → oot đều 42 ngày	ĐẠT
T5 entity holdout	878 khách giữ riêng, 0 dòng lọt vào train/valid/calib	ĐẠT
T6 exclusion list	Nhãn, khóa, cột kiểm toán không nằm trong đặc trưng	ĐẠT

Nguồn: Tác giả tính toán từ `s1_leakage_tests.csv`, `s1_embargo_check.csv`. *Kiểm toán độc lập (13/11/2026) tính lại T1 trên 3 kỳ locked và trên cả 38 kỳ: 0 kỳ lệch.*

Qua Hình 4.1, có thể nhận thấy tỷ lệ mua lại nền theo từng t0 dao động mạnh theo mùa: cao ở mùa thu – đông (quý IV 2010 và 2011) và thấp ở đầu năm. Đây là đặc điểm dữ liệu quan trọng nhất đối với các giai đoạn sau: tập valid (tháng 1–3) có tỷ lệ 0,175, tập calib (tháng 4–5) có 0,203, còn tập oot (tháng 9–11) lên tới 0,282. Điều này là do hàng quà tặng có nhu cầu tăng mạnh trước Giáng sinh. Vì vậy, một bộ hiệu chỉnh khớp trên calib sẽ khó hợp với cả valid lẫn oot.



Hình 4.1. Tỷ lệ mua lại nền (a0) theo từng kỳ t0 và màu theo tập dữ liệu

Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s1_base_rate_by_t0.png`)

Lớp can thiệp bán tổng hợp cho ATE thật trên biến mua lại ở train là 0,0385 (a1), 0,0795 (a2) và 0,0526 (a3), ổn định qua các tập (0,038–0,044 cho a1). Tuy nhiên lợi nhuận gia tăng thật trung bình trên mỗi dòng là **âm** với cả ba hành động (−£3,5, −£9,3 và −£7,4 ở train), vì chiết khấu được trả cho cả nhóm sure things. Theo phân loại bốn nhóm, với a2 chỉ 8,6 % khách là persuadables, 23,3 % là sure things, 67,7 % là lost causes và 0,3 % là sleeping dogs. Như vậy, nếu gửi voucher đại trà thì doanh nghiệp chắc chắn lỗ. Giá trị của hệ thống nằm hoàn toàn ở khả năng nhắm đúng nhóm persuadables. Kiểm tra nhiễu (confounding) xác nhận chính sách lịch sử gây chệch đúng như thiết kế: chênh lệch thô trên toàn bộ dữ liệu ghi log lệch −0,018 với a1 và +0,028 với a3 so với ATE thật, trong khi chênh lệch trên nhánh ngẫu nhiên gần với sự thật hơn.

4.1.2. Giai đoạn 2: dự báo nền, hiệu chỉnh xác suất và định lượng bất định

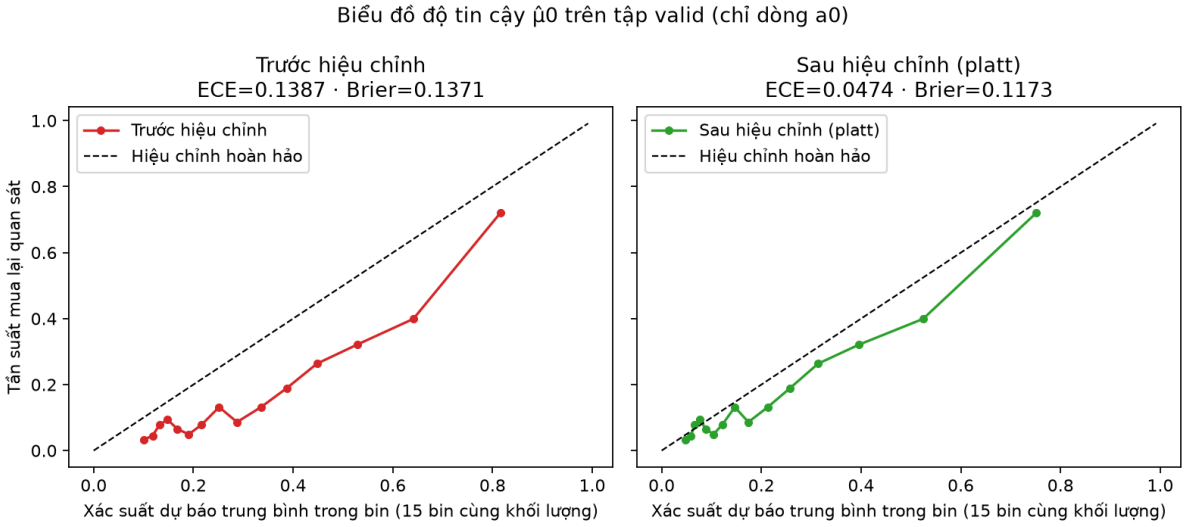
Qua Bảng 4.2, ta thấy LightGBM (4 lá, 400 cây) được chọn trên valid với ROC-AUC 0,786 và PR-AUC 0,532, hơn hồi quy logistic (0,776 và 0,509) chủ yếu ở log loss (0,439 so với 0,510). Điểm thô của LightGBM bị lệch hiệu chỉnh nặng (ECE 0,139, Brier 0,137): mô hình học trên train với tỷ lệ nền 0,2575 nên dự báo cao hơn hẳn thực tế của valid (0,1751). Trong CV bên trong calib, Platt cho log loss 0,422 so với 0,426 của Isotonic nên được chọn. Sau Platt, trên valid log loss giảm còn 0,385, Brier còn 0,117 và ECE còn 0,047 (Bảng 4.2, Hình 4.2). Điều này cho thấy hiệu chỉnh không làm thay đổi khả năng xếp hạng (ROC-AUC giữ nguyên 0,786) nhưng kéo xác suất dự báo về sát thực tế hơn nhiều.

Bảng 4.2. Chỉ số dự báo của $\hat{\mu}_0$ trên valid (n = 3 650 dòng a0) trước và sau hiệu chỉnh

Phân khúc / phương pháp	ROC-AUC	PR-AUC	Log loss	Brier	ECE [CI 95 %]
Toàn bộ – chưa hiệu chỉnh	0,786	0,532	0,439	0,137	0,139 [0,126; 0,151]
Toàn bộ – Platt	0,786	0,532	0,385	0,117	0,047 [0,039; 0,060]
Toàn bộ – Isotonic	0,785	0,507	0,387	0,119	0,045 [0,038; 0,060]
UK – Platt	0,786	0,533	0,385	0,117	0,050 [0,041; 0,063]
non-UK – Platt (n =	0,788	0,534	0,382	0,117	0,070 [0,062; 0,125]

Phân khúc / phương pháp	ROC-AUC	PR-AUC	Log loss	Brier	ECE [CI 95 %]
258)					
Khách mua một lần – Platt	0,582	0,076	0,225	0,056	0,032 [0,028; 0,049]
Khách mua lặp – Platt	0,773	0,567	0,453	0,144	0,059 [0,046; 0,075]

Nguồn: Tác giả tính toán từ `s2_metrics_valid.csv`, `s2_model_selection_valid.csv`. CI bootstrap 300 lần.

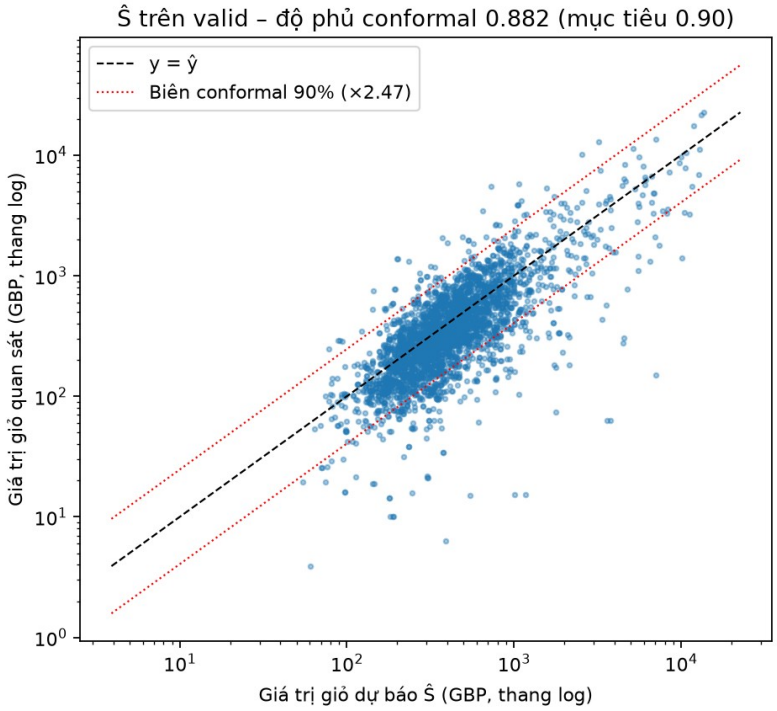


Hình 4.2. Biểu đồ độ tin cậy của $\hat{\mu}_0$ trên valid trước và sau hiệu chỉnh Platt

Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s2_reliability_valid.png`)

Tuy nhiên, tiêu chí chấp nhận ECE ≤ 0,03 trên valid **không đạt** (0,047), trong khi ECE ngoài fold bên trong calib là 0,028. Điều này là do trôi tỷ lệ nền theo mùa đã nêu ở mục 4.1.1: valid rơi vào tháng 1–3, nằm ngoài khoảng tháng mà train bao phủ (6–12), nên các đặc trưng lịch bị ngoại suy. Thí nghiệm cắt bỏ (ablation) đặc trưng lịch không cải thiện được tình hình. Theo luật cứng của dự án, ngưỡng G2 không được sửa; thay vào đó hệ thống ghi nhận rủi ro này vào mục đăng ký trước 6b và chuyển việc hiệu chỉnh lại theo kỳ cho cơ chế Challenger ở giai đoạn 8. Như sẽ thấy ở mục 4.3.2, locked (tháng 7–8) nằm trong khoảng tháng của train nên ECE trên locked chỉ còn 0,020.

Với giá trị giỏ $\hat{S}$, LightGBM trên thang log đạt R^2 0,50 và MAE 0,457 (thang log) trên valid. Khoảng split-conformal 90 % khớp trên calib có phân vị q = 0,903 trên thang log, tương đương biên nhân ×2,47 mỗi phía, và đạt độ phủ 0,882 trên valid (mục tiêu 0,90; trong khoảng chấp nhận 0,85–0,95), đồng đều giữa UK (0,882) và non-UK (0,880) (Hình 4.3). Biên rộng phản ánh phương sai lớn của giỏ hàng khách sỉ và chính là lý do Router dùng độ rộng khoảng conformal làm một điều kiện chuyển HITL. Giá trị kỳ vọng $\hat{S}$ lệch +13 % trên valid vì cùng nguyên nhân trôi mùa.



Hình 4.3. Giá trị giỏ dự báo Ŝ so với quan sát trên valid và biên conformal 90 %

Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s2_basket_conformal.png`)

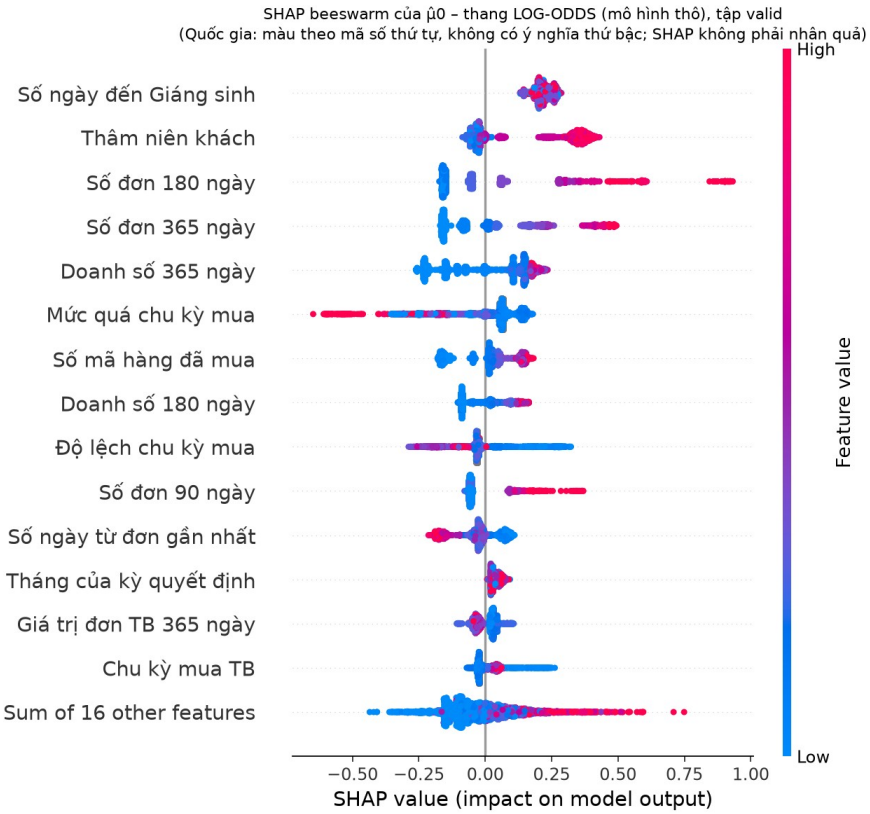
4.1.3. Giai đoạn 3: giải thích và độ tin cậy của mô hình

Qua Bảng 4.3, ta thấy nhóm RFM chiếm gần như toàn bộ sức mạnh dự báo (mức tăng log loss 0,141 ± 0,006 khi hoán vị), nhóm nhịp mua đóng góp nhỏ (0,007), còn các nhóm lịch, quốc gia và hủy đơn xấp xỉ 0 hoặc âm nhẹ (Bảng 4.3). Về từng đặc trưng, số đơn 180 và 365 ngày, doanh số 365 ngày và thâm niên là những biến quan trọng nhất. SHAP (thang log-odds) cho bức tranh bổ sung: `days_to_xmas` đứng đầu về |SHAP| trung bình (0,222) dù PFI của nhóm lịch bằng 0. Hai kết quả này không mâu thuẫn: PFI hoán vị *trong* tập valid, nơi `days_to_xmas` gần như không đổi giữa bốn kỳ nên hoán vị không làm mất thông tin; còn SHAP đo mức dịch chuyển *mức nền* của dự báo so với train, và với valid rơi xa Giáng sinh, biến lịch kéo xác suất xuống cho mọi khách. Nói cách khác, đặc trưng lịch mang thông tin về mức (level) chứ không phải về thứ hạng, và đây chính là kênh làm trôi hiệu chỉnh theo mùa.

Bảng 4.3. PFI theo nhóm đặc trưng và 8 đặc trưng SHAP quan trọng nhất (valid)

Nhóm (PFI, tăng log loss ± sd)	Giá trị	Đặc trưng SHAP hàng đầu (|SHAP| log-odds TB)
RFM	0,141 ± 0,006	days_to_xmas 0,222 · tenure_days 0,184 · n_orders_180 0,184 · n_orders_365 0,156
Nhịp mua	0,007 ± 0,001	value_365 0,148 · overdue_ratio 0,109 · distinct_products_365 0,091 · value_180 0,080
Lịch	0,000	—
Quốc gia	≈ 0 (−0,00005)	—
Hủy đơn	−0,002 ± 0,0003	—

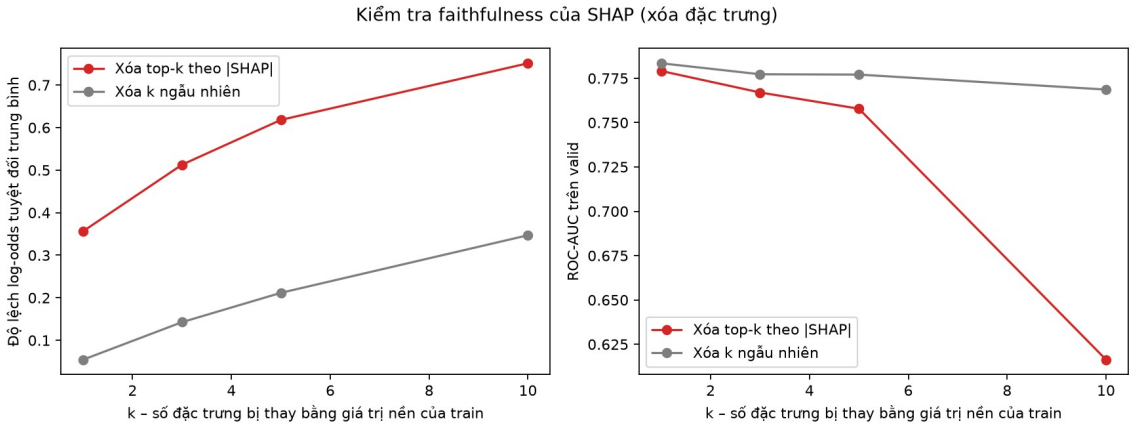
Nguồn: Tác giả tính toán từ `s3_pfi_group.csv`, `s3_shap_importance.csv`.



Hình 4.4. SHAP beeswarm của $\hat{\mu}_0$ trên valid (thang log-odds, nhãn nghiệp vụ tiếng Việt)

Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s3_shap_beeswarm.png`)

Độ ổn định của giải thích được kiểm tra bằng cách huấn luyện lại mô hình trên 5 mẫu bootstrap: tương quan hạng Spearman của tầm quan trọng SHAP giữa mô hình gốc và từng mô hình bootstrap nằm trong khoảng 0,86–0,94, giữa các cặp bootstrap là 0,80–0,94. Kiểm tra faithfulness (Hình 4.5) cho thấy khi xóa lần lượt k đặc trưng SHAP quan trọng nhất, ROC-AUC trên valid giảm từ 0,786 xuống 0,616 ở k = 10, trong khi xóa k đặc trưng ngẫu nhiên chỉ giảm xuống 0,769; độ lệch logit tuyệt đối trung bình tương ứng là 0,75 so với 0,35. Điều này cho thấy giải thích do SHAP cung cấp phản ánh đúng những gì mô hình thực sự dựa vào. Mỗi khách hàng được gán ba mã lý do từ các giá trị SHAP lớn nhất (ví dụ `N_ORDERS_180|DOWN`, `VALUE_365|UP`), được Router ghi vào bản ghi quyết định để bộ phận CSKH đọc. Cần nhấn mạnh rằng PFI và SHAP mô tả mô hình dự báo $\hat{\mu}_0$, không phải quan hệ nhân quả; tác động của can thiệp được ước lượng riêng ở giai đoạn 4.

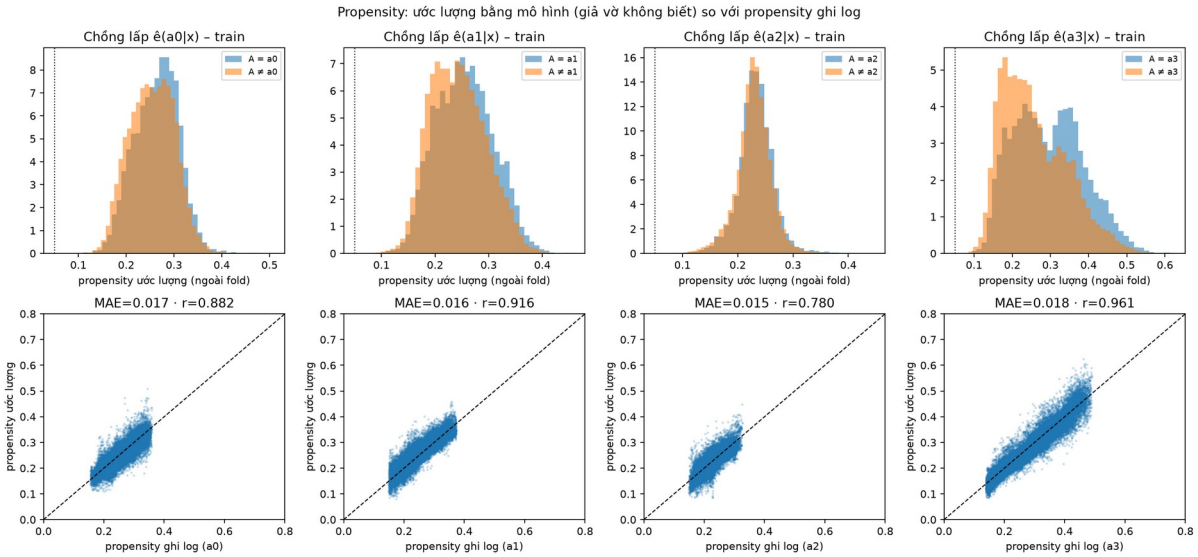


Hình 4.5. Kiểm tra faithfulness: xóa top-k đặc trưng theo SHAP so với xóa ngẫu nhiên

Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s3_faithfulness.png`)

4.1.4. Giai đoạn 4: nhân quả, CATE và uplift

Propensity và chồng lấp. Propensity ước lượng bằng mô hình (giả định chưa biết chính sách lịch sử) tương quan 0,78–0,96 với propensity ghi log, MAE 0,015–0,018, giá trị nhỏ nhất ≥ 0,07 và không dòng nào dưới 0,05 (Hình 4.6). Điều kiện chồng lấp vì thế được thỏa và trọng số IPW không bị nổ.



Hình 4.6. Chồng lấp propensity theo hành động (trên) và propensity ước lượng so với ghi log (dưới), train ngoài fold

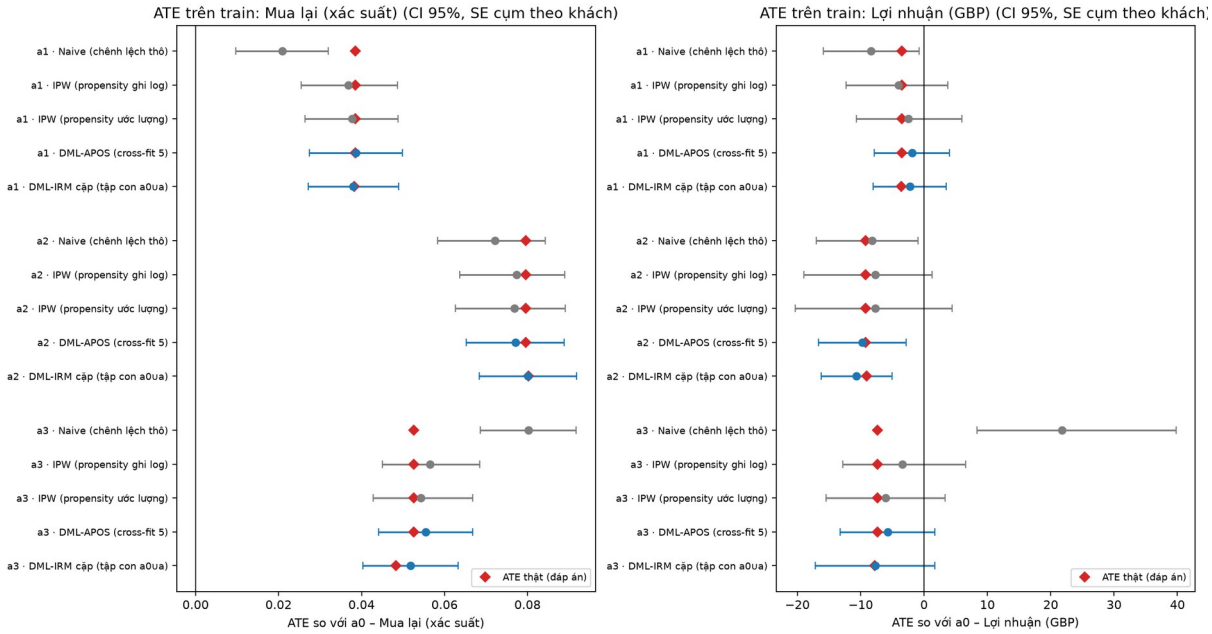
Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s4_propensity_overlap.png`)

ATE. Bảng 4.4 và Hình 4.7 so sánh các bộ ước lượng với đáp án. Qua bảng, ta thấy ước lượng naive chệch đúng như dự đoán: a1 bị đánh giá thấp (0,021 so với 0,039 thật) và a3 bị đánh giá cao (0,080 so với 0,053) Điều này là do luật RFM cũ ưu tiên gọi điện cho khách giá trị cao vốn hay mua lại. Ngược lại, IPW và DML đều đưa ước lượng về sát sự thật; DML-APOS cho a1 0,0386 [0,027; 0,050], a2 0,0771 [0,065; 0,089], a3 0,0554 [0,044; 0,067], CI phủ ATE thật ở cả 6/6 phép thử (APOS và IRM), và kiểm định placebo (xáo trộn ngẫu nhiên hành động) cho 6/6 CI chứa 0. Ngoài mẫu trên valid+calib, AIPW với nuisance học từ train vẫn phủ sự thật cho cả ba hành động.

Bảng 4.4. ATE trên biến mua lại (train, n = 43 921) theo các bộ ước lượng so với ATE thật

Phương pháp	a1 (thật 0,0385)	a2 (thật 0,0795)	a3 (thật 0,0526)
Naive (chênh lệch thô)	0,0209 ✗	0,0721 √	0,0802 ✗
IPW (propensity ghi log)	0,0368 √	0,0773 √	0,0565 √
IPW (propensity ước lượng)	0,0376 √	0,0768 √	0,0543 √
DML-APOS (cross-fit 5)	0,0386 [0,027; 0,050] √	0,0771 [0,065; 0,089] √	0,0554 [0,044; 0,067] √
DML-IRM từng cặp	0,0380 √	0,0800 √	0,0518 √
Placebo DML (kỳ vọng 0)	−0,0096 [−0,021; 0,002]	0,0011 [−0,011; 0,013]	−0,0048 [−0,016; 0,007]

Nguồn: Tác giả tính toán từ `s4_ate_vs_truth.csv`, `s4_placebo.csv`. ✓ = CI 95 % phủ ATE thật; ✗ = không phủ.



Hình 4.7. Forest plot ATE trên mua lại (trái) và lợi nhuận (phải), train, CI 95 % bootstrap cụm theo khách

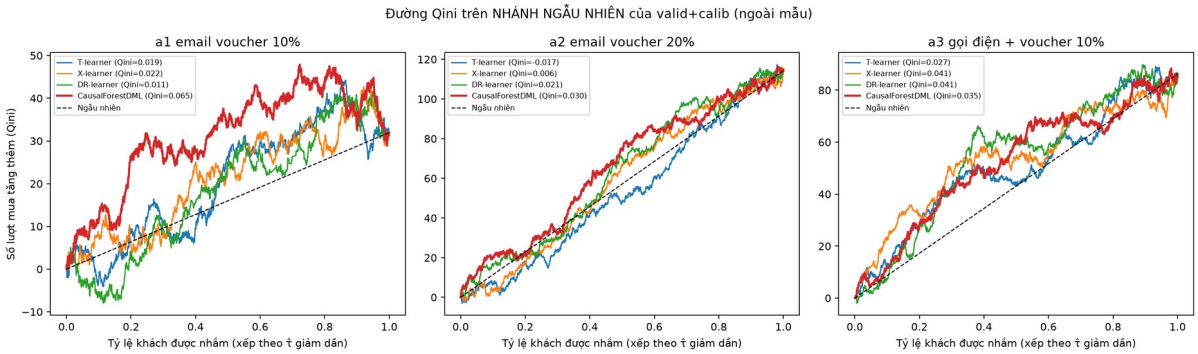
Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s4_ate_forest.png`)

CATE. Trong bốn learner, CausalForestDML cho tương quan hạng cao nhất với τ thật trên valid+calib: 0,44 (a1), 0,56 (a2) và 0,63 (a3), so với 0,34/0,33/0,44 của T-learner (Bảng 4.5). Vì τ thật không có trong thực tế, tiêu chí chọn learner là Qini trên nhánh ngẫu nhiên của valid, và CausalForestDML cũng thắng theo tiêu chí này. Trên valid+calib, hệ số Qini của CausalForestDML là 0,065 [0,008; 0,116] cho a1, 0,030 [−0,026; 0,089] cho a2 và 0,035 [−0,019; 0,096] cho a3 (Hình 4.8): cả ba đều dương về điểm, nhưng chỉ một CI không chứa 0. Tiêu chí chấp nhận nội bộ "Qini có CI > 0 cho ≥ 2 hành động" vì thế **không đạt** (1/3) ngay từ giai đoạn 4, và riêng trên calib (không dùng để chọn learner) Qini chỉ là 0,068 / 0,004 / 0,021.

Bảng 4.5. Chất lượng CATE của các learner trên valid+calib

Learner	Spearman a1	Spearman a2	Spearman a3	Qini CausalForestDML [CI 95 %], nhánh ngẫu nhiên
T-learner	0,336	0,330	0,440	a1: 0,065 [0,008; 0,116] (n = 2 541)
X-learner	0,306	0,379	0,485	a2: 0,030 [−0,026; 0,089] (n = 2 545)
DR-learner	0,285	0,459	0,559	a3: 0,035 [−0,019; 0,096] (n = 2 545)
CausalForestDML (chọn)	0,437	0,556	0,626	Riêng calib: 0,068 / 0,004 / 0,021 (không CI)

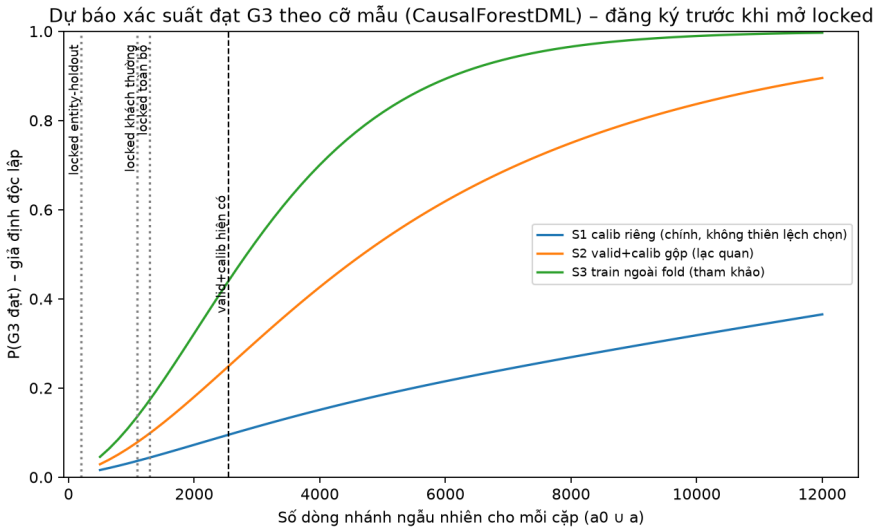
Nguồn: Tác giả tính toán từ `s4_cate_vs_truth.csv`, `s4_qini.csv`. Spearman giữa $\tau\hat{}$ và τ thật chỉ dùng để đánh giá, không dùng để chọn learner.



Hình 4.8. Đường Qini trên nhánh ngẫu nhiên valid+calib theo learner và theo hành động

Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s4_qini_curves.png`)

Dự báo power cho cổng G3 (giai đoạn 4b, đăng ký trước). Locked chỉ có khoảng 1 300 dòng ngẫu nhiên cho mỗi cặp (a0 ∪ a), bằng một nửa valid+calib, nên sai số chuẩn của Qini lớn hơn khoảng 1,4 lần. Lấy Qini trên calib làm hiệu ứng thật, xác suất G3 đạt trên toàn bộ locked được dự báo chỉ **4–7 %** (kịch bản chính), 10–13 % nếu lấy valid+calib gộp và 17–21 % nếu lấy train ngoài fold (Hình 4.9). Để đạt power 80 %, a1 cần cỡ mẫu gấp khoảng 2,5 lần locked và a2, a3 cần hơn 10 lần. Dự báo đăng ký trước vì vậy là: G3 nhiều khả năng không đạt, do cỡ mẫu chứ không phải do mô hình sai hướng. Kết quả thực tế ở mục 4.3.2 sẽ được đối chiếu với dự báo này.



Hình 4.9. Dự báo power của cổng G3 theo bội số cỡ mẫu nhánh ngẫu nhiên so với locked

Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s4b_power_g3.png`)

4.1.5. Giai đoạn 5: Predict-Then-Optimize, SPO+ và quan hệ sai số – regret

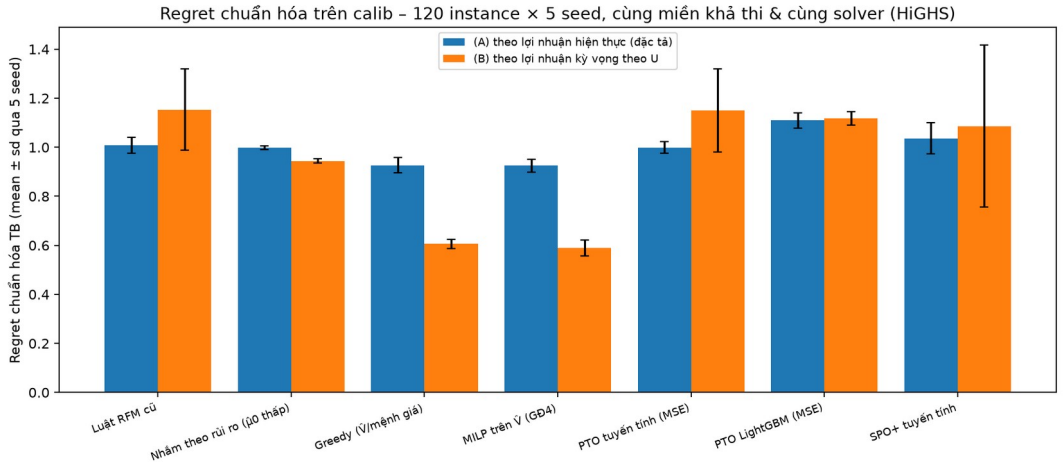
Dưới đây là kết quả so sánh các phương pháp ra quyết định. Bảng 4.6 và Hình 4.10 tổng hợp regret chuẩn hóa của bảy phương pháp trên 120 instance (lô 100 khách) × 5 seed trong calib, cùng miền khả thi và cùng bộ giải HiGHS. Ba điểm nổi bật. Thứ nhất, **mốc "biết trước hiện thực" là không thể đạt**: ngay chính sách biết kỳ vọng thật của cơ chế sinh dữ liệu cũng có regret A là 0,742, vì phần lớn lợi nhuận hiện thực phụ thuộc vào kết quả ngẫu nhiên của từng khách (giỏ hàng, mua hay không). Regret B (so với kỳ vọng) mới là thước đo phản ánh chất lượng mô hình. Thứ hai, MILP trên $\hat{V}$ của giai đoạn 4 và Greedy là hai phương pháp tốt nhất (regret B 0,588 và 0,606), vượt xa luật RFM cũ (1,154, tức là tệ hơn không làm gì) và nhắm theo rủi ro (0,944). Thứ ba, các phương pháp *học* vector chi phí từ pseudo-outcome AIPW, gồm PTO tuyến tính, PTO LightGBM và SPO+, đều có regret B trên 1, tức không tốt hơn không làm gì. Nhìn chung, có thể thấy cách xây dựng $\hat{V}$ từ các thành phần đã ước lượng ổn định hiệu quả hơn so với việc học trực tiếp từ nhãn lợi nhuận.

Bảng 4.6. Regret chuẩn hóa trung bình trên calib (120 instance × 5 seed, lô 100 khách)

Phương pháp	Regret A (hiện thực)	Regret B (kỳ vọng)	Giá trị hiện thực TB (£/lô)	Giá trị kỳ vọng TB (£/lô)
Luật RFM cũ	1,008	1,154	40,3	0,3
Nhắm theo rủi ro ($\hat{\mu}_0$ thấp)	0,998	0,944	6,2	10,4
Greedy ($\hat{V}$/mệnh giá)	0,926	0,606	117,7	93,9
MILP trên $\hat{V}$ (GĐ4)	0,925	0,588	122,7	101,7
PTO tuyến tính (MSE)	0,999	1,151	48,0	−2,5
PTO LightGBM (MSE)	1,110	1,119	37,6	12,6
SPO+ tuyến tính	1,036	1,087	4,5	−4,8
Đáp án (kỳ vọng theo cơ chế)	0,742	0,000	225,1	199,5

Phương pháp	Regret A (hiện thực)	Regret B (kỳ vọng)	Giá trị hiện thực TB (£/lô)	Giá trị kỳ vọng TB (£/lô)
Đáp án (biết trước hiện thực)	0,000	0,665	586,8	64,9

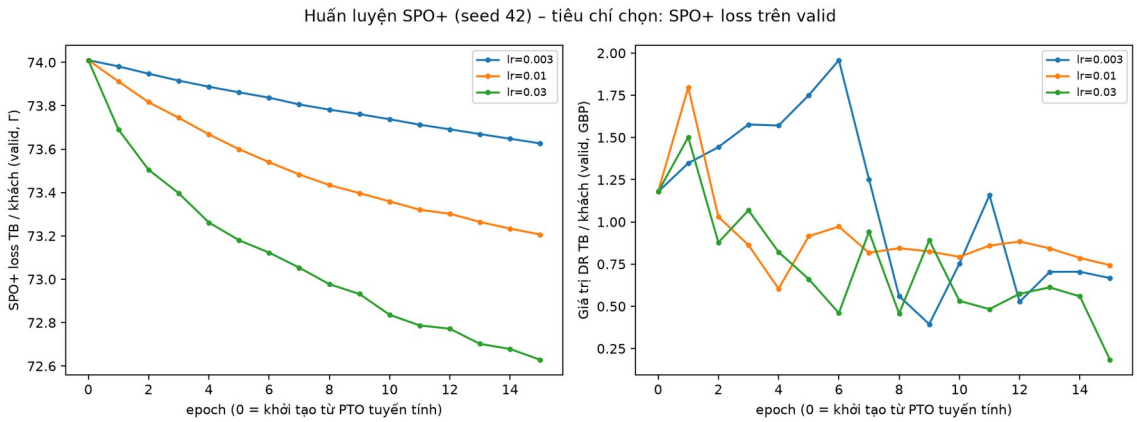
Nguồn: Tác giả tính toán từ `s5_regret_summary.csv` (lưới gốc). Lưới mở rộng theo quy tắc đăng ký trước: PTO tuyến tính 0,969/0,866, SPO+ 1,074/1,255 (`s5_regret_summary_mo_rong.csv`).



Hình 4.10. Regret chuẩn hóa A và B theo phương pháp (trung bình ± sd qua 5 seed)

Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s5_regret_by_method.png`)

SPO+ không thắng PTO. So sánh theo cặp trên cùng instance, SPO+ tuyến tính có regret A cao hơn PTO tuyến tính 0,037 (sd 0,066 qua seed), tốt hơn ở 42 % instance và chỉ thắng ở 1/5 seed; với lưới mở rộng khoảng cách còn lớn hơn (+0,105, thắng 19 % instance, 0/5 seed). Nguyên nhân chính không nằm ở cài đặt: kiểm chứng trên instance 6 khách (418 nghiệm khả thi trong 4 096) cho sai lệch tối đa $2{,}8 \times 10^{-14}$ giữa hàm mất mát tự cài và bộ giải, SPO+ ≥ SPO ở 100 % trường hợp, subgradient khớp sai phân hữu hạn và đi ngược subgradient luôn làm giảm loss. Nguyên nhân nằm ở **nhãn**: vector chi phí "thật" dùng để huấn luyện là pseudo-outcome AIPW của lợi nhuận gia tăng *ở cấp từng khách*, có phương sai rất lớn (giá trị DR trung bình mỗi lô dao động hàng trăm bảng), nên cả PTO lẫn SPO+ đều học từ tín hiệu nhiễu. $\hat{V}$ của giai đoạn 4 tốt hơn vì nó được *cấu trúc* từ ba thành phần đã được ước lượng ổn định ($\hat{\mu}_0$, $\hat{S}$, $\hat{\tau}$) thay vì hồi quy trực tiếp lên nhãn nhiễu. Đường SPO+ loss trên valid giảm đều theo epoch (Hình 4.11), cho thấy thuật toán hội tụ nhưng tới một nghiệm không tốt hơn.



Hình 4.11. Huấn luyện SPO+ (seed 42): SPO+ loss trên valid và giá trị DR theo epoch với ba learning rate

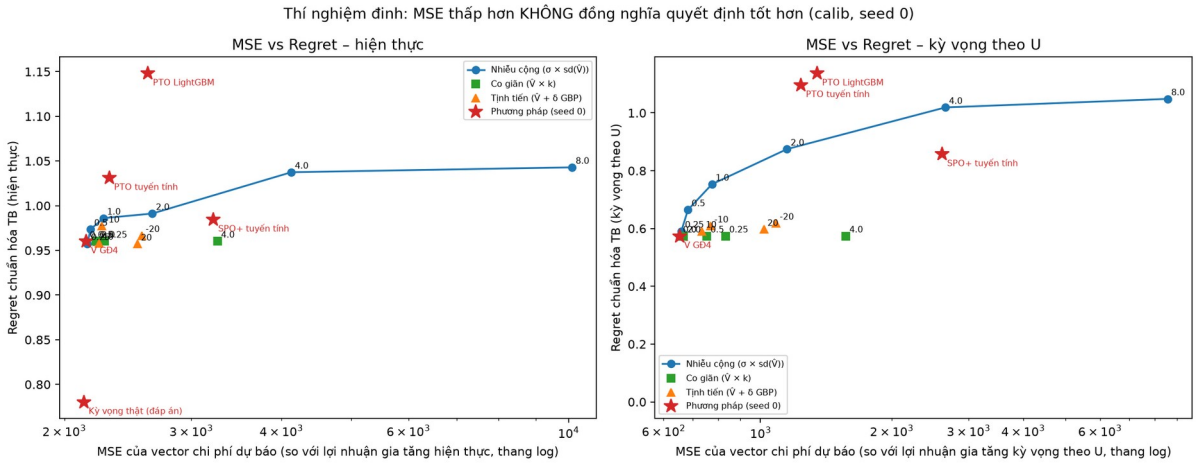
Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s5_spo_training.png`)

Sai số dự báo và regret là phi tuyến. Thí nghiệm bơm nhiễu vào $\hat{V}$ (Hình 4.12, Bảng 4.7) cho thấy khi nhiễu cộng tăng từ 0 đến 8 lần độ lệch chuẩn của $\hat{V}$, MSE tăng 4,7 lần (2 145 → 10 114) nhưng regret A chỉ nhích từ 0,960 lên khoảng 1,04; regret B tăng từ 0,574 lên 1,05 nhưng theo đường cong lõm, bão hòa khi nhiễu lớn. Ngược lại, **nhân $\hat{V}$ với một hằng số** $k \in \{0{,}25; 0{,}5; 2; 4\}$ làm MSE thay đổi mạnh (667 → 1 569 trên thang kỳ vọng) nhưng regret *không đổi* (0,960 / 0,574), vì bộ giải chỉ cần đúng thứ hạng và dấu. Tịnh tiến $\hat{V}$ một hằng số (−£20) cũng chỉ thay đổi regret nhẹ. Đây là bằng chứng thực nghiệm trực tiếp cho luận điểm của Elmachtoub và Grigas (2022) rằng tối ưu MSE không phải mục tiêu đúng của tầng quyết định, đồng thời giải thích vì sao PTO LightGBM có MSE tốt hơn PTO tuyến tính nhưng regret lại xấu hơn.

Bảng 4.7. Thí nghiệm nhiễu: MSE của vector chi phí và regret chuẩn hóa (calib, seed 0, trung bình theo mức nhiễu)

Biến đổi $\hat{V}$	MSE (hiện thực)	MSE (kỳ vọng)	Regret A	Regret B
Không nhiễu	2 145	652	0,960	0,574
Nhiễu cộng $\sigma = 0{,}5 \cdot \mathrm{sd}(\hat{V})$	2 175	682	0,974	0,665
Nhiễu cộng $\sigma = 1 \cdot \mathrm{sd}(\hat{V})$	2 267	774	0,986	0,753
Nhiễu cộng $\sigma = 2 \cdot \mathrm{sd}(\hat{V})$	2 649	1 150	0,991	0,875
Nhiễu cộng $\sigma = 4 \cdot \mathrm{sd}(\hat{V})$	4 128	2 653	1,037	1,019
Nhiễu cộng $\sigma = 8 \cdot \mathrm{sd}(\hat{V})$	10 114	8 573	1,043	1,049
Co giãn $\hat{V} \times 0{,}25 \ldots \times 4$	2 213 – 3 262	667 – 1 569	0,960	0,574

Nguồn: Tác giả tính toán từ `s5_mse_vs_regret.csv`. Bảng này dùng instance của seed 0 nên regret không nhiễu (0,960) khác giá trị trung bình 5 seed ở Bảng 4.6 (0,925).



Hình 4.12. MSE của vector chi phí so với regret chuẩn hóa hiện thực (trái) và kỳ vọng (phải)

Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s5_mse_vs_regret.png`)

Chẩn đoán bộ ước lượng DR (giai đoạn 5b). Vì bộ ước lượng AIPW được đăng ký trước làm thước đo giá trị chính sách ở giai đoạn 8, giai đoạn 5b kiểm tra nó trên valid với 16 đơn vị (bốn chính sách × bốn cách đo): CI 95 % của AIPW phủ giá trị thật ở 100 % đơn vị cho cả hai mốc A và B, chệch trung bình chỉ −£1,3/dòng, nhưng sai số chuẩn trung bình tới £6,1/dòng, tức là bộ ước lượng không chệch nhưng rất nhiễu. Ước lượng chỉ dựa trên mô hình (DM) có CI hẹp hơn nhiều nhưng chệch và không phủ sự thật với a1 và a3. Kết luận đăng ký trước từ đây là: ở giai đoạn 8, DR chỉ là thước đo giám sát kèm CI, không dùng để chấm gate.

4.1.6. Giai đoạn 6: MILP toàn quy mô, giá bóng, độ nhạy và chi phí tính toán

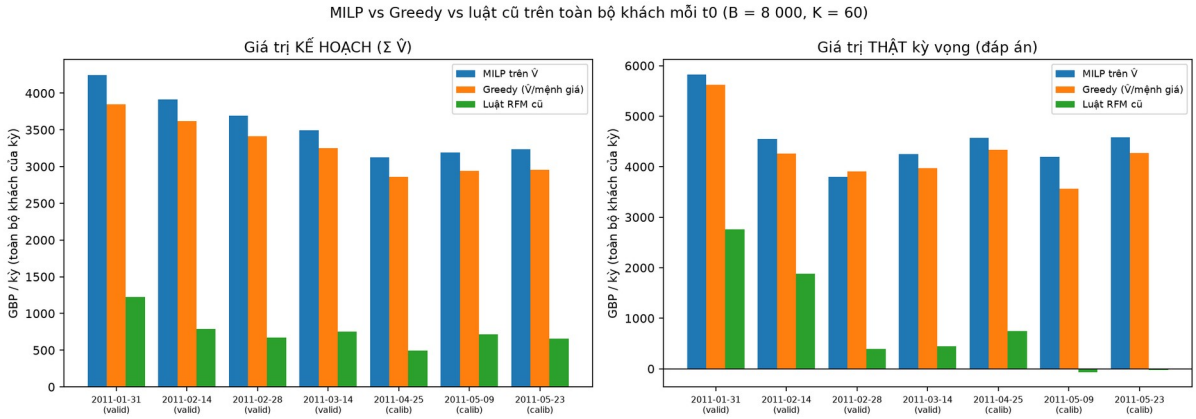
Qua Bảng 4.8, ta thấy trên bảy kỳ valid+calib với toàn bộ 3 564–3 675 khách mỗi kỳ, B = £8 000 và K = 60, MILP trên V̂ đạt giá trị kế hoạch trung bình £3 558/kỳ, giá trị thật hiện thực £4 019/kỳ và kỳ vọng £4 538/kỳ; Greedy đạt £3 271 / £4 046 / £4 276; luật RFM cũ chỉ £759 / **−£379** / £875 (Bảng 4.8, Hình 4.13). Luật cũ thua cả phương án không làm gì về hiện thực. Điều này là do luật cũ gửi nhiều voucher 20 % (53/kỳ) cho khách giá trị cao vốn sẽ mua. Regret B cộng dồn là 0,486 (MILP), 0,516 (Greedy) và 0,901 (luật cũ). MILP thắng Greedy về V̂ ở 7/7 kỳ (đúng như lý thuyết, vì Greedy chỉ là xấp xỉ), về kỳ vọng thật ở 6/7 kỳ, nhưng về hiện thực chỉ 4/7 kỳ; khoảng cách giữa hai phương pháp (regret A 0,832 so với 0,831) nhỏ hơn nhiễu hiện thực. Vì vậy tác giả **không** khẳng định MILP giảm regret hiện thực so với Greedy; lợi thế của MILP nằm ở việc thỏa mãn đồng thời nhiều ràng buộc (độ phủ phân khúc, tỷ lệ a2) mà Greedy phải vá bằng quy tắc thủ công, và ở giá bóng.

Bảng 4.8. MILP, Greedy và luật cũ trên toàn bộ khách của 7 kỳ valid+calib (B = £8 000, K = 60)

Phương pháp	V̂ kế hoạch TB (£/kỳ)	Thật hiện thực TB (£/kỳ)	Thật kỳ vọng TB (£/kỳ)	Regret A cộng dồn	Regret B cộng dồn	Thời gian giải TB (s)
MILP trên V̂	3 558	4 019	4 538	0,832	0,486	0,150

Phương pháp	V̂ kế hoạch TB (£/kỳ)	Thật hiện thực TB (£/kỳ)	Thật kỳ vọng TB (£/kỳ)	Regret A cộng dồn	Regret B cộng dồn	Thời gian giải TB (s)
Greedy (V̂/mệnh giá)	3 271	4 046	4 276	0,831	0,516	0,005
Luật RFM cũ	759	−379	875	1,016	0,901	0,235

Nguồn: Tác giả tính toán từ `s6_main_summary.csv`*. Số voucher trung bình: MILP 250, Greedy 258, luật cũ 213; ngân sách dùng £7 980/kỳ ở cả ba; 0 vi phạm ràng buộc.*



Hình 4.13. MILP, Greedy và luật cũ theo từng kỳ: giá trị kế hoạch (trái) và giá trị thật kỳ vọng (phải)

Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s6_main_comparison.png`*)*

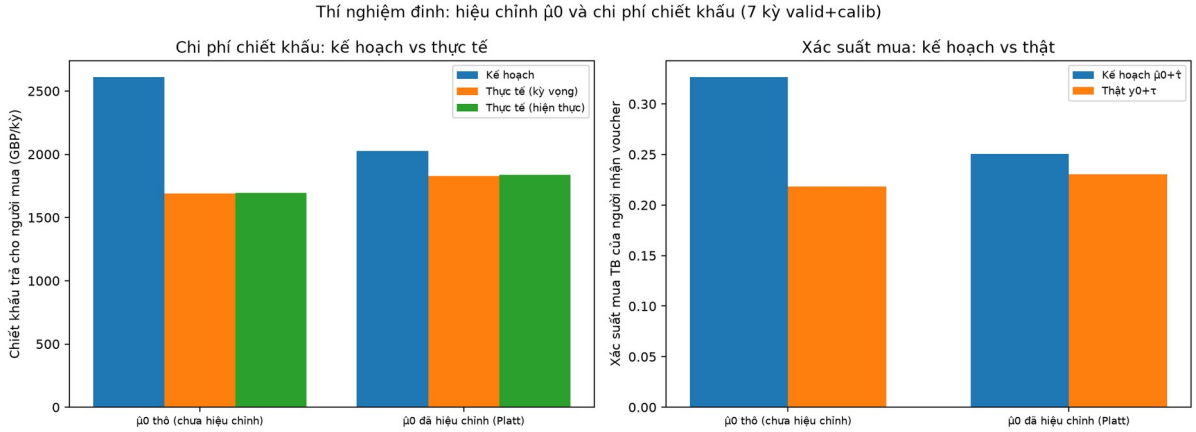
Giá bóng. Nghiệm đối ngẫu của LP nới lỏng cho giá bóng ngân sách £0,12–0,16 lợi nhuận gia tăng kỳ vọng trên mỗi £1 mệnh giá phát hành thêm, và giá bóng cuộc gọi £8,1–9,0 trên mỗi cuộc gọi thêm; ràng buộc trần a2 và độ phủ phân khúc không ràng buộc chặt (giá bóng 0) ở mức B, K hiện tại. Hai con số này là thông tin trực tiếp cho Tài chính: nới ngân sách còn hiệu quả nhưng hiệu quả biên giảm dần, trong khi mỗi cuộc gọi của account manager đáng giá gấp khoảng ba lần chi phí £3 của nó, tức là K = 60 đang quá chặt. Phân tích độ nhạy theo lưới B × K xác nhận: với B = 2 000 bài toán bất khả thi khi bật độ phủ phân khúc, và giá bóng cuộc gọi giảm từ £11–12 (K = 30) về 0 (K = 120).

Hiệu chỉnh xác suất và chi phí chiết khấu (Hình 4.14, Bảng 4.9). Đây là thí nghiệm đinh của giai đoạn. Nếu đưa $\hat{\mu}_0$ thô (chưa hiệu chỉnh) vào hàm giá trị, chi phí chiết khấu kế hoạch là £2 611/kỳ trong khi thực tế kỳ vọng chỉ £1 691 (tỷ lệ thực/kế hoạch 0,65), tỷ lệ mua kế hoạch 0,327 so với thật 0,218; V kế hoạch lệch £1 815 so với giá trị thật kỳ vọng. Với $\hat{\mu}_0$ đã hiệu chỉnh Platt, chi phí kế hoạch £2 027 so với thực £1 828 (0,90), tỷ lệ mua 0,251 so với 0,230, và lệch V còn £981. Kết luận quản trị: hiệu chỉnh xác suất không phải chi tiết kỹ thuật mà là điều kiện để kế hoạch ngân sách bám sát thực tế; sai số hiệu chỉnh 0,1 trên xác suất chuyển thành sai số 35 % trên chi phí.

Bảng 4.9. Chi phí chiết khấu kế hoạch so với thực tế theo $\hat{\mu}_0$ thô và $\hat{\mu}_0$ đã hiệu chỉnh (7 kỳ valid+calib)

$\hat{\mu}_0$ đưa vào hàm giá trị	Chiết khấu kế hoạch (£/kỳ)	Chiết khấu thực kỳ vọng (£/kỳ)	Tỷ lệ thực / kế hoạch	Tỷ lệ mua kế hoạch / thật
Thô (chưa hiệu chỉnh)	2 611	1 691	0,65	0,327 / 0,218
Đã hiệu chỉnh (Platt)	2 027	1 828	0,90	0,251 / 0,230

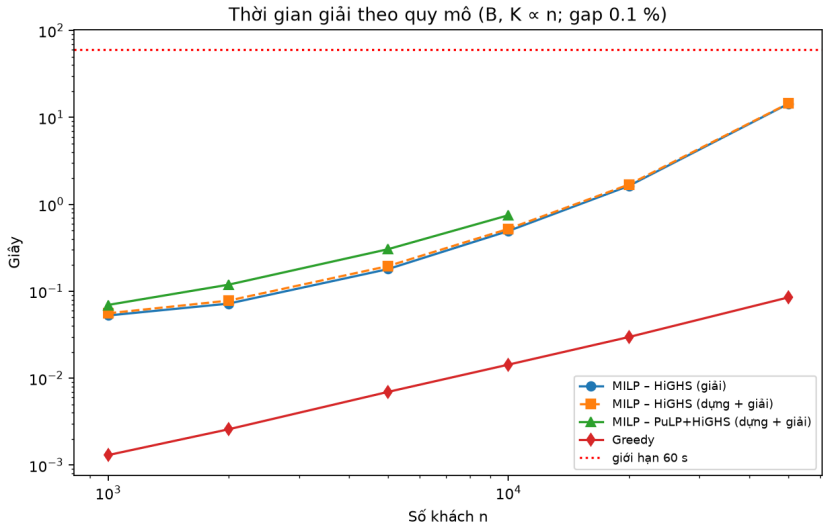
Nguồn: Tác giả tính toán từ `s6_calibration_discount_cost_summary.csv`.



Hình 4.14. Chi phí chiết khấu và xác suất mua: kế hoạch so với thực tế, theo trạng thái hiệu chỉnh của $\hat{\mu}_0$

Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s6_calibration_discount_cost.png`*)*

Chi phí tính toán. Thời gian giải MILP bằng highspy tăng xấp xỉ tuyến tính–siêu tuyến tính theo số khách: 0,05 s (1 000), 0,18 s (5 000), 0,49 s (10 000), 1,6 s (20 000) và 14,3 s (50 000), gap 0 ở mọi quy mô; PuLP + HiGHS chậm hơn khoảng 30 % do thời gian dựng mô hình (Hình 4.15). Greedy nhanh hơn 50–170 lần nhưng kém MILP 3,8–17,1 % trên $\hat{V}$. Ở quy mô một kỳ của doanh nghiệp này (~3,6 nghìn khách), thời gian giải 0,15 s là không đáng kể so với khâu chấm điểm mô hình; ở 50 000 khách, MILP vẫn nằm trong ngưỡng 30 giây của G6 nhưng bắt đầu cần cân nhắc giới hạn thời gian và phương án dự phòng Greedy mà Router đã có.



Hình 4.15. Thời gian giải theo số khách n: MILP (highspy, PuLP) so với Greedy, thang log

Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s6_scaling.png`)

Một phát hiện phụ khi phân tích độ nhạy biên lợi nhuận (`s6_sensitivity_margin.csv`) là hiện tượng *winner's curse*: khi biên thật là 0,30, giả định $\hat{m}$ = 0,20 trong $\hat{V}$ lại cho giá trị thật cao hơn giả định đúng $\hat{m}$ = 0,30, vì $\hat{m}$ thấp làm MILP chọn ít khách hơn và tránh được những khách có $\hat{\tau}$ cao do nhiễu. Hướng xử lý là co $\hat{\tau}$ về trung bình nhóm (shrinkage) hoặc dùng cận dưới CI trong $\hat{V}$; tác giả **không** áp dụng vì phát hiện này đến từ việc đối chiếu với đáp án, mà theo luật cứng đáp án chỉ dùng để đánh giá.

4.1.7. Giai đoạn 7: Action Router, guardrail và Human-in-the-loop

Bảng 4.10 và Hình 4.16 trình bày số phận của các đề xuất MILP khi đi qua Router v2.1 trên 25 327 dòng của bảy kỳ valid+calib. MILP đề xuất 1 788 voucher; không ca nào bị guardrail cứng chặn ở bước này vì các khách opt-out, bị giới hạn tần suất hay có tỷ lệ hủy cao đã được loại khỏi miền khả thi trước khi giải (bảng `s7_guardrail_rates_v21`); 819 ca (45,8 %) chuyển HITL, trong đó 517 vì CI của $\hat{\tau}$ vắt qua 0 và 302 vì khoảng conformal của $\hat{S}$ quá rộng; người duyệt mô phỏng duyệt 408 và từ chối 411; 137 ca rơi vào nhóm đối chứng 10 %; 873 ca gửi tự động; tổng gửi thực tế 1 240. Với luật cũ qua cùng Router, tỷ lệ chuyển HITL lên tới 77 % và 905/1 151 ca bị từ chối. Điều này cho thấy luật cũ đề xuất nhiều ca có tác động không chắc chắn; Router phải bù 288 ca để giữ độ phủ phân khúc.

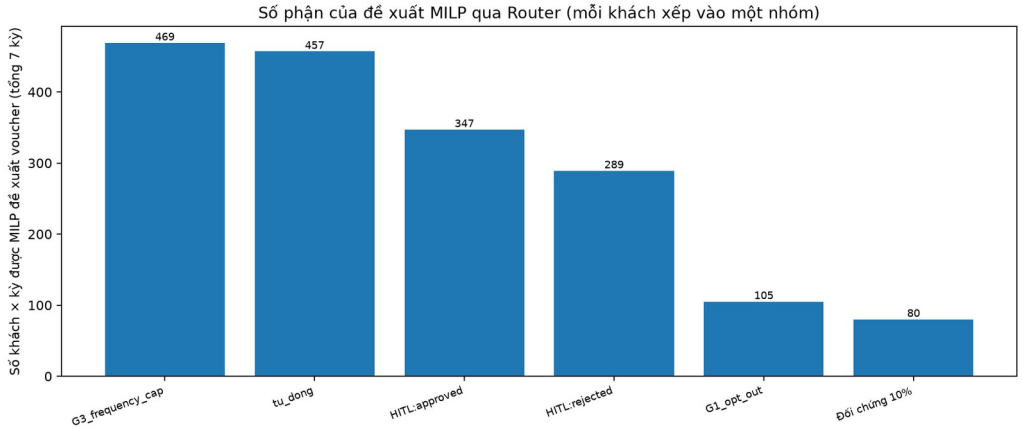
Bảng 4.10. Luồng quyết định qua Router v2.1 trên 7 kỳ valid+calib (25 327 dòng khách × kỳ)

Đvt: lượt (khách × kỳ)

Bước	MILP qua Router	Luật cũ qua Router
Đề xuất voucher (a1/a2/a3)	1 788	1 491
Bị guardrail cứng chặn	0	0
Chuyển HITL (tỷ lệ trên đề xuất)	819 (45,8 %)	1 151 (77,2 %)
HITL duyệt / hạ a1 / từ chối	408 / 0 / 411	231 / 15 / 905

Bước	MILP qua Router	Luật cũ qua Router
Nhóm đối chứng 10 % (ép a0)	137	62
Gửi tự động không qua HITL	873	306
Bù độ phủ phân khúc	0	288
Gửi thực tế	1 240	809

Nguồn: Tác giả tính toán từ `s7_decision_flow_v21.csv`, `s7_hitl_breakdown.csv`. *Bản ghi quyết định: 25 327 dòng, khóa chống lặp duy nhất, chạy lại trả đúng bản ghi cũ (*`s7_idempotency_v21.csv`*).*



Hình 4.16. Số phận của các đề xuất MILP qua Router (mỗi khách xếp vào một nhóm, tổng 7 kỳ)

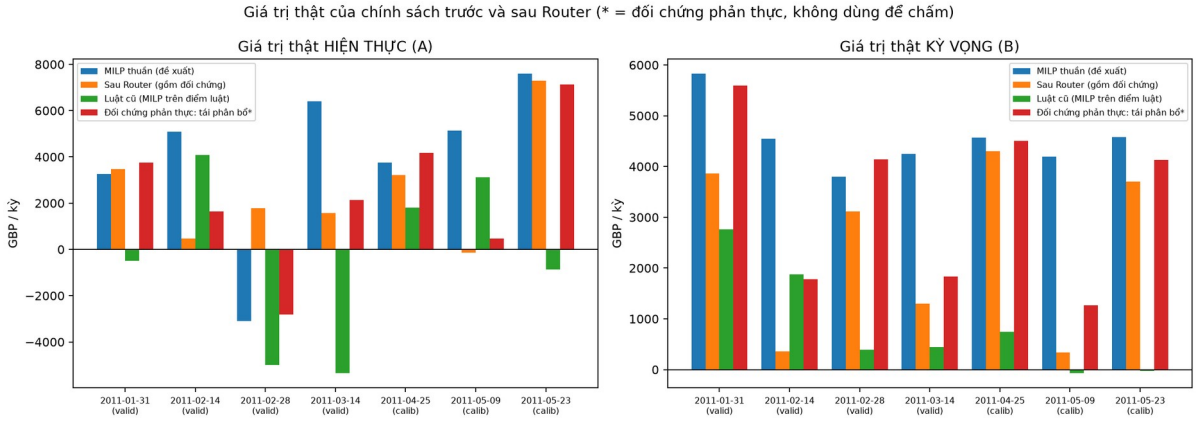
Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s7_decision_flow.png`*)*

Giá trị của HITL và chi phí của guardrail. Đối chiếu với đáp án, các ca HITL được duyệt có giá trị thật hiện thực trung bình +£35,8/ca còn các ca bị từ chối có −£25,7/ca, nghĩa là quy tắc duyệt mô phỏng (yêu cầu $\hat{V}$ vẫn dương ở nửa đường tới cận dưới CI) tách được hai nhóm đúng hướng và tránh được khoản lỗ £6 664 từ 411 ca bị từ chối. Ngược lại, nhóm đối chứng 10 % làm mất £2 161 giá trị hiện thực; đây là *chi phí đo lường* có chủ đích để sau này ước lượng được giá trị thực hiện. Tổng hợp bảy kỳ (Bảng 4.11, Hình 4.17): MILP thuần (không Router) đạt £28 134 hiện thực, luật cũ thuần −£2 650; qua Router, MILP đạt £21 483 và luật cũ đạt £15 039. Router làm giảm giá trị của MILP (vì bớt gửi và vì đối chứng) nhưng *cứu* luật cũ (vì HITL chặn các ca lỗ). So sánh chính được đăng ký trước cho giai đoạn 8 là MILP qua Router với luật cũ qua Router, tức là so sánh bất lợi cho MILP, vì guardrail và HITL là quy định bắt buộc chứ không phải lựa chọn của chính sách.

Bảng 4.11. Giá trị chính sách cộng dồn 7 kỳ valid+calib theo luồng (lợi nhuận gia tăng so với a0)

Chính sách	Số voucher TB/kỳ	Hiện thực cộng dồn (£)	Kỳ vọng cộng dồn (£)	Regret B cộng dồn
MILP thuần (miền v1, không Router)	250	28 134	31 769	0,486
Luật cũ thuần (miền v1)	213	−2 650	6 127	0,901
MILP qua Router v2.1	177	21 483	20 089	0,675
Luật cũ qua Router v2.1	116	15 039	15 273	0,753

Nguồn: Tác giả tính toán từ `s7_policy_value_summary_v21.csv`. *0 vi phạm ràng buộc ở cả hai luồng qua Router.*



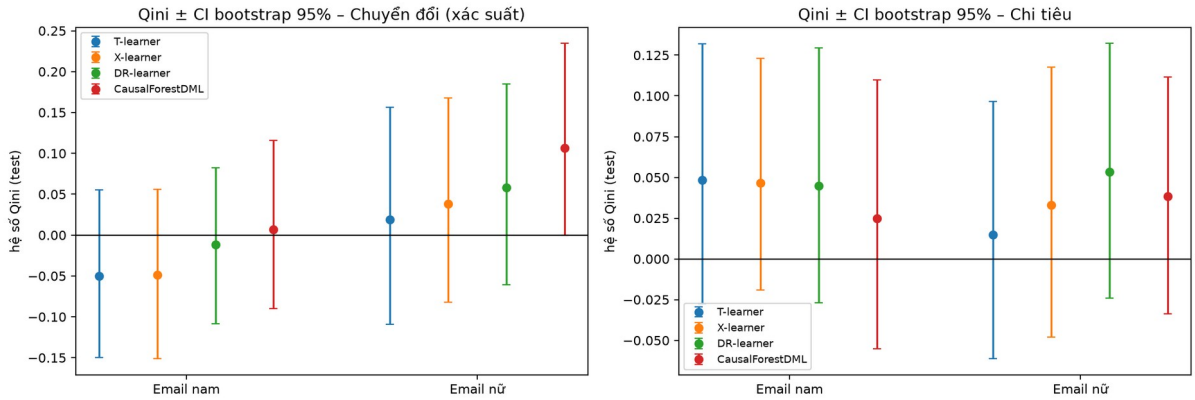
Hình 4.17. Giá trị thật của chính sách trước và sau Router theo từng kỳ: hiện thực (trái) và kỳ vọng (phải)

Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s7_policy_value.png`*)*

Độ trễ. Trên valid+calib, một kỳ đầu–cuối có P50 0,72 s, P95 0,75 s, P99 0,94 s, trong đó khâu chấm điểm mô hình ($\hat{\mu}_0$, $\hat{S}$, ba $\hat{\tau}$ với CI từ Causal Forest) chiếm 0,56 s, MILP 0,12 s, router 0,03 s. Giai đoạn 8 sẽ cộng thêm khâu mã lý do SHAP top-3 (0,06 s) vào phép đo chính thức.

4.1.8. Kiểm định ngoài trên thử nghiệm ngẫu nhiên thật (Hillstrom)

Để kiểm tra phương pháp trên dữ liệu có can thiệp thật, giai đoạn s9 chạy lại chuỗi nhân quả – uplift – tối ưu trên bộ Hillstrom (64 000 khách, ba nhánh cân bằng 33,3 %: không gửi, email nam, email nữ; chia train 44 800 / test 19 200). ATE trên chuyển đổi là 0,0068 [0,0050; 0,0086] cho email nam và 0,0031 [0,0015; 0,0047] cho email nữ, trên lượt ghé thăm là 0,077 và 0,045; tất cả có ý nghĩa, xác nhận can thiệp có tác động trung bình. Tuy nhiên với kết quả chính đăng ký trước là chuyển đổi, **không learner nào có Qini với CI > 0 trên test** (0/2 email cho cả T, X, DR-learner và CausalForestDML; Hình 4.18). Với kết quả phụ đã khai báo trước là lượt ghé thăm, email nữ có Qini 0,072 [0,049; 0,096] dương có ý nghĩa. Khi chuyển sang tầng quyết định với trần gửi 30 %, MILP trùng Greedy (chỉ một ràng buộc đếm) và giá trị ước lượng IPW của chính sách MILP không hơn gửi ngẫu nhiên 30 % có ý nghĩa (chênh −0,015 [−0,091; 0,058]) và không hơn không gửi có ý nghĩa (+0,026 [−0,063; 0,111]), trong khi gửi ngẫu nhiên 30 % lại hơn không gửi có ý nghĩa (+0,040 [0,008; 0,078]).



Hình 4.18. Hillstrom: hệ số Qini ± CI bootstrap 95 % trên test theo learner, chuyển đổi (trái) và chi tiêu (phải)

Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s9_qini_ci.png`)

Kết quả Hillstrom nhất quán với bức tranh trên Online Retail: với tỷ lệ chuyển đổi nền chỉ 0,6 %, tín hiệu CATE quá yếu so với nhiễu để xếp hạng có ý nghĩa, và một chính sách nhắm mục tiêu phức tạp không chứng minh được rằng nó hơn gửi ngẫu nhiên. Đây không phải lỗi của pipeline mà là giới hạn thống kê của bài toán uplift ở tỷ lệ sự kiện thấp, và là lý do để phần đề xuất ở Chương VI đặt trọng tâm vào thiết kế thí điểm có nhóm đối chứng đủ lớn thay vì vào mô hình phức tạp hơn.

4.2. Phân tích độ trễ đầu cuối, giám sát độ trôi, độ trễ nhãn và đối sánh Current – Challenger

Phần này trình bày kết quả khi tác giả cho hệ thống "chạy thật" trên năm kỳ Out-of-Time, tập trung vào bốn nhóm chỉ số mà đề bài yêu cầu: độ trễ đầu cuối (P50, P95, P99), độ trôi (PSI, Brier, ECE, Action TVD), độ trễ nhãn và đối sánh mô hình Current với Challenger.

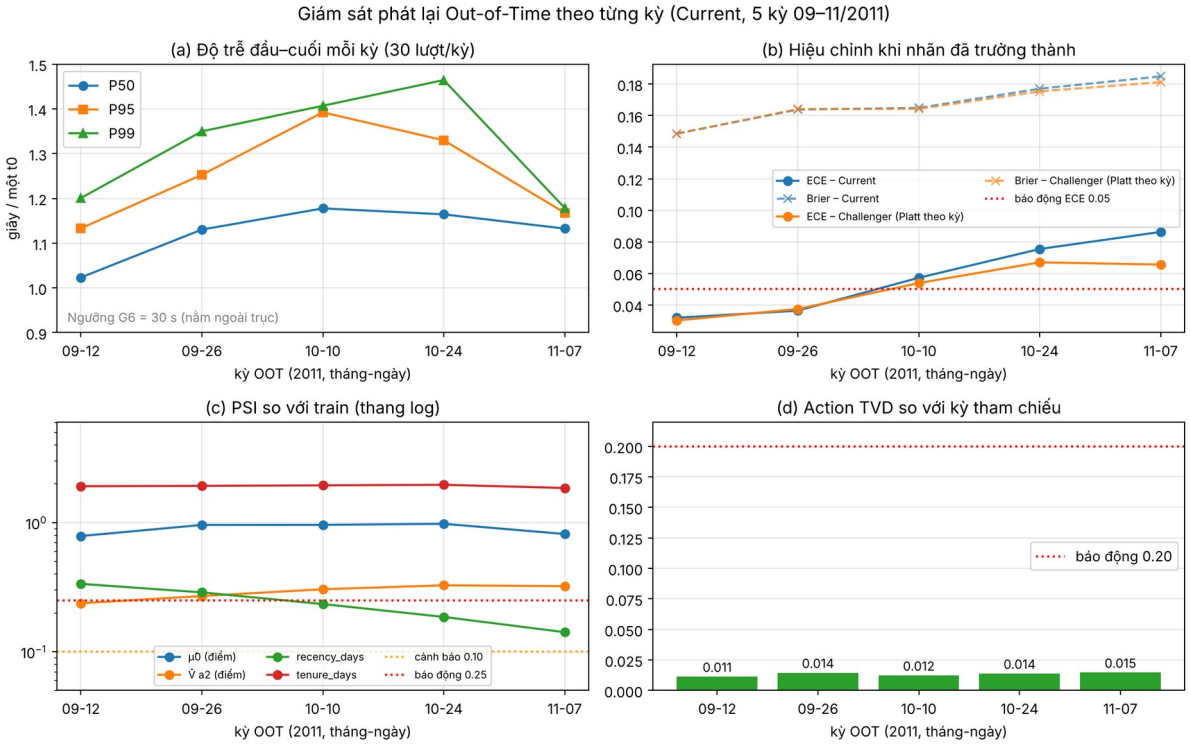
Năm kỳ OOT (12/09 – 07/11/2011, mùa cao điểm quý IV) được phát lại tuần tự như vận hành thật với mô hình Current. Bảng 4.12 và Hình 4.19 tổng hợp các chỉ số giám sát theo kỳ.

Bảng 4.12. Giám sát phát lại Out-of-Time theo từng kỳ (Current)

Kỳ t0 (2011)	Độ trễ P50 / P95 / P99 (s)	Tỷ lệ mua thật (a0)	p̄ dự báo (a0)	ECE Current	ECE Challenger	Action TVD
12/09	1,02 / 1,13 / 1,20	0,245	0,229	0,032	0,030	0,011
26/09	1,13 / 1,25 / 1,35	0,265	0,231	0,036	0,037	0,014
10/10	1,18 / 1,39 / 1,41	0,293	0,237	0,057	0,054	0,012
24/10	1,16 / 1,33 / 1,46	0,317	0,241	0,075	0,067	0,014
07/11	1,13 / 1,17 / 1,18	0,327	0,240	0,086	0,066	0,015
Gộp 5 kỳ	1,14 / 1,32 /	—	—	—	Challenger	ngưỡng 0,20

Kỳ t0 (2011)	Độ trễ P50 / P95 / P99 (s)	Tỷ lệ mua thật (a0)	p̄ dự báo (a0)	ECE Current	ECE Challenger	Action TVD
	1,41				tốt hơn 4/5	

Nguồn: Tác giả tính toán từ `s8_oot_latency.csv`, `s8_oot_calibration_matured.csv`, `s8_oot_action_tvd.csv`. *In đậm: vượt ngưỡng báo động ECE 0,05. ECE chỉ tính khi nhãn đã trưởng thành (trễ 30–58 ngày, trung bình 43,2 ngày).*



Hình 4.19. Giám sát OOT theo kỳ: (a) độ trễ P50/P95/P99, (b) ECE và Brier của Current và Challenger, (c) PSI của bốn biến tiêu biểu, (d) Action TVD

Nguồn: Tác giả vẽ từ các bảng `s8_oot_latency.csv`, `s8_oot_calibration_matured.csv`, `s8_oot_psi.csv`, `s8_oot_action_tvd.csv`

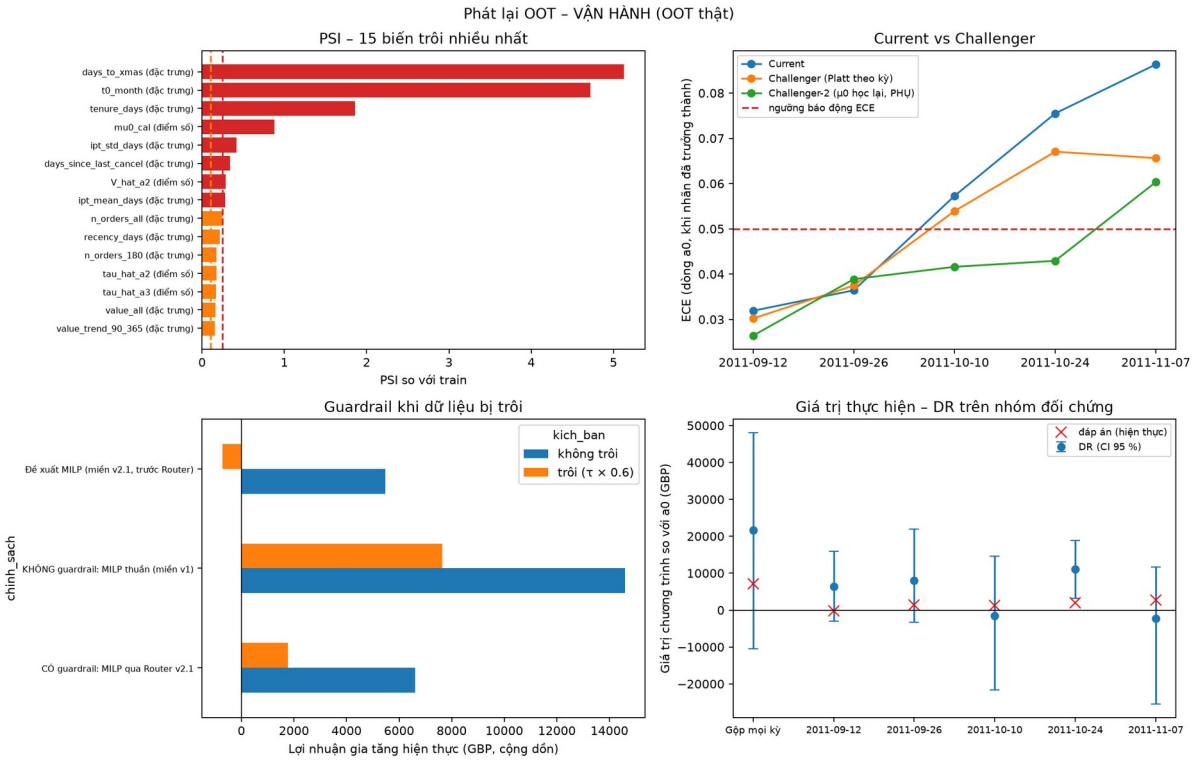
Độ trễ đầu–cuối P50/P95/P99 gộp là 1,14 / 1,32 / 1,41 s, cao hơn mức đo trên Locked Test (mục 4.3.2) khoảng 25 % vì quần thể OOT lớn hơn (4,3 nghìn khách/kỳ); khâu chấm điểm chiếm 0,82 s (72 %), MILP 0,21 s, mã lý do 0,07 s. Tất cả xa dưới ngưỡng 30 s, nên nút thắt vận hành không nằm ở hạ tầng tính toán mà ở **độ trễ nhãn**: Brier/ECE, hiệu chỉnh lại Challenger, giá trị thực hiện DR và chẩn đoán khuyết nhãn đều phải chờ cửa sổ 30 ngày kết thúc rồi tới ngày phát lại kế tiếp, nên thực tế trễ 30–58 ngày (trung bình 43,2). Các chỉ số không cần nhãn (PSI, Action TVD, vi phạm ràng buộc, độ trễ) có ngay tại t0 và vì thế là lớp cảnh báo sớm.

Hiệu chỉnh trôi theo mùa. Qua Bảng 4.12, ta thấy tỷ lệ mua lại nền tăng dần từ 0,245 lên 0,327 trong mùa cao điểm, trong khi xác suất dự báo trung bình của Current gần như đứng yên ở 0,23–0,24 vì bộ Platt được khớp trên calib (tháng 4–5). ECE của Current vì thế tăng từ 0,032 lên 0,086 và vượt ngưỡng báo động 0,05 từ kỳ 10/10. Challenger (Platt hiệu chỉnh lại theo cửa sổ ba kỳ đã trưởng thành) tốt hơn ở 4/5 kỳ và giữ ECE ở 0,066 ở kỳ cuối, nhưng vẫn vượt 0,05 vì bản thân nó cũng chậm 42 ngày so với thực tế. Challenger-2 (huấn luyện lại μ_0, phụ) có ECE thấp hơn nữa (0,026–0,060), song

kiểm toán chỉ ra bộ hiệu chỉnh của nó được khớp trên điểm số trong mẫu, nên con số này không so sánh sạch được và không được dùng để kết luận. Như vậy, kế hoạch ngân sách của Current sẽ đánh giá thấp chi phí chiết khấu trong quý IV, đúng cơ chế đã chỉ ra ở mục 4.1.6.

PSI. Gộp năm kỳ, 8 biến vượt ngưỡng báo động 0,25: `days_to_xmas` (5,13), `t0_month` (4,72), `tenure_days` (1,86), `ipt_std_days` (0,42), `days_since_last_cancel` (0,34), `ipt_mean_days` (0,28), điểm $\hat{\mu}_0$ (0,88) và $\hat{V}$ của a2 (0,29); 12 biến khác ở mức cảnh báo 0,10–0,25 và các đặc trưng RFM ngắn hạn (30–365 ngày) ổn định. Phần lớn báo động là **trôi theo cấu trúc thời gian** chứ không phải trôi hành vi: đặc trưng lịch tất yếu khác train, thâm niên của cùng tập khách tất yếu tăng theo thời gian, và điểm tham chiếu PSI của train là điểm trong mẫu nên PSI điểm số bị phóng đại. Playbook vì thế loại đặc trưng lịch khỏi quy tắc đếm báo động. Dù vậy PSI của $\hat{\mu}_0$ (0,88) và $\hat{V}$ a2 (0,29) là tín hiệu thật rằng phân phối điểm số đã đổi, nhất quán với ECE tăng.

Action TVD so với kỳ tham chiếu chỉ 0,011–0,015, xa dưới ngưỡng 0,20: phân phối hành động (≈ 96 % a0, 2 % a1, 1,2 % a3, 0,1–0,3 % a2) ổn định dù đầu vào trôi, vì các ràng buộc ngân sách và cuộc gọi cố định số lượng gửi. Điều này cũng có nghĩa TVD không phải chỉ số nhạy để phát hiện trôi trong thiết kế có ràng buộc chặt; nó hữu ích hơn để phát hiện lỗi hệ thống (ví dụ a2 tăng vọt).



Hình 4.20. Phát lại OOT: 15 biến trôi nhiều nhất theo PSI, Current so với Challenger, guardrail khi dữ liệu trôi, và giá trị thực hiện DR trên nhóm đối chứng

Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s8_oot.png`)

4.3. Phân tích, đánh giá kết quả thực chứng và kiểm định các cổng phát hành

Sau khi theo dõi hệ thống vận hành trên dữ liệu ngoài thời gian, phần này đánh giá bằng chứng thực chứng để trả lời câu hỏi then chốt: hệ thống đã đủ điều kiện phát hành hay chưa. Tác giả trình bày quy trình mở Locked Test, kết quả bảy cổng phát hành, sau đó phân tích giá trị thực hiện, vai trò của guardrail khi dữ liệu trôi và vấn đề khuyết nhãn có chọn lọc.

4.3.1. Diễn tập, đóng băng và mở Locked Test

Lần diễn tập với calib đóng vai locked cho kết quả G2, G3 và G4b trượt, G1, G4a, G5, G6, G7 đạt, nhất quán với các giai đoạn trước (ECE valid 0,047, Qini CI 1/3, regret A ≈ 0,83). Manifest đóng băng được ghi lúc 21:31:07 ngày 12/11/2026 (giờ Việt Nam) với 28 file mã, mô hình, cấu hình và 15 file dữ liệu; file khóa Locked Test được tạo lúc 21:40:19 và ghi lại hash tổng hợp của trạng thái đóng băng. Mọi file kết quả `s8_locked_*` đều có thời điểm sau khóa; không có lần mở thứ hai (lệnh từ chối chạy khi khóa đã tồn tại, được kiểm thử tự động).

4.3.2. Kết quả kiểm định bảy cổng phát hành

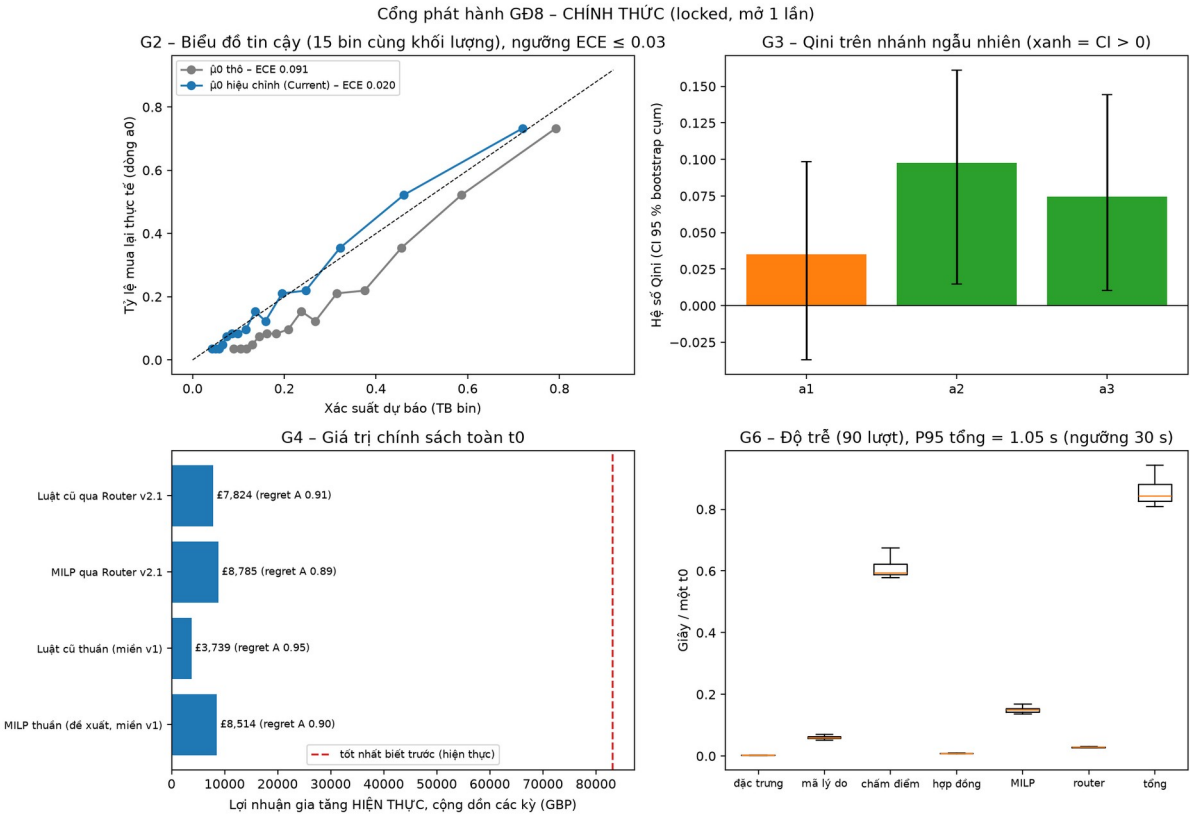
Bảng 4.13 và Hình 4.21 trình bày kết quả chính thức trên toàn bộ locked (12 947 dòng, 4 426 khách, 3 kỳ). **Bảy trong tám tiêu chí đạt; G4b trượt; hệ thống KHÔNG được phát hành toàn phần.** Từng cổng được đối chiếu với dự báo đăng ký trước:

Bảng 4.13. Cổng phát hành trên Locked Test (toàn bộ, mở một lần) và đối chiếu với dự báo đăng ký trước

Cổng	Kết quả	Ngưỡng	Đạt	Đối chiếu dự báo §6b / điều cần đọc kèm
G1	7/7 kiểm tra hợp đồng dữ liệu	tất cả	ĐẠT	Không có dự báo riêng; lỗi mã ở dry-run đã sửa trước đóng băng
G2	ECE 0,0201 [CI 0,0169; 0,0351]; Brier 0,1127 so với thô 0,1213 (n_a0 = 3 422)	ECE ≤ 0,03; Brier không tệ hơn	ĐẠT	Dự báo: có thể không hợp. Ngưỡng nằm trong CI percentile (chệch lên); entity holdout ECE 0,049 (mô tả)
G3	2/3: a1 0,035 [−0,037; 0,098] · a2 0,098 [0,015; 0,161] · a3 0,075 [0,010; 0,144]	≥ 2 hành động CI > 0	ĐẠT	Trái dự báo (P ≈ 4–7 %). Cận dưới a3 sát 0; Bonferroni thì trượt; khách thường 1/3; holdout 0/3
G4a	£8 785 so với £7 824 (luật cũ qua Router), chênh £961	chênh ≥ £782	ĐẠT	Đúng dự báo (khả thi). CI bootstrap của chênh [−£2 273; +£3 980]: nằm trong nhiễu. Phụ: so luật cũ thuần £3 739, chênh £5 046
G4b	Regret A 0,894 (giá trị £8 785 so với mốc biết trước £83 080); regret B 0,709	≤ 0,35	TRƯỢT	Đúng dự báo (gần như chắc trượt): ngay chính sách biết kỳ vọng thật cũng

Cổng	Kết quả	Ngưỡng	Đạt	Đối chiếu dự báo §6b / điều cần đọc kèm
				có regret A 0,742
G5	0 vi phạm trên 3 kỳ quyết định gửi thực tế	0	ĐẠT	Bước sửa khả thi cuối hoạt động đúng
G6	P95 1,052 s (90 lượt; P95 kỳ cao nhất 1,145 s)	≤ 30 s	ĐẠT	Đã gồm khâu mã lý do SHAP
G7	UK +18,8 % (£4 998 so với £4 206); non-UK +4,7 % (£3 787 so với £3 617)	≥ −5 % mỗi phân khúc	ĐẠT	Phụ so luật cũ thuần: UK +5 284 % vì mẫu số chỉ £93, nên báo chênh tuyệt đối +£4 905

Nguồn: Tác giả tính toán từ `s8_locked_gates.csv`, `s8_locked_g4a_comparison.csv`, `s8_locked_g7_segments.csv`; CI của G4a từ kiểm toán độc lập (bootstrap cụm khách 5 000 lần).



Hình 4.21. Cổng phát hành chính thức trên Locked Test: G2 (độ tin cậy), G3 (Qini), G4 (giá trị chính sách), G6 (độ trễ)

Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s8_locked_gates.png`)

Ba điểm cần đọc kỹ. **G4b trượt vì mốc không thể đạt.** Regret A lấy mốc là chính sách biết trước kết quả hiện thực của từng khách; như đã thấy ở giai đoạn 5, ngay chính sách biết kỳ vọng thật cũng có regret A 0,742 và mọi phương pháp ở quy mô toàn t0 đều trên 0,83. Ngưỡng 0,35 được đặt khi đăng ký trước mà chưa lường được điều này; theo luật cứng, ngưỡng không được sửa sau khi mở locked, nên kết quả được giữ nguyên là trượt và cổng phát hành đã làm đúng chức năng tự từ chối. Regret B của MILP qua Router là 0,709, và của MILP thuần là 0,549, cho thấy phần tổn thất quyết định do mô

hình nhỏ hơn nhiều so với phần may rủi. **G4a đạt nhưng nằm trong nhiễu.** Chênh £961 vượt ngưỡng £782 chỉ £179; hai luồng chỉ khác nhau ở 553/12 947 dòng; bootstrap cụm khách cho CI [−£2 273; +£3 980] và chỉ 55,8 % mẫu lấy lại đạt ngưỡng. G4a vì thế đạt theo đúng định nghĩa đăng ký trước (ước lượng điểm) nhưng tác giả không kết luận rằng MILP hơn luật cũ có ý nghĩa thống kê trên locked. Theo giá trị kỳ vọng, chênh là £3 082 (£8 211 so với £5 129). **G3 đạt trái dự báo và là kết cục thiểu số.** Qini a2 trên locked (0,098) cao hơn hẳn calib (0,004); phân tích hậu kiểm của kiểm toán bằng cách gán lại nhánh ngẫu nhiên 1 000 lần từ đáp án cho Qini kỳ vọng ổn định qua các mùa (a2 ≈ 0,06, a3 ≈ 0,065 ở cả valid, calib, locked, độ lệch chuẩn do gán ≈ 0,04): giá trị 0,004 trên calib là một lần rút thấp (phân vị 7 %) và 0,098 trên locked là một lần rút cao (phân vị 86 %). Với hiệu ứng kỳ vọng này, xác suất đạt G3 khoảng 16 %, vẫn là thiểu số. Cận dưới CI của a3 (0,010) phụ thuộc hạt giống bootstrap (dương ở 15/20 hạt giống) và trượt nếu hiệu chỉnh Bonferroni cho ba phép thử.

Trên quần thể entity holdout (2 005 dòng khách chưa từng thấy), G2 (ECE 0,049), G3 (0/3) và G4a (−£167 so với £384) đều không đạt; các con số này chỉ mang tính mô tả vì cỡ mẫu nhỏ, nhưng là lời nhắc rằng mô hình khái quát kém hơn cho khách hàng mới.

4.3.3. Giá trị thực hiện, guardrail khi dữ liệu trôi và khuyết nhãn có chọn lọc

Giá trị thực hiện. Ước lượng DR trên nhóm đối chứng cho giá trị chương trình gộp năm kỳ là £21 703 với CI 95 % [−£10 524; £48 043], **chứa 0**; giá trị thật theo đáp án là £7 143 và nằm trong CI. Nguyên nhân đã được dự báo đăng ký trước: Router vận hành gần tất định, chỉ 10 % trong số 765 khách được chọn rơi vào đối chứng, tức là chỉ **72 khách** trên năm kỳ để ước lượng phần tăng thêm, so với 837 dòng ngẫu nhiên của chính sách ghi log. Theo kỳ, chỉ kỳ 24/10 có CI không chứa 0. Bảng 4.14 cho thấy tổn thất khác nhau của ba cách ước lượng tác động trên nhóm *được chọn*: so sánh thô giữa khách được gửi và không được chọn cho +£33,5/khách, so với đối chứng ngẫu nhiên cho +£32,1, DR cho +£25,9, trong khi sự thật là **£8,6/khách**. Cả ba đều chệch dương vì Router chọn những khách có $\hat{V}$ cao, mà $\hat{V}$ cao một phần do nhiễu (winner's curse), và vì nhóm đối chứng quá nhỏ để khử hết. Đây là minh họa định lượng cho vấn đề khuyết nhãn có chọn lọc: dữ liệu phản hồi do chính hệ thống sinh ra sẽ cho mô hình học lại một bức tranh lạc quan hơn thực tế khoảng ba lần.

Bảng 4.14. Khuyết nhãn có chọn lọc: ước lượng tác động trên nhóm khách được chọn (OOT, 765 khách được gửi, 72 đối chứng)

Cách ước lượng	Ước lượng (£/khách)	Thật (£/khách)	Độ chệch
So thô: được gửi − không được chọn (không đối chứng)	33,5	8,6	+24,9
Đối chứng ngẫu nhiên: được gửi − đối chứng	32,1	8,6	+23,5
DR/AIPW (đối chứng + IPW)	25,9	8,6	+17,3

Nguồn: Tác giả tính toán từ `s8_oot_selective_effect.csv`.

Guardrail khi dữ liệu trôi (Bảng 4.15). Kịch bản trôi được sinh trước khi đóng băng bằng cách nhân tác động thuyết phục với 0,6 (khách bớt nhạy ưu đãi trong mùa cao

điểm). Không có guardrail, MILP thuần gửi 1 242 voucher, đạt £14 587 khi không trôi và £7 642 khi trôi, nhưng **vi phạm quy định 5/5 kỳ** (gửi cho khách opt-out, vượt giới hạn tần suất hoặc có tỷ lệ hủy cao). Có guardrail (MILP qua Router v2.1), số voucher giảm còn 776, vi phạm về 0, HITL từ chối hoặc hạ cấp 448 ca, nhưng giá trị hiện thực chỉ còn £6 611 (không trôi) và £1 776 (trôi). Có thể thấy, guardrail **không bảo vệ giá trị** khi trôi mà làm mất £7 976 (không trôi) và £5 866 (trôi) so với không có guardrail; lợi ích của nó là tuân thủ quy định và giảm rủi ro pháp lý, danh tiếng, chứ không phải lợi nhuận ngắn hạn. Tổn thất tương đối lớn hơn khi trôi (mất 77 % giá trị thay vì 55 %) vì HITL từ chối theo CI của $\hat{\tau}$, mà CI này không biết rằng tác động thật đã giảm.

Bảng 4.15. Guardrail khi dữ liệu trôi trên 5 kỳ OOT (lợi nhuận gia tăng hiện thực cộng dồn)

Chính sách	Kịch bản	Giá trị hiện thực (£)	Số voucher	Vi phạm quy định (kỳ)	HITL từ chối / hạ cấp
Không guardrail: MILP thuần (miền v1)	không trôi	14 587	1 242	5	0
Có guardrail: MILP qua Router v2.1	không trôi	6 611	776	0	448
Không guardrail: MILP thuần (miền v1)	trôi ($\tau \times 0{,}6$)	7 642	1 242	5	0
Có guardrail: MILP qua Router v2.1	trôi ($\tau \times 0{,}6$)	1 776	776	0	448

Nguồn: Tác giả tính toán từ `s8_oot_drift_guardrail.csv`.

TÓM TẮT CHƯƠNG IV

Chương IV đã trình bày kết quả thực nghiệm qua tám giai đoạn và kiểm định ngoài trên Hillstrom. Nhìn chung, hệ thống đạt được nhiều kết quả tích cực. Dữ liệu không rò rỉ, mô hình dự báo được hiệu chỉnh tốt trên locked (ECE 0,020), DML khôi phục đúng tác động thật, MILP giảm regret kỳ vọng so với luật cũ, Router đảm bảo 0 vi phạm với độ trễ dưới 1,5 giây. Tuy nhiên, hệ thống vẫn còn một số vấn đề:

- Cổng G4b trượt (regret 0,894 > 0,35) vì mốc so sánh không thể đạt, nên hệ thống không được phát hành toàn phần.
- Các chênh lệch về giá trị kinh tế (G4a, G3, giá trị DR trên OOT) đúng hướng nhưng đều nằm trong nhiễu thống kê.
- Hiệu chỉnh xác suất trôi theo mùa trong quý IV, ECE vượt ngưỡng báo động từ kỳ 10/10.
- Guardrail đưa vi phạm về 0 nhưng làm giảm giá trị lợi nhuận, và dữ liệu phản hồi bị chệch do khuyết nhãn có chọn lọc.

Những kết quả và hạn chế này là cơ sở để tác giả thảo luận trong Chương V.

V. THẢO LUẬN (DISCUSSION)

5.1. So sánh kết quả đạt được với mục tiêu quản trị và các tiêu chí chấp nhận ban đầu

Từ những kết quả đã phân tích ở Chương IV, tác giả đối chiếu lại với mục tiêu ban đầu. Mục tiêu quản trị của dự án là một hệ thống phân bổ ngân sách giữ chân khách hàng có lợi nhuận cao hơn luật RFM cũ ít nhất 10 %, tuân thủ mọi ràng buộc vận hành, chạy trong thời gian cho phép và không gây bất lợi cho phân khúc nào. Theo nghĩa hẹp, hệ thống đạt 7/8 tiêu chí trên Locked Test và chỉ trượt G4b. Tuy nhiên, theo tác giả, kết quả cần được đọc theo nghĩa rộng hơn như sau. Về **tuân thủ và vận hành** (G1, G5, G6, G7), hệ thống đạt chắc chắn: 0 vi phạm ràng buộc trên mọi kỳ locked và OOT, P95 dưới 1,5 giây so với ngưỡng 30 giây, không phân khúc nào bị thiệt. Về **chất lượng dự báo** (G2), hệ thống đạt trên locked nhưng bằng chứng mỏng (ngưỡng nằm trong CI) và sẽ không giữ được qua mùa cao điểm nếu thiếu hiệu chỉnh lại theo kỳ. Về **giá trị kinh tế** (G3, G4a), các ước lượng điểm đều đúng hướng: Qini dương cho cả ba hành động, MILP qua Router hơn luật cũ qua Router £961 trên locked và hơn luật cũ thuần £5 046, các chỉ số kỳ vọng đều ủng hộ MILP. Nhưng không một trong các chênh lệch đó vượt qua được nhiễu thống kê với cỡ mẫu hiện có: CI của chênh G4a chứa 0, G3 đạt phụ thuộc hạt giống bootstrap, DR trên OOT chứa 0, Hillstrom 0/2. Vì vậy câu trả lời cho câu hỏi đặt ra ở mục 1.1 là: **hệ thống chưa đủ bằng chứng để được phát hành toàn phần, và nút thắt là sức mạnh thống kê chứ không phải chất lượng mô hình.** Điều đáng ghi nhận về mặt phương pháp là kết luận này được chính hệ thống đưa ra: ba trong bốn dự báo đăng ký trước (G2 rủi ro, G4a khả thi, G4b trượt, DR không phân định được) đã đúng, dự báo thứ tư (G3) sai theo hướng bi quan vì ước lượng hiệu ứng từ calib là một lần rút thấp.

5.2. Những điểm mạnh, hạn chế của hệ thống

5.2.1. Những điểm mạnh

- **Kỷ luật kiểm chứng.** Ngưỡng cổng đăng ký trước, dự báo kết quả đăng ký trước, đóng băng SHA-256 cho 43 file, Locked Test mở đúng một lần có khóa, đáp án cô lập bằng kiểm thử tự động, và một phiên kiểm toán độc lập tính lại 7/7 cổng khớp tới chữ số cuối và đối chiếu 443 con số không lệch. Mức độ này hiếm gặp trong các dự án phân tích ứng dụng và là điều kiện để các kết luận âm tính (không phát hành) có giá trị.
- **Tính khép kín thực sự.** Hàm giá trị V[i,a] nối ba tầng dự báo, nhân quả và tối ưu bằng một công thức duy nhất, trong đó hiệu chỉnh xác suất đi thẳng vào chi phí; kết quả tối ưu đi qua Router với guardrail, HITL, đối chứng và bản ghi chống lặp; đầu ra của Router quay lại nuôi vòng giám sát và Challenger. Mỗi mắt xích đều có thí nghiệm riêng chứng minh vai trò của nó (ví dụ hiệu chỉnh ↔ chi phí chiết khấu, HITL ↔ giá trị thật của ca được duyệt và từ chối).
- **Minh bạch về kết quả âm tính.** SPO+ không thắng PTO, MILP không hơn Greedy về hiện thực, guardrail làm mất giá trị, Hillstrom 0/2: tất cả được giữ nguyên và giải thích thay vì bị lược bỏ.

– **Chi phí tính toán thấp.** Toàn bộ chu trình chạy trên máy cá nhân với bộ giải mã nguồn mở; một kỳ quyết định mất khoảng một giây.

5.2.2. Những hạn chế

Tác động của khuyết nhãn có chọn lọc. Mục 4.3.3 cho thấy mọi cách ước lượng tác động trên nhóm được chọn đều chệch dương từ +£17 đến +£25/khách so với sự thật £8,6, kể cả khi đã có đối chứng ngẫu nhiên và IPW. Nếu mô hình được huấn luyện lại từ dữ liệu phản hồi này, nó sẽ học một bức tranh lạc quan gấp ba lần thực tế và tự củng cố việc chọn những khách có $\hat{V}$ cao do nhiễu. Hệ quả thiết kế là tỷ lệ đối chứng 10 % không đủ: với 72 khách đối chứng trên năm kỳ, không một chỉ số giá trị nào phân định được. Khoản mất £2 161 của nhóm đối chứng trên valid+calib là chi phí đo lường cần thiết, và bài học là chi phí này phải được tính từ đầu bằng phân tích power (mục 6.4).

Độ trễ hạ tầng và độ trễ nhãn. Độ trễ tính toán không phải vấn đề (P99 1,4 s), nhưng độ trễ nhãn 30–58 ngày khiến các chỉ số cần nhãn luôn đến muộn hơn PSI và TVD từ hai đến bốn kỳ. Trong mùa cao điểm, điều này nghĩa là ECE báo động ở kỳ 10/10 chỉ được biết vào đầu tháng 12, khi mùa đã gần qua. Hệ thống giảm nhẹ bằng lớp cảnh báo sớm không cần nhãn và Challenger hiệu chỉnh lại theo cửa sổ trượt, nhưng không loại bỏ được độ trễ cấu trúc này.

Chi phí tính toán của bộ giải. MILP ở quy mô một kỳ mất 0,15 s và ở 50 000 khách mất 14,3 s, vẫn dưới ngưỡng G6 nhưng tăng siêu tuyến tính; khâu chấm điểm (Causal Forest với CI) mới là phần chiếm 70 % độ trễ. Greedy nhanh hơn 50–170 lần và chỉ kém 4–17 % trên $\hat{V}$, lại không khác MILP có ý nghĩa về giá trị hiện thực; với doanh nghiệp lớn hơn nhiều lần, lựa chọn hợp lý có thể là Greedy có vá ràng buộc, giữ MILP cho phân tích giá bóng ngoại tuyến.

Giả định nhận dạng nhân quả. Vì lớp can thiệp là bán tổng hợp với cơ chế chỉ phụ thuộc các đặc trưng mô hình thấy, giả định không nhiễu chưa quan sát đúng theo cấu trúc; CI DML phủ sự thật 6/6 và placebo 6/6 vì thế chỉ kiểm chứng *cài đặt*, không kiểm chứng rằng các giả định này đúng với voucher thật. Trên RCT thật (Hillstrom), không CATE nào vượt được ngẫu nhiên có ý nghĩa ở kết quả chính. Ngoài ra, cơ chế bán tổng hợp không có hiệu ứng mang sang giữa các kỳ, giá trị giỏ của người mới chuyển đổi là mô phỏng, $\hat{S}$ được giả định không đổi theo can thiệp, và biên lợi nhuận 30 % là giả định có ảnh hưởng tới quyết định (winner's curse theo m ở mục 4.1.6).

Những điều phải công khai về quy trình kiểm chứng. (i) Locked Test không "mù" hoàn toàn: các số tổng hợp của locked và oot (tỷ lệ mua lại, giá trị giỏ trung bình, ATE thật theo tập) đã được sinh ra ở giai đoạn 1, 1b và 2 trước khi mở khóa; kiểm toán không thấy dấu hiệu chúng được dùng để chỉnh mô hình hay ngưỡng, nhưng không thể chứng minh điều ngược lại với bên thứ ba. (ii) Bằng chứng đăng ký trước chỉ dựa trên thời gian sửa file và hash đóng băng, không có lịch sử git sớm; toàn bộ dự án diễn ra trong một ngày. (iii) Ngưỡng G4b 0,35 đặt sai khi đăng ký trước và được giữ nguyên theo luật. (iv) Người duyệt HITL là quy tắc mô phỏng, giả định đủ nhân lực duyệt hết trong kỳ. (v) Hai file kiểm thử được sửa sau khi đóng băng (hash đã ghi vào phụ lục), và lần dry-run đầu G1 từng trượt do lỗi mã, đã sửa. (vi) Kiểm thử rò rỉ T1–T3 ở giai đoạn 1

chỉ chạy trên 4 kỳ, kiểm toán bổ sung trên 38 kỳ. (vii) "Luật cũ" trong các so sánh là MILP trên điểm logit của luật RFM chứ không phải chính sách ghi log, và "luật cũ qua Router" dùng CI của mô hình ở bước HITL, nên so sánh chính bất lợi cho MILP.

5.3. Những phát hiện đáng chú ý

5.3.1. Quan hệ phi tuyến giữa sai số dự báo và tổn thất quyết định

Thí nghiệm ở mục 4.1.5 cho ba bằng chứng bổ sung nhau. Nhân $\hat{V}$ với hằng số làm MSE thay đổi hơn hai lần mà regret không đổi; nhiễu cộng làm MSE tăng 4,7 lần mà regret A chỉ nhích 0,08; và trong bảng xếp hạng phương pháp, PTO LightGBM có MSE thấp hơn PTO tuyến tính nhưng regret cao hơn. Nghĩa là tầng quyết định chỉ cần $\hat{V}$ đúng *thứ hạng và dấu* quanh ngưỡng chọn, còn mức tuyệt đối không quan trọng. Hàm ý thực hành: khi đánh giá một mô hình phục vụ quyết định, chỉ số đúng là regret trên tập kiểm định có đáp án hoặc có đối chứng, không phải MSE hay AUC; và một mô hình được *cấu trúc* từ các thành phần ước lượng ổn định ($\hat{\mu}_0$, $\hat{S}$, $\hat{\tau}$) có thể thắng một mô hình hồi quy trực tiếp lên nhãn giá trị nhiễu dù mô hình sau tối ưu đúng hàm mất mát hướng quyết định. Kết quả SPO+ không thắng PTO ở đây vì thế không bác bỏ lý thuyết của Elmachtoub và Grigas (2022), mà chỉ ra điều kiện áp dụng của nó: SPO+ cần nhãn chi phí đủ sạch, điều hiếm có khi chi phí là lợi nhuận gia tăng ở cấp cá nhân.

5.3.2. Hiệu quả của rào chắn nghiệp vụ khi dữ liệu bị trôi

Kết quả ở Bảng 4.15 đi ngược kỳ vọng thông thường rằng guardrail "bảo vệ" hệ thống khi dữ liệu trôi. Trên lợi nhuận, guardrail làm mất 55 % giá trị khi không trôi và 77 % khi trôi; phần lớn tổn thất đến từ HITL từ chối 411–448 ca theo CI của $\hat{\tau}$, một CI không biết tác động thật đã giảm. Cái guardrail thực sự mang lại là đưa số kỳ vi phạm quy định từ 5/5 về 0 và tạo nhóm đối chứng để đo lường. Hàm ý là guardrail phải được đánh giá theo mục tiêu tuân thủ và rủi ro, không theo lợi nhuận; và nếu doanh nghiệp muốn giảm tổn thất lợi nhuận của HITL, hướng đi là hiệu chỉnh lại CI của $\hat{\tau}$ theo kỳ (tương tự Challenger cho $\hat{\mu}_0$) chứ không phải nới lỏng quy tắc duyệt. Một hệ quả thứ hai là ngay khi trôi 40 % về tác động, MILP thuần vẫn dương (£7 642) còn MILP qua Router gần hòa (£1 776): hệ thống không gây lỗ khi trôi, nhưng cũng không còn tạo giá trị đáng kể, nên playbook cần điều kiện quay lui dựa trên DR hai kỳ liên tiếp.

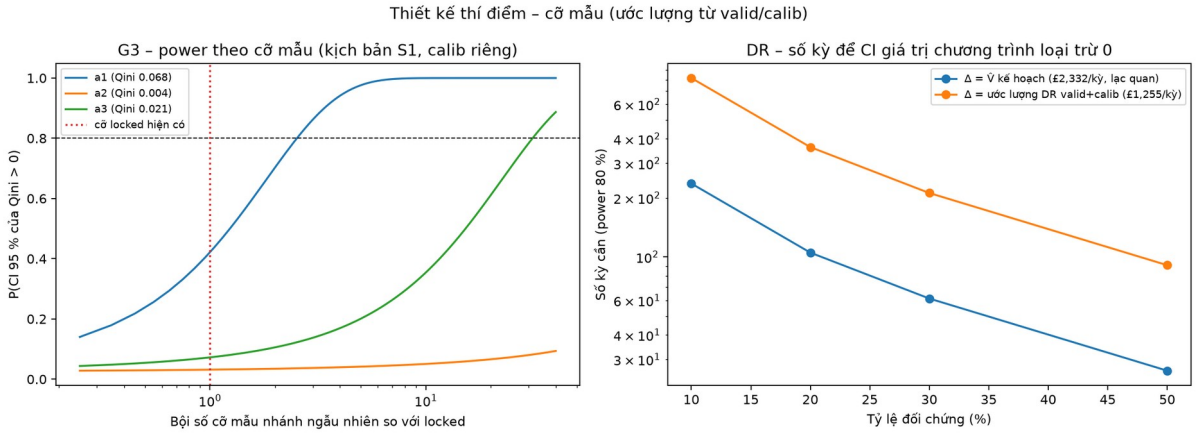
5.3.3. Hiệu chỉnh xác suất là biến ngân sách, không phải chi tiết kỹ thuật

Ở nhiều hệ thống, hiệu chỉnh được coi là bước làm đẹp. Trong thiết kế này, vì chiết khấu được trả cho cả nhóm sure things, sai số hiệu chỉnh 0,1 của $\hat{\mu}_0$ chuyển thành sai số 35 % của chi phí chiết khấu kế hoạch (mục 4.1.6), và trôi mùa làm ECE tăng từ 0,03 lên 0,09 trong năm kỳ OOT (mục 4.2). Hàm ý tổ chức là bộ phận Tài chính nên nhận báo cáo ECE như một chỉ số tài chính, và chu kỳ hiệu chỉnh lại nên được gắn với lịch mùa vụ thay vì với lịch huấn luyện lại mô hình.

5.3.4. Sức mạnh thống kê là nút thắt

Khi gom lại, mọi bằng chứng về giá trị kinh tế đều đúng hướng và đều không có ý nghĩa thống kê. Lý do là tín hiệu nhỏ ($\tau \approx 0{,}04$–$0{,}08$ trên xác suất mua, lợi nhuận gia tăng $\approx$ £8/khách được chọn) so với nhiễu rất lớn của giỏ hàng khách sỉ (biên conformal

×2,47), trong khi cỡ mẫu có ích lại nhỏ (1 300 dòng ngẫu nhiên mỗi cặp Qini, 72 khách đối chứng). Phân tích cỡ mẫu thí điểm (`s8_pilot_dr.csv`, Hình 5.1) cho thấy với tỷ lệ đối chứng 10 % cần 237–816 kỳ (9–31 năm) để CI của giá trị chương trình loại trừ 0; với 50 % đối chứng cần 26–91 kỳ (1–3,5 năm) tùy hiệu ứng giả định là V̂ kế hoạch (£2 332/kỳ, lạc quan) hay ước lượng DR (£1 255/kỳ). Đây là con số mà doanh nghiệp cần biết trước khi đầu tư vào mô hình phức tạp hơn.



Hình 5.1. Thiết kế thí điểm: power của G3 theo cỡ mẫu nhánh ngẫu nhiên (trái) và số kỳ cần để CI giá trị chương trình loại trừ 0 theo tỷ lệ đối chứng (phải)

Nguồn: Tác giả xây dựng từ kết quả chạy mã nguồn dự án (`outputs/figures/fig_s8_pilot_sample_size.png`)

TÓM TẮT CHƯƠNG V

Chương V đã đối chiếu kết quả với mục tiêu quản trị và tiêu chí chấp nhận ban đầu. Qua đó, tác giả nhận thấy hệ thống đạt chắc chắn về tuân thủ và vận hành, đạt nhưng chưa vững về hiệu chỉnh, và đúng hướng nhưng chưa đủ bằng chứng về giá trị kinh tế. Bên cạnh những điểm mạnh về kỷ luật kiểm chứng và tính khép kín, hệ thống còn các hạn chế về khuyết nhãn có chọn lọc, độ trễ nhãn, chi phí bộ giải và giả định nhân quả bán tổng hợp. Bốn phát hiện đáng chú ý đã được rút ra, trong đó quan trọng nhất là sức mạnh thống kê chính là nút thắt của hệ thống. Dựa trên những phân tích này, tác giả đưa ra kết luận và đề xuất trong Chương VI.

VI. KẾT LUẬN VÀ ĐỀ XUẤT (CONCLUSION AND RECOMMENDATIONS)

6.1. Tổng kết nội dung chính và tính xuyên suốt của toàn bộ quy trình hỗ trợ ra quyết định

Qua quá trình thực hiện, tác giả đã xây dựng một hệ thống hỗ trợ ra quyết định khép kín cho bài toán phân bổ ngân sách khuyến mãi giữ chân khách hàng trên dữ liệu giao dịch TMĐT thật, đi trọn tám giai đoạn từ thiết kế dữ liệu point-in-time đến giám sát sau triển khai, và kiểm chứng bằng cổng phát hành đăng ký trước trên Locked Test mở một lần. Tính xuyên suốt thể hiện ở chỗ một hàm giá trị duy nhất nối dự báo có hiệu chỉnh ($\hat{\mu}_0$, $\hat{S}$), tác động nhân quả không đồng nhất ($\hat{\tau}_a$) và bài toán MILP có ràng buộc, rồi Router chuyển nghiệm thành hành động có kiểm soát và nuôi ngược vòng giám sát. Kết quả thực nghiệm chính: mô hình dự báo và hiệu chỉnh đạt yêu cầu trên locked (AUC 0,79, ECE 0,020); DML khôi phục ATE thật 6/6; CausalForestDML xếp hạng tốt hơn ngẫu nhiên với Qini dương cho cả ba hành động; MILP trên $\hat{V}$ giảm regret kỳ vọng từ 0,90 (luật cũ) xuống 0,49 và hơn luật cũ về lợi nhuận hiện thực ở mọi phép so sánh; Router bảo đảm 0 vi phạm với độ trễ dưới 1,5 giây. Đồng thời, hệ thống tự kết luận rằng bằng chứng về giá trị kinh tế chưa vượt qua nhiễu thống kê, và vì thế **không phát hành toàn phần**.

Bên cạnh đó, do giới hạn về thời gian thực hiện và dữ liệu (không có lịch sử chiến dịch khuyến mãi thật, lớp can thiệp phải xây dựng bán tổng hợp), bài làm khó tránh khỏi những thiếu sót. Tác giả mong nhận được ý kiến đóng góp của Thầy để hoàn thiện hơn.

6.2. Ý nghĩa thực tiễn trong việc tối ưu hóa nguồn lực và kiểm soát rủi ro cho doanh nghiệp

Thứ nhất, về tối ưu hóa nguồn lực: giá bóng cho thấy mỗi cuộc gọi của account manager đáng giá £8–9 lợi nhuận gia tăng kỳ vọng so với chi phí £3, tức là giới hạn 60 cuộc gọi/kỳ đang là ràng buộc chặt nhất và nên được nới trước khi nới ngân sách voucher (giá bóng chỉ £0,12–0,16 mỗi £1 mệnh giá). Luật RFM cũ, nếu áp dụng thuần, làm lỗ vì gửi voucher 20 % cho khách sẽ mua; chỉ riêng việc thay luật cũ bằng Greedy trên $\hat{V}$ đã đưa lợi nhuận gia tăng từ âm lên khoảng £4 000/kỳ ở quy mô 3,6 nghìn khách. Thứ hai, về kiểm soát rủi ro: Router với guardrail và HITL đưa vi phạm quy định về 0 và tránh được các ca lỗ, với chi phí là một phần lợi nhuận; doanh nghiệp cần quyết định rõ mức đánh đổi này. Thứ ba, về quản trị bằng chứng: giá trị lớn nhất của hệ thống nằm ở quy trình, gồm đăng ký trước, đóng băng, cổng phát hành tự từ chối khi chưa đủ bằng chứng, và playbook giám sát có ngưỡng và điều kiện quay lui; quy trình này tái sử dụng được cho các bài toán khác (bổ sung tồn kho, định giá) với chi phí thấp.

6.3. Hướng phát triển và nâng cấp hệ thống trong tương lai

- **Thí điểm có nhóm đối chứng lớn** (mục 6.4) là ưu tiên số một, vì không nâng cấp mô hình nào giải quyết được thiếu sức mạnh thống kê.
- **Hiệu chỉnh lại theo mùa cho cả $\hat{\mu}_0$ và CI của $\hat{\tau}$**: đưa Challenger (Platt theo cửa sổ trượt) thành cơ chế mặc định cho kế hoạch ngân sách; mở rộng sang hiệu chỉnh lại khoảng tin cậy của $\hat{\tau}$ để HITL không từ chối quá tay khi tác động trôi.

- **Shrinkage cho $\hat{\tau}$ trong $\hat{V}$**: co $\hat{\tau}$ về trung bình nhóm hoặc dùng cận dưới CI để giảm winner's curse; chỉ áp dụng sau khi có dữ liệu thí điểm thật, không dựa trên đáp án mô phỏng.
- **Đặt lại ngưỡng G4b theo regret B** hoặc theo tỷ lệ so với chính sách biết kỳ vọng thật, và công bố lại trước khi mở một Locked Test mới trên dữ liệu mới.
- **Dữ liệu can thiệp thật**: thay lớp bán tổng hợp bằng lịch sử chiến dịch thật ngay khi có; cho tới lúc đó, tiếp tục kiểm định phương pháp trên các RCT công khai.
- **Mở rộng kênh**: thêm thông báo đẩy, SMS hoặc quảng cáo nhắm lại để bài toán đúng nghĩa đa kênh; mô hình hóa hiệu ứng mang sang và giới hạn tần suất liên kênh.
- **Vận hành**: ghi lịch sử git từ đầu để đăng ký trước có dấu thời gian bên thứ ba; chuyển khâu chấm điểm Causal Forest sang chế độ lô để giảm 70 % độ trễ nếu quy mô tăng.

6.4. Kiến nghị vận hành và kịch bản ứng phó sự cố (Playbook) cho tổ chức

Kiến nghị phát hành. Không phát hành toàn phần. Thay vào đó chạy thí điểm với tỷ lệ đối chứng 50 % trong nhóm khách được chọn, trong tối thiểu 26 kỳ (một năm) và tối đa 91 kỳ, với tiêu chí dừng sớm là CI 95 % của giá trị chương trình (ước lượng DR) loại trừ 0 ở hai kỳ trưởng thành liên tiếp; nới K từ 60 lên 120 cuộc gọi theo giá bóng; giữ B = £8 000. Trong thời gian thí điểm, Current ra quyết định, Challenger lập kế hoạch ngân sách. Bảng 6.1 là playbook giám sát: mỗi cảnh báo có ngưỡng lấy từ cấu hình, chủ sở hữu, hành động và điều kiện quay lui.

Bảng 6.1. Playbook giám sát và ứng phó sự cố

Cảnh báo	Ngưỡng cảnh báo / báo động	Độ trễ dữ liệu	Chủ sở hữu	Hành động	Điều kiện quay lui
PSI đặc trưng (không tính đặc trưng lịch)	≥ 0,10 / ≥ 0,25	0 ngày	Data Scientist (MLOps)	Cảnh báo: soát pipeline dữ liệu; báo động ≥ 3 đặc trưng: đưa Challenger-2 vào đánh giá	PSI điểm $\hat{\mu}_0$ hoặc $\hat{V} \geq 0{,}25$ hai kỳ liên tiếp ⇒ quay lui Luật cũ qua Router
PSI điểm số ($\hat{\mu}_0$, $\hat{S}$, $\hat{\tau}$, $\hat{V}$)	≥ 0,10 / ≥ 0,25	0 ngày	Data Scientist	Kiểm tra trôi đầu vào; tạm giảm B nếu $\hat{V}$ trôi lên	như trên
ECE $\hat{\mu}_0$ trên kỳ đã trưởng thành	> 0,03 / ≥ 0,05	≥ 30 ngày (thực tế 42)	Data Scientist	Dùng Challenger cho kế hoạch ngân sách; giữ Current để ra quyết định tới khi duyệt	Chi phí chiết khấu thực vượt kế hoạch > 20 % hai kỳ liên tiếp ⇒ chuyển hẳn sang Challenger
Action TVD so với tham chiếu	— / ≥ 0,20	0 ngày	Trưởng nhóm CRM	Rà soát hành động bất thường; duyệt thủ công đợt gửi	TVD ≥ 0,20 kèm PSI báo động ⇒ quay lui Luật cũ qua Router

Cảnh báo	Ngưỡng cảnh báo / báo động	Độ trễ dữ liệu	Chủ sở hữu	Hành động	Điều kiện quay lui
Độ trễ P95 đầu–cuối	> 15 s / > 30 s	0 ngày	MLOps	Solver quá giờ ⇒ Greedy (dự phòng Router)	Quá ngưỡng 2 kỳ ⇒ chạy Luật cũ qua Router
Vi phạm ràng buộc trên quyết định gửi	— / > 0	0 ngày	Tài chính + MLOps	Chặn gửi đợt đó; sửa và chạy lại	Bất kỳ vi phạm ⇒ dừng gửi tự động, HITL 100 %
Giá trị thực hiện DR (đối chứng)	CI chứa 0 / CI < 0	≥ 30 ngày	Trưởng nhóm CRM + Tài chính	CI < 0: thu hẹp ngân sách, tăng tỷ lệ đối chứng	CI < 0 hai kỳ trưởng thành liên tiếp ⇒ quay lui Luật cũ qua Router
Tải HITL	> 150 / > 250 ca/kỳ	0 ngày	CSKH	Bổ sung người duyệt	Không duyệt kịp ⇒ ca chưa duyệt về a0
Tỷ lệ bị chặn cứng	tăng > 2× tham chiếu	0 ngày	Trưởng nhóm CRM	Soát danh sách opt-out, cap, hủy đơn	—

Nguồn: Tác giả tính toán từ `s8_oot_playbook.csv`; ngưỡng lấy từ `configs/config.yaml` (`monitoring`, `release_gates`).

VII. TÀI LIỆU THAM KHẢO (REFERENCES)

Trình bày theo chuẩn APA (ấn bản 7).

Ascarza, E. (2018). Retention futility: Targeting high-risk customers might be ineffective. *Journal of Marketing Research, 55*(1), 80–98. https://doi.org/10.1509/jmr.16.0163

Athey, S., Tibshirani, J., & Wager, S. (2019). Generalized random forests. *The Annals of Statistics, 47*(2), 1148–1178. https://doi.org/10.1214/18-AOS1709

Bach, P., Chernozhukov, V., Kurz, M. S., & Spindler, M. (2022). DoubleML – An object-oriented implementation of double machine learning in Python. *Journal of Machine Learning Research, 23*(53), 1–6.

Battocchi, K., Dillon, E., Hei, M., Lewis, G., Oka, P., Oprescu, M., & Syrgkanis, V. (2019). *EconML: A Python package for ML-based heterogeneous treatment effects estimation* (Version 0.x) [Phần mềm]. Microsoft Research. https://github.com/py-why/EconML

Bertsimas, D., & Kallus, N. (2020). From predictive to prescriptive analytics. *Management Science, 66*(3), 1025–1044. https://doi.org/10.1287/mnsc.2018.3253

Breck, E., Cai, S., Nielsen, E., Salib, M., & Sculley, D. (2017). The ML test score: A rubric for ML production readiness and technical debt reduction. Trong *2017 IEEE International Conference on Big Data* (tr. 1123–1132). IEEE.

Chen, D. (2012). *Online Retail II* [Bộ dữ liệu]. UCI Machine Learning Repository. https://doi.org/10.24432/C5CG6D

Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal, 21*(1), C1–C68. https://doi.org/10.1111/ectj.12097

Dudík, M., Langford, J., & Li, L. (2011). Doubly robust policy evaluation and learning. Trong *Proceedings of the 28th International Conference on Machine Learning* (tr. 1097–1104).

Elmachtoub, A. N., & Grigas, P. (2022). Smart "Predict, then Optimize". *Management Science, 68*(1), 9–26. https://doi.org/10.1287/mnsc.2020.3922

Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M., & Bouchachia, A. (2014). A survey on concept drift adaptation. *ACM Computing Surveys, 46*(4), Article 44. https://doi.org/10.1145/2523813

Gubela, R., Bequé, A., Lessmann, S., & Gebert, F. (2019). Conversion uplift in e-commerce: A systematic benchmark of modeling strategies. *International Journal of Information Technology & Decision Making, 18*(3), 747–791.

Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On calibration of modern neural networks. Trong *Proceedings of the 34th International Conference on Machine Learning* (PMLR 70, tr. 1321–1330).

Hillstrom, K. (2008, 20 tháng 3). *The MineThatData e-mail analytics and data mining challenge* [Bộ dữ liệu]. MineThatData.

https://blog.minethatdata.com/2008/03/minethatdata-e-mail-analytics-and-data.html

Huangfu, Q., & Hall, J. A. J. (2018). Parallelizing the dual revised simplex method. *Mathematical Programming Computation, 10*(1), 119–142. https://doi.org/10.1007/s12532-017-0130-5

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. Trong *Advances in Neural Information Processing Systems 30* (tr. 3146–3154).

Kennedy, E. H. (2023). Towards optimal doubly robust estimation of heterogeneous causal effects. *Electronic Journal of Statistics, 17*(2), 3008–3049. https://doi.org/10.1214/23-EJS2157

Künzel, S. R., Sekhon, J. S., Bickel, P. J., & Yu, B. (2019). Metalearners for estimating heterogeneous treatment effects using machine learning. *Proceedings of the National Academy of Sciences, 116*(10), 4156–4165. https://doi.org/10.1073/pnas.1804597116

Lakkaraju, H., Kleinberg, J., Leskovec, J., Ludwig, J., & Mullainathan, S. (2017). The selective labels problem: Evaluating algorithmic predictions in the presence of unobservables. Trong *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (tr. 275–284). https://doi.org/10.1145/3097983.3098066

Lei, J., G'Sell, M., Rinaldo, A., Tibshirani, R. J., & Wasserman, L. (2018). Distribution-free predictive inference for regression. *Journal of the American Statistical Association, 113*(523), 1094–1111. https://doi.org/10.1080/01621459.2017.1307116

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. Trong *Advances in Neural Information Processing Systems 30* (tr. 4765–4774).

Mandi, J., Kotary, J., Berden, S., Mulamba, M., Bucarey, V., Guns, T., & Fioretto, F. (2024). Decision-focused learning: Foundations, state of the art, benchmark and future opportunities. *Journal of Artificial Intelligence Research, 80*, 1623–1701. https://doi.org/10.1613/jair.1.15320

Naeini, M. P., Cooper, G. F., & Hauskrecht, M. (2015). Obtaining well calibrated probabilities using Bayesian binning. Trong *Proceedings of the Twenty-Ninth AAAI Conference on Artificial Intelligence* (tr. 2901–2907).

Nosek, B. A., Ebersole, C. R., DeHaven, A. C., & Mellor, D. T. (2018). The preregistration revolution. *Proceedings of the National Academy of Sciences, 115*(11), 2600–2606. https://doi.org/10.1073/pnas.1708274114

Platt, J. C. (1999). Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. Trong A. J. Smola, P. Bartlett, B. Schölkopf, & D. Schuurmans (Biên tập), *Advances in large margin classifiers* (tr. 61–74). MIT Press.

Radcliffe, N. J. (2007). Using control groups to target on predicted lift: Building and assessing uplift models. *Direct Marketing Analytics Journal, 1*, 14–21.

Robins, J. M., Rotnitzky, A., & Zhao, L. P. (1994). Estimation of regression coefficients when some regressors are not always observed. *Journal of the American Statistical Association*, *89*(427), 846–866. https://doi.org/10.1080/01621459.1994.10476818

Sculley, D., Holt, G., Golovin, D., Davydov, E., Phillips, T., Ebner, D., Chaudhary, V., Young, M., Crespo, J.-F., & Dennison, D. (2015). Hidden technical debt in machine learning systems. Trong *Advances in Neural Information Processing Systems 28* (tr. 2503–2511).

Tang, B., & Khalil, E. B. (2024). PyEPO: A PyTorch-based end-to-end predict-then-optimize library for linear and integer programming. *Mathematical Programming Computation*, *16*, 297–335. https://doi.org/10.1007/s12532-024-00255-x

VIII. PHỤ LỤC (APPENDIX)

8.1. Tài liệu minh chứng được cấp quyền truy cập (Google Colab / GitHub Repository)

- **GitHub Repository (công khai):** https://github.com/imty-cloud/retention-decision-system – toàn bộ mã nguồn `src/`, cấu hình `configs/config.yaml`, mô hình `models/`, dữ liệu đã xử lý `data/processed/`, bảng và hình `outputs/`, manifest và file khóa `outputs/manifests/`, bộ kiểm thử `tests/` (76 passed, 1 skipped), đặc tả và đăng ký trước `CLAUDE.md`, báo cáo kiểm toán độc lập `outputs/manifests/audit_2026-11-13.md`.
- **Google Colab:** `notebooks/PTDLNC_full_pipeline.ipynb` (nút "Mở trong Colab" trên README). Mặc định `RUN_FULL = False`: tự clone repo, kiểm tra SHA-256 ở ô đầu, rồi đọc lại toàn bộ bảng và hình (16/16 ô chạy không lỗi khi kiểm toán). Đặt `RUN_FULL = True` để chạy lại pipeline trên bản sao; Locked Test không thể mở lại.
- **Dữ liệu:** Online Retail II (CC BY 4.0) có trong `data/raw/online_retail_ii.zip`, SHA-256 `572e3627…8e67bfb`; Hillstrom không có giấy phép rõ ràng nên không kèm trong repo, script `s9` tự tải qua `sklift.datasets.fetch_hillstrom` (SHA-256 `bab6578f…885d7234f`).

8.2. Mã nguồn Python xuyên suốt

Bảng 8.1 liệt kê các module chính; mỗi module chạy độc lập bằng `python src/<tên>.py`, đọc `configs/config.yaml`, ghi bảng vào `outputs/tables/`, hình vào `outputs/figures/` và manifest vào `outputs/manifests/`.

Bảng 8.1. Các module mã nguồn và kích thước

File	Bytes	Vai trò
`src/common.py`	2 336	Đọc config, seed, ghi manifest SHA-256
`src/s1_data.py`	29 553	GĐ1: làm sạch, snapshot, nhãn, chia tập, hợp đồng dữ liệu, kiểm thử rò rỉ; danh sách `FEATURES_NUM`, `FEATURES_CAT`
`src/ s1b_intervention.py`	10 006	GĐ1b: lớp can thiệp bán tổng hợp, chính sách ghi log, propensity
`src/s2_predict.py`	21 657	GĐ2: $\hat{\mu}_0$ (Logit/LightGBM), Platt/Isotonic, $\hat{S}$ + conformal
`src/s3_explain.py`	20 389	GĐ3: PFI, SHAP, ổn định, faithfulness, mã lý do
`src/s4_causal.py`, `src/s4b_power_g3.py`	40 382 + 7 110	GĐ4: propensity, ATE (IPW/DML), CATE (T/X/DR/CausalForest), Qini, placebo; dự báo power G3
`src/s5_spo.py`, `src/s5b_dr_diagnostics.py`	51 273 + 24 178	GĐ5: PTO, SPO+ (subgradient tự cài), MSE ↔ regret, kiểm chứng 6 khách; chẩn đoán DR
`src/s6_milp.py`	38 194	GĐ6: MILP toàn quy mô, giá bóng, độ nhạy, thời gian giải
`src/s7_router.py`	97 398	GĐ7: lớp `ActionRouter`, guardrail, HITL mô phỏng, đối chứng, bản ghi quyết định
`src/s8_mlops.py`,	51 290 +	GĐ8: đóng băng, dry-run, mở locked, cổng phát hành; phát lại

File	Bytes	Vai trò
`src/s8b_oot.py`	48 695	OOT, PSI, Challenger, kịch bản trôi, playbook, thí điểm
`src/s9_external_hillstrom.py`	40 160	Kiểm định ngoài trên Hillstrom
`tools/build_packaging.py`	56 857	Sinh phụ lục SHA-256, bản tóm tắt và notebook
`tests/` (8 file)	—	pytest: cô lập đáp án, rò rỉ, hợp đồng, Router, khóa locked

Kích thước và SHA-256 đầy đủ của mọi file trong phạm vi đóng băng: `outputs/tables/s8_sha256_appendix.csv` *(51 file).*

8.3. Hợp đồng dữ liệu đầu vào – đầu ra (trích)

Hợp đồng đầy đủ gồm 185 dòng cho ba bảng snapshot, logged và decisions, khai báo bằng pandera và xuất ở `outputs/tables/appx_data_contract.csv`. Bảng 8.2 trích các cột then chốt.

Bảng 8.2. Trích hợp đồng dữ liệu

Bảng	Cột	Kiểu / ràng buộc	Mô tả
snapshot	customer_id, t0	string, datetime; khóa duy nhất	Mã khách (không dùng làm đặc trưng) và thời điểm quyết định
snapshot	recency_days, tenure_days	float ≥ 1	Số ngày từ đơn gần nhất / đơn đầu tiên đến t0
snapshot	n_orders_, *value_*	float ≥ 0	Số đơn và doanh số trong 30/90/180/365 ngày và toàn lịch sử
snapshot	cancel_rate_365	float ∈ [0, 1]	Tỷ lệ hủy đơn 365 ngày (guardrail > 0,3)
snapshot	y, y_value_h	int {0,1}, float ≥ 0	Nhãn mua lại trong [t0, t0+30) và giá trị giỏ (cột kiểm toán, không phải đặc trưng)
logged	A_logged, propensity_a0..a3, is_random_arm	category, float ∈ (0,1), int	Hành động ghi log, propensity của chính sách lịch sử, cờ nhánh ngẫu nhiên
logged	y_obs, value_obs, profit_obs	int, float, float	Kết quả quan sát dưới hành động ghi log
decisions	decision_id, idempotency_key	uuid5, string duy nhất	Khóa bản ghi quyết định và khóa chống lặp `customer_id|t0|policy_version`
decisions	action, channel, reason_codes, hitl_outcome, control_group	category, category, list, category, int	Hành động cuối, kênh, mã lý do, kết quả HITL, cờ đối chứng

8.4. Ma trận tương thích phiên bản

Bảng 8.3. Ma trận tương thích phiên bản (outputs/tables/s8_compat_matrix.csv)

Thành phần	Yêu cầu tối thiểu	Phiên bản chạy thực tế	Ghi chú
Python	3.11 (khuyến nghị)	3.14.7 (GĐ2–GĐ8, s9) · 3.13.18 (GĐ1, GĐ1b)	GĐ1/GĐ1b chạy trên Linux x86_64; các GĐ còn lại trên macOS arm64. Dựng lại GĐ1+GĐ1b trên macOS cho nội dung trùng 100 %. Chưa kiểm trên 3.11
Nền tảng	macOS Apple Silicon	macOS-27.2.1-arm64	LightGBM cần libomp (brew)
pandas / numpy / pyarrow	≥ 2.2 / ≥ 1.26 / ≥ 15	3.1.1 / 2.5.4 / 26.0.1	GĐ1: pandas 3.0.5, numpy 2.5.3
scikit-learn / lightgbm	≥ 1.4 / ≥ 4.3	1.9.1 / 4.7.0	
econml / doubleml / scikit-uplift	≥ 0.15 / ≥ 0.9 / ≥ 0.5	0.17.0 / 0.11.4 / 0.5.1	
highspy / pulp / pyepo / torch	≥ 1.7 / ≥ 2.8 / ≥ 0.4 / ≥ 2.2	1.16.0 / 4.2.0 / 2.2.7 / 2.15.0	SPO+ tự cài bằng numpy; PyEPO chỉ để đối chiếu
shap / pandera / pytest	≥ 0.45 / ≥ 0.20 / ≥ 8	0.54.1 / 0.36.0 / 9.2.0	

`requirements.txt` ghi yêu cầu tối thiểu; `outputs/manifests/requirements_lock.txt` là `pip freeze` của môi trường 3.14.7.

8.5. Bảng mã băm kiểm chứng SHA-256

Manifest đóng băng `outputs/manifests/s8_freeze_manifest.json` băm theo byte 28 file mã, mô hình, cấu hình, `CLAUDE.md` và 15 file parquet; hash tổng hợp được ghi vào file khóa `s8_locked_opened.lock` (mở lúc 2026-11-12T14:40:19Z). Lệnh kiểm tra: `python -c "import sys; sys.path.insert(0,'src'); import s8_mlops as S8; print(S8.verify_freeze() or 'KHỚP')"`. Bảng 8.4 trích một số hash; bảng đầy đủ 51 file ở `outputs/tables/s8_sha256_appendix.csv`.

Bảng 8.4. Trích bảng SHA-256

File	SHA-256
`src/common.py`	`72ab78c45744f7ed325fcba9b53e3532b6d0ee66477cc18a2d2bb84d2bac8f9e`
`src/s1_data.py`	`aae640ca989e70b1ba393d29c7aaad9834bd8d6614591abd3cc5935407efff4b`
`data/raw/online_retail_ii.zip`	`572e36277c2390fbfde10664750731e0a86f55e33470d91919085f0408e67bfb`
`data/raw/online_retail_II.xlsx` (giải nén)	`bcbe73b35f5b7babf197fb0cb983a11f5d9ff929078d4aa53d171b1f2df2e980`
`hillstorm_no_indices.csv.gz` (tải tự động)	`bab6578f60db5d792f1c2372c502f029152a5249cf5ea84390f3b7f885d7234f`

Các file còn lại (mô hình `.joblib`, parquet, config, CLAUDE.md, tests) xem file CSV nêu trên. `.gitattributes` đặt `* -text` để Git không đổi ký tự xuống dòng làm lệch hash.

8.6. Ghi chú tái lập

- Chạy lại GĐ1 sẽ tạo thêm `data/processed/raw_combined.parquet` trong phạm vi băm dữ liệu, nên `verify_freeze` báo "file mới" dù nội dung không đổi; hai hình `fig_s1_*` được ghi sau `s1_manifest.json` nên SHA trong manifest đó không còn khớp.
- `CLAUDE.md` §2 còn câu "tiếp theo: `--open-locked`" đã lỗi thời nhưng không sửa được vì nằm trong phạm vi băm; trạng thái thật ghi trong file khóa.
- Hai đầu vào nằm ngoài phạm vi băm: hệ số smearing và q conformal trong `s2_manifest.json` (đã đối chiếu khớp với `pred_s2.parquet`) và `s1_embargo_check.csv` mà G1 đọc.
- Kết quả chạy lại không nhất thiết trùng từng byte vì phụ thuộc phiên bản thư viện và đa luồng; hash đóng băng chỉ bảo đảm cho các file trong repo.